

2 Modelagem Estatística e Regressão

2.1 Introdução à Modelagem

Antes de estudarmos a regressão em si, é importante entender que ela faz parte de um campo mais amplo chamado **modelagem matemática/estatística**. Modelar é o ato de construir representações formais de fenômenos reais com o objetivo de descrevê-los, explicá-los, prever seu comportamento ou orientar decisões.

Em termos conceituais, modelar significa responder à seguinte pergunta:

Como posso representar, de maneira estruturada, um fenômeno complexo do mundo real por meio de variáveis e relações formais?

De forma geral, a modelagem matemática/estatística consiste na tentativa de traduzir um problema do mundo real em termos matemáticos ou estatísticos, estruturando hipóteses, equações e relações que permitam analisar e responder à pergunta proposta. Ela está presente em diversas áreas, como física, química, biologia, economia, engenharia e ciências sociais.

É fundamental compreender que **um modelo não é a realidade**. Ele é uma aproximação útil. Todo modelo envolve simplificações, suposições e escolhas: quais variáveis considerar, quais ignorar, que tipo de relação assumir, qual grau de precisão é necessário. Assim, modelar é sempre um exercício de equilíbrio entre realismo e simplicidade.

Alguns exemplos de fenômenos que podem ser descritos por modelos matemáticos incluem:

- Crescimento populacional;
- Reações químicas;
- Sistemas mecânicos e eletrônicos;
- Previsão do clima;
- Dinâmica do tráfego e da logística;
- Estratégias econômicas e financeiras;
- Mudanças ambientais e climáticas.

2.1.1 Modelo matemático versus modelo estatístico

Uma distinção conceitual importante é a diferença entre:

- **Modelo matemático (determinístico):** descreve uma relação funcional exata entre variáveis. Para cada valor de entrada, existe um único valor de saída.
- **Modelo estatístico (estocástico):** descreve uma relação média ou probabilística, reconhecendo a presença de variabilidade não explicada pelas variáveis observadas.

No modelo determinístico, escreve-se algo como:

$$Y = 2X$$

Aqui, se $X = 5$, então necessariamente $Y = 10$. Não há variação possível.

Já em um modelo estatístico, reconhecemos que fenômenos reais sofrem influência de fatores não observados, erros de mensuração, flutuações naturais ou variáveis omitidas. Assim, escreve-se:

$$Y = 2X + \varepsilon,$$

em que ε representa a componente aleatória (ruído).

A diferença entre essas duas estruturas pode ser visualizada na simulação abaixo.




Figura 2.1: Modelo matemático (determinístico) versus modelo estatístico (com ruído): no primeiro, a relação é funcional; no segundo, observa-se uma tendência média com variabilidade aleatória.

Observe que, no modelo estatístico, não buscamos uma igualdade exata, mas uma **tendência média** em torno da qual os dados se distribuem.

Essa diferença é central para compreender a regressão.

2.1.2 Classificações didáticas de modelos

De forma didática, modelos matemáticos/estatísticos podem ser classificados em:

1. Determinísticos ou estocásticos (estatísticos)

Dependendo se o acaso está explicitamente presente na formulação.

2. Discretos ou contínuos

Dependendo da natureza das variáveis envolvidas. Contagens são discretas; altura, peso e temperatura são contínuos.

3. Dinâmicos ou estáticos

Dependendo se o tempo é incorporado explicitamente na estrutura do modelo.

Essas classificações são discutidas em livros clássicos de modelagem matemática, como Meerschaert (2013) e Giordano; Fox; Horton (2013). Elas ajudam a organizar o tipo de pergunta que estamos fazendo e a estrutura matemática adequada para respondê-la.

2.1.3 O ciclo da modelagem

O processo de modelagem geralmente envolve as seguintes etapas:

1. Formular a pergunta em termos matemáticos.
2. Selecionar uma abordagem de modelagem.
3. Construir o modelo com base nas variáveis e hipóteses do problema.
4. Resolver o modelo matemático (ou ajustá-lo aos dados, no caso estatístico).

5. Interpretar a solução em termos do fenômeno real.

Esse ciclo é **iterativo**: muitas vezes o modelo precisa ser ajustado ou refinado conforme novas informações surgem. Ao confrontar o modelo com dados, podem surgir questões como:

- A forma funcional escolhida faz sentido?
- Variáveis importantes foram omitidas?
- O comportamento dos resíduos está de acordo com as hipóteses?
- O modelo mantém desempenho em novos dados?

Modelagem não é um procedimento linear; é um processo de aproximações sucessivas.

Além disso, três elementos costumam acompanhar o ciclo de modelagem:

- **Estimação ou calibração**: ajuste de parâmetros com base em dados observados.
- **Validação**: verificação da qualidade do ajuste.
- **Análise de sensibilidade**: avaliação do impacto de pequenas mudanças nas hipóteses ou nos dados.

2.1.4 Exemplos de modelagem

- **Problema de otimização**: determinar o momento ideal de venda de um animal de criação, considerando ganho de peso, custo de manutenção e preço de mercado.
- **Problema de crescimento populacional**: prever a evolução da população de um país ou espécie a partir de dados censitários.

Dentro desse panorama mais amplo, a regressão ocupa um papel específico: ela é uma técnica estatística voltada para modelar a **média condicional** de uma variável resposta em função de variáveis explicativas. Em outras palavras, ela formaliza matematicamente a ideia de que parte da variação observada pode ser explicada sistematicamente, enquanto outra parte permanece como ruído.

Modelagem é, portanto, a linguagem que conecta teoria, dados e inferência. A regressão é uma de suas expressões mais importantes.

2.1.4.1 Exemplos de modelagem em diferentes áreas

A modelagem matemática e estatística é utilizada para descrever e prever o comportamento de fenômenos em uma grande variedade de contextos. Alguns exemplos ilustrativos incluem:

- **Epidemiologia**: modelos SIR (Susceptíveis–Infectados–Recuperados) para descrever a propagação de doenças infecciosas ao longo do tempo.
- **Engenharia de Pesca**: relação entre esforço de pesca (dias de mar, número de embarcações) e o estoque pesqueiro disponível.
- **Ciência de Dados**: previsão da demanda de energia elétrica a partir de temperatura, hora do dia e perfil de consumo.
- **Economia**: modelos de oferta e demanda que relacionam preços e quantidades em equilíbrio de mercado.
- **Climatologia**: simulações que conectam emissão de gases de efeito estufa, temperatura média global e regimes de precipitação.
- **Educação**: análise da relação entre investimento em ensino e desempenho em exames padronizados.
- **Oceanografia**: modelos que descrevem correntes marinhas em função de gradientes de temperatura e salinidade.

Esses exemplos mostram que **modelagem é uma linguagem comum em ciência e tecnologia**. A regressão estatística é uma forma particular de modelagem que foca em quantificar relações entre variáveis observáveis,

buscando separar o **sinal** (estrutura determinística) do **ruído** (componente aleatória).

2.2 Introdução à Regressão

Regressão é um **modelo matemático-estatístico** que busca relacionar uma **variável resposta** (Y) com uma ou mais **variáveis explicativas**. De forma conceitual, a regressão parte da ideia de que o comportamento médio de Y pode ser descrito condicionalmente às variáveis explicativas X .

Em termos mais precisos, o que a regressão modela não é simplesmente Y , mas a **média condicional**:

$$E(Y | X)$$

Essa perspectiva é central nos textos clássicos de regressão e econometria ([Charnet et al., 2008](#); [Gujarati, 2006](#); [Hoffmann, 2006](#)). O objetivo não é afirmar que X determina exatamente Y , mas que existe uma **estrutura sistemática média** associada às variáveis explicativas.

A ideia fundamental é que a variação observada em um fenômeno pode ser decomposta em duas partes:

1. Uma **estrutura determinística** (ou componente sistemática), que representa o sinal da relação entre as variáveis;
2. Uma **componente aleatória**, representada pelo ruído ε , que captura variações não explicadas pelo modelo.

Essa decomposição aparece de forma recorrente na literatura de regressão aplicada ([Draper; Smith, 1998](#); [Kutner et al., 2005](#); [Montgomery; Peck; Vining, 2021](#)) como a base conceitual do modelo linear.

De forma geral, existem duas representações usuais para essa ideia. - **Modelo Aditivo** (o mais utilizado):

$$Y = \mu(X) + \varepsilon$$

- **Modelo Multiplicativo** (útil em contextos onde a variabilidade é proporcional ao nível médio):

$$Y = \mu(X) \cdot \varepsilon$$

com:

- $\mu(X) \rightarrow$ parte determinística (estrutura média);
- $\varepsilon \rightarrow$ componente aleatória (ruído), que pode ser aditivo ou multiplicativo.

O sinal $\mu(X)$ também é denominado de função de regressão.

No modelo aditivo clássico, assume-se que

$$E(\varepsilon | X) = 0,$$

isto é, o erro não carrega informação sistemática adicional sobre Y além da já contida em X . Essa condição garante que $E(Y | X) = \mu(X)$, permitindo interpretar $\mu(X)$ como a **média condicional de Y dado X** . Essa hipótese é central para a interpretação dos coeficientes como efeitos médios condicionais ([Gujarati, 2006](#); [Hoffmann, 2006](#)).

No caso do **modelo multiplicativo**, a condição análoga é

$$E(\varepsilon | X) = 1.$$

Nesse caso, temos $E(Y | X) = \mu(X) E(\varepsilon | X) = \mu(X)$, de modo que $\mu(X)$ continua representando a média condicional de Y dado X .

A diferença fundamental entre as duas formulações é estrutural. No modelo aditivo, o erro representa um **deslocamento absoluto** em torno da média condicional: a variação aleatória soma-se ao valor esperado, produzindo oscilações cuja magnitude, em princípio, não depende do nível médio. Já no modelo multiplicativo, o erro atua como um **fator proporcional**, ampliando ou reduzindo o valor médio de acordo com sua própria intensidade. Nesse caso, a variabilidade está intrinsecamente ligada ao nível esperado da variável resposta.

Essa distinção tem implicações relevantes. Em estruturas aditivas, concebe-se a variabilidade como relativamente independente da escala do fenômeno; em estruturas multiplicativas, a dispersão tende a crescer ou decrescer proporcionalmente ao valor médio. Fenômenos econômicos, biológicos e ambientais frequentemente apresentam esse comportamento proporcional, por exemplo, renda, produção, crescimento populacional ou biomassa, o que torna a formulação multiplicativa conceitualmente mais adequada em muitos contextos.

A escolha entre uma estrutura aditiva ou multiplicativa envolve considerações teóricas e empíricas. Modelos econômicos frequentemente sugerem relações proporcionais, enquanto a inspeção gráfica dos dados pode revelar padrões de variância crescente. Assim, a definição da forma funcional e da natureza da variação depende da teoria utilizada, da escala de mensuração das variáveis e do comportamento empírico observado nos dados ([Gujarati, 2006](#); [Hoffmann, 2006](#)).

No caso do modelo aditivo clássico, a hipótese de que o erro não carrega informação sistemática adicional além da contida nas variáveis explicativas é central para a interpretação dos coeficientes como efeitos médios condicionais. Essa perspectiva, segundo a qual a regressão modela a média condicional e não valores individuais, constitui um dos pilares da regressão aplicada e da econometria tradicional ([Gujarati, 2006](#); [Hoffmann, 2006](#)).

2.2.1 Interpretação conceitual: sinal e ruído

A regressão parte do reconhecimento de que fenômenos reais são influenciados por múltiplos fatores, muitos dos quais não são observáveis ou mensuráveis. Assim, mesmo que exista uma relação estrutural entre X e Y , os dados observados não estarão perfeitamente alinhados sobre uma curva.

O modelo assume que:

$$Y = \text{sinal} + \text{ruído}$$

O sinal representa a parte explicável pelas variáveis incluídas no modelo; o ruído representa:

- variáveis omitidas,
- erros de mensuração,
- flutuações naturais,
- fatores aleatórios não controlados.

Essa separação entre componente sistemática e erro é um dos pilares da regressão linear clássica ([Draper; Smith, 1998](#)).

2.2.1.1 Exemplo ilustrativo: Sinal + Ruído

A seguir, simulamos um conjunto de dados artificiais para ilustrar a lógica central da regressão: **um sinal determinístico mais um componente de ruído**.


Considere a relação:

$$Y = 3 + 2X + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 5^2),$$

com $X \in \{1, 2, \dots, 30\}$. A reta $Y = 3 + 2X$ representa o **sinal verdadeiro**, enquanto os pontos observados (X, Y) incluem a variabilidade aleatória do ruído ε .

O gráfico abaixo mostra a dispersão dos dados simulados juntamente com a curva verdadeira. Essa visualização reforça a ideia de que a regressão busca recuperar a estrutura determinística do fenômeno em meio à aleatoriedade introduzida pelos ruídos (erros ou fonte de variação).

Relação entre X e Y: sinal + ruído




2.2.1.2 Exemplo ilustrativo: Sinal + Ruído (homoscedástico vs heteroscedástico)

Neste exemplo, comparamos dois cenários de regressão linear que diferem apenas na **dispersão dos ruídos**:


- **Homoscedástico**: a variância dos erros é constante em todos os valores de X . Nesse caso, a nuvem de pontos se distribui de forma aproximadamente uniforme em torno da reta verdadeira, independentemente da posição no eixo X .
- **Heteroscedástico**: a variância cresce com X . Assim, para valores pequenos de X os pontos estão mais concentrados, enquanto para valores grandes de X a dispersão aumenta.

Esse contraste é fundamental: se a homoscedasticidade não for respeitada, os estimadores de mínimos quadrados continuam **não viesados**, mas deixam de ser eficientes (ou seja, não são os de menor variância). Isso motiva o uso de métodos alternativos, como os mínimos quadrados ponderados (WLS) ou transformações nos dados.

Variância constante



Variância crescente




Sinal + ruído: (esq.) variância constante; (dir.) variância crescente (heteroscedasticidade).

2.2.1.3 Exemplo ilustrativo: Possibilidades de relações ente X e Y

Observe que nem toda relação entre duas variáveis é **linear e forte**. Considere alguns possibilidades comuns:

- **(a) Sem correlação:** não existe padrão claro entre X e Y ; conhecer X não ajuda a prever Y .
- **(b) Correlação linear fraca:** existe uma tendência positiva, mas com grande dispersão ao redor da reta.
- **(c) Correlação linear forte:** os pontos seguem de perto uma tendência linear; X *explica* grande parte da variabilidade em Y .
- **(d) Relação não linear:** X e Y se relacionam, mas a forma não é bem descrita por uma reta (por exemplo, uma parábola).

Esse exemplo mostra que a **correlação linear** é apenas um caso particular dentro de uma variedade de possíveis dependências entre variáveis. Por isso, ao analisar dados, é sempre importante, quando possível, **visualizar os diagramas de dispersão** antes de ajustar um modelo, evitando conclusões equivocadas sobre linearidade.



Correlação entre X e Y: (a) nenhuma, (b) linear fraca, (c) linear forte, (d) não linear.

2.2.1.4 Exemplo ilustrativo: Relação não linear entre X e Y

Até agora, discutimos a regressão sob a perspectiva de relações lineares. No entanto, nem todo fenômeno real apresenta comportamento aproximadamente linear. Em muitos contextos, como crescimento biológico, processos de absorção, liberação acumulada de substâncias ou resposta a doses, a relação entre as variáveis pode apresentar **curvatura**, **saturação** ou **pontos de inflexão**.

Neste exemplo, construiremos artificialmente uma base de dados cujo **sinal verdadeiro não é linear**. O comportamento adotado será do tipo **crescimento com saturação**: inicialmente, pequenos aumentos em X produzem grandes aumentos em Y ; à medida que X cresce, o efeito marginal diminui e a curva tende a estabilizar.

Essa estrutura pode ser representada genericamente por uma função do tipo:

$$Y = f(X) + \varepsilon$$

em que $f(X)$ é não linear e ε representa o componente aleatório.

O objetivo aqui é didático: comparar dois cenários sobre os mesmos dados observados:

1. Ajustar um **modelo linear**, mesmo sabendo que o sinal não é linear;
2. Comparar esse ajuste com a **curva verdadeira** que gerou os dados.

Essa comparação permite visualizar um ponto conceitual central da modelagem:

Um modelo pode estar corretamente estimado sob suas hipóteses e, ainda assim, estar incorretamente especificado.

Ou seja, o problema pode não estar na estimação, mas na **forma funcional escolhida**.

Ao observar os gráficos, procure refletir:

- O modelo linear captura adequadamente o padrão médio?
- Há evidências visuais de curvatura?
- O erro parece sistemático ao longo de X ?
- O que aconteceria com os resíduos nesse caso?

Esse tipo de análise visual é uma etapa importante antes da formalização do modelo. A regressão linear é uma ferramenta poderosa, mas sua adequação depende da coerência entre a estrutura assumida e o comportamento real dos dados.




Figura 2.2: Exemplo com sinal não linear: (esq.) ajuste linear; (dir.) sinal verdadeiro que gerou os dados.

2.2.2 Objetivos e Estruturas do Modelo da Regressão

Depois de explorar exemplos visuais de associação entre variáveis, é importante consolidar uma visão mais conceitual sobre a regressão. A regressão não é simplesmente uma técnica de ajuste de curvas; ela é uma estrutura formal para modelar a **relação média entre variáveis observáveis**.

Em termos conceituais, a regressão procura compreender como o comportamento médio de Y varia em função de X . Isto é, ela organiza a seguinte pergunta:

Como a variável resposta se comporta, em média, quando as variáveis explicativas variam?

2.2.2.1 Objetivos centrais

A regressão pode ser compreendida a partir de três grandes finalidades:

1. Explicar

Identificar quais fatores estão associados à variável resposta e quantificar a magnitude dessas associações.

2. Predizer

Utilizar o modelo ajustado para estimar valores futuros ou não observados de Y .

3. Controlar

Avaliar o efeito de uma variável mantendo as demais constantes, permitindo interpretações condicionais.

Esses objetivos aparecem de maneira combinada na prática. Em econometria, frequentemente busca-se compreender relações estruturais entre variáveis macroeconômicas (Gujarati, 2006; Hoffmann, 2006). Em engenharia e estatística aplicada, pode haver maior ênfase na capacidade preditiva do modelo (Montgomery; Peck; Vining, 2021). Em estudos científicos em geral, explicar e prever caminham juntos.

2.2.2.2 Observações conceituais importantes

Antes de avançarmos para a formalização do modelo linear simples, duas observações merecem destaque.

1. Correlação significativa e ajuste linear

Em geral, quando existe correlação linear significativa entre variável explicativa e variável resposta, é razoável esperar que o Modelo de Regressão Linear Simples produza um ajuste satisfatório. Isso ocorre porque a correlação mede o grau de associação linear entre duas variáveis. Se essa associação é forte, a reta ajustada tende a capturar uma parcela substancial da variabilidade observada.

Entretanto, correlação elevada não garante que o modelo esteja corretamente especificado. Pode haver curvatura, variância não constante ou outros padrões estruturais não capturados por uma reta. A inspeção gráfica continua sendo essencial.

2. Associação estatística não implica causa e efeito

Uma relação estatística entre variáveis não implica automaticamente causalidade. Mesmo que um coeficiente estimado seja estatisticamente significativo, isso não significa que uma variável cause a outra. A interpretação causal:

- não pode se basear apenas na amostra considerada;
- deve estar apoiada em teoria ou conhecimento empírico;
- pode exigir desenho experimental ou hipóteses estruturais adicionais.

Exemplos clássicos ilustram essa distinção:

- **Despesas de consumo pessoal e renda pessoal disponível** — aqui, a teoria econômica sustenta a direção causal.
- **Ganho de peso e consumo de calorias** — a evidência empírica e experimental apoia a interpretação causal.

Sem essa base teórica ou experimental, a regressão revela associação, não mecanismo causal.

2.2.2.3 Duas características fundamentais do modelo de regressão


Do ponto de vista probabilístico, um modelo de regressão possui duas características essenciais:

1. Para cada nível fixado de X , existe uma **distribuição de probabilidade de Y** .
2. As médias dessas distribuições variam de forma sistemática com X .

Essa segunda característica é o coração da regressão: modelar como a média de Y se altera quando X varia.

Visualmente, isso significa que, para cada valor de X , não há um único valor possível de Y , mas sim uma distribuição de valores possíveis. O modelo descreve o comportamento médio dessas distribuições.

Geração de observações em regressão linear



Como as observações são geradas em regressão linear.

Essa perspectiva probabilística será formalizada no próximo capítulo, quando introduzirmos o Modelo de Regressão Linear Simples (MRLS).

2.2.2.4 Estrutura conceitual da regressão

Independentemente da área, a regressão parte de uma ideia fundamental:

$$Y = \text{parte sistemática} + \text{parte não explicada}$$

A parte sistemática representa o padrão médio associado às variáveis explicativas. A parte não explicada representa variações adicionais que não são capturadas pelo modelo, seja por fatores não observados, limitações de mensuração ou variabilidade inerente ao fenômeno.

A regressão organiza essa decomposição de maneira formal e mensurável. Ela não elimina a variabilidade; ela a estrutura.

2.2.2.5 Alguns exemplos que mostram a importância prática

A utilidade da regressão torna-se mais clara quando observamos aplicações concretas.

- **Economia**

Modelos de regressão são usados para analisar como variáveis como taxa de juros, câmbio e nível de consumo se associam à inflação. O objetivo pode ser compreender o mecanismo econômico (explicação) ou projetar cenários futuros (previsão).

- **Saúde**

Em estudos clínicos, a regressão permite avaliar a relação entre tratamento e resposta terapêutica, controlando

por idade, sexo ou comorbidades. Aqui, a regressão organiza a comparação entre grupos e ajuda a quantificar diferenças médias.

- **Engenharia**

Na modelagem da resistência de materiais, regressões relacionam tensão aplicada e deformação observada, permitindo prever limites operacionais.

- **Esportes**

Pode-se modelar o desempenho de uma equipe em função de variáveis como investimento, tempo de posse de bola ou eficiência ofensiva, identificando padrões associados ao resultado final.

- **Pesca e aquicultura**

Relações entre esforço de pesca e biomassa capturada, ou entre tempo de cultivo e ganho de peso, podem ser analisadas por regressão para apoiar decisões produtivas.

- **Políticas públicas**

Avaliações de impacto utilizam regressão para investigar como programas sociais se associam a indicadores como renda, escolaridade ou emprego.

Esses exemplos mostram que regressão não é apenas um instrumento matemático; é uma ferramenta de organização do raciocínio quantitativo em contextos reais.

2.2.2.6 Potenciais e limites

A regressão possui algumas virtudes que explicam sua ampla utilização:

- Permite quantificar efeitos médios;
- Oferece interpretação relativamente direta dos coeficientes;
- Estrutura a análise de dados de forma sistemática;
- Serve como base para extensões mais sofisticadas.

Ao mesmo tempo, é importante reconhecer que:

- A qualidade da conclusão depende da qualidade dos dados;
- A forma funcional escolhida influencia os resultados;
- Modelos podem ser mal especificados;
- Associação estatística não é automaticamente causalidade.

Reconhecer essas dimensões faz parte da maturidade estatística.

A regressão é, portanto, uma ferramenta que conecta **teoria, dados e decisão**. Ela organiza a variabilidade observada em uma estrutura interpretável e mensurável.

No próximo capítulo, iniciaremos o estudo formal do **Modelo de Regressão Linear Simples (MRLS)**, que constitui o ponto de partida para compreender, com rigor matemático, como essa estrutura é estimada e quais propriedades possui.