

9 Transformações nas Variáveis

9.1 Motivação

Quando os **gráficos de resíduos** revelam padrões sistemáticos, heteroscedasticidade ou violações de normalidade, é sinal de que a especificação do modelo pode estar inadequada. Em termos formais, isso significa que ao menos uma das hipóteses centrais do MRLS — linearidade da função média, homoscedasticidade ou normalidade dos erros — pode não estar sendo satisfeita ([Kutner et al., 2005](#); [Montgomery; Peck; Vining, 2021](#)).

A regressão linear simples assume que

$$E(Y | X) = \beta_0 + \beta_1 X \quad \text{e} \quad Var(Y | X) = \sigma^2,$$

ou seja, uma **relação linear na média** e **variância constante** condicionalmente a X . Quando os resíduos exibem padrões como funil (variância crescente), curvaturas sistemáticas ou forte assimetria, o modelo ajustado não está capturando adequadamente a estrutura do processo gerador dos dados.

Uma das abordagens mais tradicionais para lidar com tais situações é aplicar **transformações matemáticas** às variáveis, de modo a:

- estabilizar a variância;
- aproximar a normalidade dos erros;
- linearizar a relação entre as variáveis;
- tornar a interpretação estatística mais coerente com a estrutura do fenômeno estudado.

Há duas formas de realizar tais transformações:

- (a) na variável resposta (Y) e
- (b) na variável explicativa (X).

Note que, ao aplicarmos uma transformação de variáveis, estamos implicitamente redefinindo o modelo estatístico. Por exemplo, ao transformar Y em $\log(Y)$, deixamos de modelar diretamente $E(Y | X)$ e passamos a modelar $E(\log Y | X)$. Isso altera a interpretação dos coeficientes, a distribuição assumida para os erros e, em certos casos, a própria classe de modelos implícita ([Kutner et al., 2005](#); [Weisberg, 2005](#)).

Portanto, transformações devem ser motivadas por evidência empírica (diagnóstico de resíduos) e, sempre que possível, por fundamentação teórica do fenômeno estudado. Aplicá-las de forma automática pode melhorar métricas numéricas de ajuste, mas comprometer a interpretação do modelo.

Além disso, a aplicação de uma transformação implica um novo ciclo completo de análise:

1. Ajustar o modelo transformado.
2. Reavaliar os resíduos.
3. Verificar se as hipóteses agora são plausíveis.

Esse processo é inerentemente iterativo.

Quando a transformação envolve apenas mudanças algébricas simples (como logaritmo ou raiz quadrada), as justificativas formais podem ser entendidas via propriedades de variância e distribuições conhecidas; demonstrações mais técnicas dessas propriedades podem ser consultadas no Apêndice de Demonstrações {#demo}.

Nas seções seguintes, analisaremos separadamente as transformações aplicadas à variável resposta e à variável explicativa, enfatizando sua motivação estatística e suas implicações interpretativas.

9.2 Transformações na variável resposta (Y)

As transformações na variável resposta têm como objetivo principal modificar a **estrutura probabilística condicional de Y dado X** . Em muitos contextos aplicados, a violação das hipóteses do MRLS decorre não da forma funcional da média, mas do comportamento da variância ou da distribuição dos erros.

Recordando que o MRLS assume $Var(Y | X) = \sigma^2$, qualquer evidência de que

$$Var(Y | X) \neq \text{constante}$$

ou que os erros apresentam forte assimetria ou caudas pesadas pode motivar uma transformação em Y (Kutner et al., 2005; Montgomery; Peck; Vining, 2021; Weisberg, 2005).

Para exemplificar, suponha que a variância condicional dependa da média:

$$Var(Y | X) = g(E(Y | X)),$$

para alguma função $g(\cdot)$ crescente. Isso ocorre, por exemplo:

- quando a variância é proporcional à média (dados de contagem);
- quando a variância cresce aproximadamente com o quadrado da média (dados positivos e assimétricos);
- quando há padrão de funil nos resíduos vs. ajustados.

Nesse cenário, podemos buscar uma transformação $Y^* = h(Y)$ tal que

$$Var(Y^* | X) \approx \text{constante}.$$

Esse princípio é conhecido como **estabilização da variância**, e sua justificativa formal pode ser obtida por expansão de Taylor de primeira ordem (ver Apêndice de Demonstrações {#demo}).

É importante destacar que transformar Y altera simultaneamente: - a escala da resposta; - a forma da distribuição condicional; - a interpretação dos coeficientes.

Portanto, não estamos apenas “melhorando resíduos”, mas redefinindo o modelo estatístico.

9.2.1 Transformação e distribuição implícita

Se ajustamos o modelo

$$Y_i^* = h(Y_i) = \beta_0^* + \beta_1^* X_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2),$$

então estamos assumindo normalidade **na escala transformada**.

Isso implica que, na escala original, Y possui distribuição derivada da transformação inversa. Por exemplo:

- se $h(Y) = \log Y$, então Y é log-normal condicionalmente a X ;
- se $h(Y) = \sqrt{Y}$, a distribuição resultante não é normal na escala original, mas a variância pode se tornar aproximadamente constante;
- se $h(Y) = 1/Y$, a estrutura média passa a ser modelada em termos do inverso da resposta.

Essa mudança tem implicações importantes para:

- interpretação de coeficientes;
- construção de intervalos de confiança;
- previsão na escala original.

Ao transformar Y , a hipótese de normalidade passa a ser avaliada na nova escala. Isso significa que testes t , testes F e intervalos de confiança são válidos sob a suposição de normalidade dos erros na escala transformada, não necessariamente na escala original (Kutner et al. (2005)).

Nas subseções seguintes, discutiremos transformações específicas, a saber, logaritmo, raiz quadrada, inverso e potência.

9.2.2 Logaritmo ($Y^* = \log Y$)

A transformação logarítmica é uma das mais utilizadas em regressão, especialmente quando Y é **positiva** e apresenta **assimetria à direita** ou variância crescente com o nível médio.

Se ajustamos o modelo

$$Y_i^* = \log(Y_i) = \beta_0^* + \beta_1^* X_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2),$$

estamos assumindo normalidade dos erros **na escala logarítmica**. Isso implica que, condicionalmente a X_i , a variável original Y_i segue uma **distribuição log-normal** (Kutner et al., 2005; Weisberg, 2005).

Mais precisamente, se

$$\log(Y_i) \mid X_i \sim N(\mu_i, \sigma^2),$$

então

$$Y_i \mid X_i \sim \text{LogNormal}(\mu_i, \sigma^2).$$

A transformação logarítmica converte relações multiplicativas em aditivas. Se, na escala original,

$$Y = \alpha \exp(\beta X) \cdot U,$$

onde U é um termo multiplicativo de erro, então

$$\log Y = \log \alpha + \beta X + \log U,$$

ou seja, o modelo passa a ter estrutura linear com erro aditivo na escala transformada.

Isso significa que o logaritmo é particularmente adequado quando:

- a variabilidade é proporcional ao nível médio;
- o crescimento é aproximadamente exponencial;
- o erro atua de forma **multiplicativa** na escala original.

No modelo

$$E[\log(Y) \mid X] = \beta_0^* + \beta_1^* X,$$

o coeficiente β_1^* representa a variação **aditiva no logaritmo da resposta** para cada unidade adicional em X .

Na escala original,

$$E(Y \mid X) = \exp(\beta_0^*) \cdot \exp(\beta_1^* X).$$

Assim, um aumento de 1 unidade em X multiplica o valor esperado de Y por $\exp(\beta_1^*)$.

Para valores pequenos de β_1^* , podemos usar a aproximação

$$\exp(\beta_1^*) \approx 1 + \beta_1^*,$$

o que leva à interpretação aproximada de que $\beta_1^* \times 100\%$ representa uma variação percentual em Y para cada unidade de X .

Essa interpretação percentual é uma aproximação válida apenas quando $|\beta_1^*|$ é pequeno. O efeito exato é multiplicativo e deve ser interpretado via $\exp(\beta_1^*)$.

9.2.2.1 Variância e estabilização

Se a variância cresce aproximadamente de forma proporcional ao quadrado da média,

$$\text{Var}(Y | X) \propto [E(Y | X)]^2,$$

então a transformação logarítmica tende a produzir variância aproximadamente constante na escala transformada.

Advertência sobre retransformação

Ao obter previsões na escala original, não é correto simplesmente calcular

$$\hat{Y} = \exp(\widehat{\log Y}),$$

pois, para variável log-normal,

$$E(Y | X) = \exp(\mu + \frac{1}{2}\sigma^2),$$

e não apenas $\exp(\mu)$ (Casella; Berger, 2002). Ignorar esse termo pode introduzir **viés de retransformação**.

Quando usar

- Resíduos vs. ajustados exibem padrão de funil.
- Histograma dos resíduos apresenta assimetria à direita.
- QQ-plot mostra caudas pesadas superiores.
- Relação parece exponencial na escala original.

Gráficos sugeridos para verificação:

- Resíduos vs. $\hat{Y}$ (o que verificar: formato de funil; resultado esperado após transformação: dispersão homogênea).
- QQ-plot dos resíduos (o que verificar: caudas pesadas; resultado esperado após transformação: alinhamento mais próximo à reta).
- Histograma dos resíduos (o que verificar: assimetria; resultado esperado após transformação: formato mais próximo da normal).

9.2.3 Raiz quadrada ($Y^* = \sqrt{Y}$)

A transformação pela raiz quadrada é frequentemente utilizada quando Y representa **contagens** ou frequências.

Por exemplo, se $Y_i \sim \text{Poisson}(\mu_i)$, então

$$E(Y_i) = \mu_i, \quad \text{Var}(Y_i) = \mu_i,$$

ou seja, a variância é proporcional à média.

Aplicando a transformação

$$Y_i^* = \sqrt{Y_i},$$

e utilizando aproximação por expansão de Taylor, obtém-se

$$\text{Var}(Y_i^*) \approx \frac{1}{4},$$

que é aproximadamente constante e independe de μ_i (ver Apêndice de Demonstrações {#demo}).

Note que a raiz quadrada reduz a assimetria típica de distribuições de contagem e estabiliza a variância quando esta é proporcional à média.

O modelo passa então a explicar a variação na **raiz da resposta**, não na resposta original. Isso altera a escala e deve ser explicitado ao interpretar coeficientes.

Quando usar

- Dados de contagem.
- Variância aproximadamente proporcional à média.
- Histograma com cauda longa à direita.

Gráficos sugeridos para verificação:

- Histograma dos resíduos (o que verificar: cauda longa; resultado esperado após transformação: simetria).
- Resíduos vs. $\hat{Y}$ (o que verificar: variância crescente; resultado esperado após transformação: dispersão estável).

9.2.4 Inverso ($Y^* = 1/Y$)

A transformação inversa é útil quando a relação entre Y e X apresenta comportamento do tipo **decaimento rápido em direção a um limite**.

Se a relação original for não linear, por exemplo,

$$Y = \frac{1}{\alpha + \beta X},$$

então

$$\frac{1}{Y} = \alpha + \beta X,$$

que é linear.

Essa transformação é comum em fenômenos físicos e biológicos nos quais a resposta diminui rapidamente e depois se estabiliza.

O modelo ajustado explica o comportamento do **inverso da resposta**. A interpretação substantiva deve ser feita com cuidado, pois aumentos em X passam a produzir efeitos lineares sobre $1/Y$, e não diretamente sobre Y .

Quando usar

Modelos onde a resposta diminui de forma não linear (ex.: tempo de reação decrescendo com aumento de dose).

Gráficos sugeridos para verificação:

- Resíduos vs. X (o que verificar: padrão curvilíneo; resultado esperado após transformação: dispersão aleatória).
- QQ-plot dos resíduos (o que verificar: forte desvio; resultado esperado após transformação: mais alinhado).

9.2.5 Quadrado ($Y^* = Y^2$)

A transformação quadrática pode ser útil quando a variabilidade é maior em valores pequenos de Y ou quando a relação é convexa na escala original.

Ao elevar Y ao quadrado, ampliamos diferenças em níveis mais altos da resposta, o que pode reduzir padrões estruturais nos resíduos.

Essa transformação modifica significativamente a escala e deve ser utilizada apenas quando há justificativa empírica clara nos gráficos de resíduos.

Gráficos sugeridos para verificação:

- Resíduos vs. $\hat{Y}$ (o que verificar: padrão em arco; resultado esperado após transformação: dispersão homogênea).
- Histograma dos resíduos (o que verificar: concentração em torno de 0; resultado esperado após transformação: mais espalhado).

9.3 Transformações na variável explicativa (X)

As transformações na variável explicativa têm como objetivo principal **linearizar a relação entre X e a média condicional de Y** , preservando, quando possível, a estrutura de variância constante dos erros.

Recordando que o MRLS assume $E(Y | X) = \beta_0 + \beta_1 X$, portanto, qualquer evidência de que a relação média entre Y e X não é linear, por exemplo, presença de curvatura sistemática no gráfico de resíduos vs. X , sugere que a especificação funcional pode estar inadequada (Kutner et al., 2005; Montgomery; Peck; Vining, 2021).

Nesse caso, buscamos uma transformação $X^* = h(X)$ tal que

$$E(Y | X^*) = \beta_0 + \beta_1 X^*$$

represente melhor a estrutura média do fenômeno.

Transformar X significa alterar a **forma funcional da regressão** em relação à variável X , mas não a natureza probabilística da variável resposta. Diferentemente das transformações em Y , aqui a distribuição condicional de Y não é redefinida; apenas modificamos a forma como a média depende da variável explicativa.

Portanto:

- Transformações em $Y \rightarrow$ alteram a escala da resposta e a estrutura probabilística.
- Transformações em $X \rightarrow$ alteram a forma funcional da média em relação à variável X .

9.3.1 Motivação estatística

Se o gráfico de resíduos vs. X exibe:

- padrão em arco (concavidade ou convexidade),
- forma em S,
- tendência sistemática crescente ou decrescente,

então o modelo linear $\beta_0 + \beta_1 X$ não está capturando adequadamente a relação entre as variáveis. A solução é buscar uma transformação $h(X)$ tal que a nova relação seja aproximadamente linear.

Essa estratégia é coerente com o princípio geral de modelagem estatística: **especificar corretamente a função média antes de avaliar a variância dos erros** (Weisberg, 2005).

9.3.2 Logaritmo ($X^* = \log X$)

A transformação logarítmica em X é apropriada quando a relação entre Y e X apresenta comportamento de crescimento proporcional ou lei de potência.

Suponha que a relação verdadeira seja

$$Y = \alpha X^\beta + \varepsilon.$$

Tomando logaritmo em ambos os lados (desconsiderando momentaneamente o erro),

$$\log Y = \log \alpha + \beta \log X.$$

Se também transformarmos Y , obtemos o chamado modelo **log-log**, amplamente utilizado em econometria.

No entanto, mesmo sem transformar Y , pode ser apropriado modelar

$$Y = \beta_0 + \beta_1 \log X + \varepsilon,$$

quando o efeito de X diminui à medida que X cresce.

Observe que no modelo

$$Y = \beta_0 + \beta_1 \log X,$$

o coeficiente β_1 representa a variação média em Y associada a uma variação proporcional em X . Mais especificamente, um aumento percentual em X está associado a uma variação aproximadamente linear em Y .

Portanto, a transformação logarítmica em X não implica mudança na distribuição de Y .

Gráfico sugerido:

- Resíduos vs. X (o que verificar: curva sistemática; resultado esperado após transformação: dispersão aleatória).

9.3.3 Inverso ($X^* = 1/X$)

A transformação inversa é adequada quando o efeito de X é muito forte para valores pequenos e diminui rapidamente conforme X aumenta.

Exemplo típico:

- fenômenos de aprendizado;
- processos de saturação;

- respostas que se estabilizam para grandes valores de X .

Se a relação verdadeira for aproximadamente

$$Y = \alpha + \frac{\beta}{X},$$

então

$$Y = \alpha + \beta X^*$$

com $X^* = 1/X$.

A transformação inversa captura comportamentos de **retorno decrescente** ou aproximação assintótica.

Gráfico sugerido:

- Resíduos vs. X (o que verificar: curva decrescente; resultado esperado após transformação: sem padrão).

9.3.4 Potências e termos polinomiais ($X^2, X^3, \dots$)

Quando a relação apresenta curvatura suave, uma alternativa é expandir o modelo com termos polinomiais:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \varepsilon.$$

Esse modelo continua sendo linear nos parâmetros (condição essencial do MRLS), embora não seja linear em X .

Temos então que:

- $\beta_2 > 0 \rightarrow$ concavidade para cima (convexidade).
- $\beta_2 < 0 \rightarrow$ concavidade para baixo.

Apesar de introduzir não linearidade em X , o modelo permanece linear em relação aos parâmetros β_j . Isso garante que:

- os estimadores de MQO continuam válidos;
- as propriedades inferenciais permanecem as mesmas.

Essa distinção entre **linearidade nos parâmetros** e **linearidade na variável explicativa** é conceitualmente central em regressão linear.

Gráfico sugerido:

- Resíduos vs. X (o que verificar: arco ou S-curva; resultado esperado após transformação: resíduos aleatórios).

9.3.5 Transformar X ou adicionar polinômios?

Há duas estratégias principais para lidar com curvaturas:

1. Transformar X (por exemplo, $\log X$, $1/X$).
2. Incluir termos polinomiais (X^2 , X^3).

A escolha depende de:

- coerência teórica;

- interpretação desejada;
- estabilidade numérica do ajuste.

Transformações simples costumam ter interpretação mais direta; polinômios oferecem maior flexibilidade, mas podem introduzir instabilidade em extrapolações.

Logo, as transformações na variável explicativa:

- buscam linearizar a função média;
- não alteram a estrutura probabilística da resposta;
- preservam a estrutura básica do MRLS;
- exigem reavaliação completa dos resíduos após o ajuste.

9.4 Guia prático: escolhendo a transformação

Após compreender as motivações teóricas para transformar Y ou X , surge a questão prática: **como decidir qual transformação aplicar?**

A escolha não deve ser arbitrária nem baseada apenas em melhora numérica de R^2 . O critério central é a adequação às hipóteses do modelo e à estrutura substantiva do fenômeno (Kutner et al, 2005; Montgomery; Peck; Vining, 2021).

Etapa 1 — Diagnóstico inicial

Antes de qualquer transformação, ajusta-se o modelo na escala original:

$$Y_i = \beta_0 + \beta_1 X_i + e_i.$$

Em seguida, analisam-se os resíduos:

- Resíduos vs. ajustados → verificar homoscedasticidade.
- Resíduos vs. X → verificar linearidade.
- QQ-plot → verificar normalidade.
- Histograma → avaliar assimetria e caudas.

A transformação deve responder a um padrão empírico específico observado nos resíduos. Se não há padrão sistemático, não há justificativa para transformar.

Etapa 2 — Identificação do padrão

Alguns padrões típicos e suas possíveis soluções:

Padrão observado	Possível causa	Transformação sugerida
Funil (variância cresce com média)	$Var(Y \mid X)$ proporcional à média ou ao quadrado da média	$\log(Y)$ ou $\sqrt{Y}$
Curvatura em arco	Relação não linear entre Y e X	X^2 ou $\log(X)$
Assimetria à direita	Distribuição assimétrica positiva	$\log(Y)$

Padrão observado	Possível causa	Transformação sugerida
Efeito forte em valores pequenos de X	Retorno decrescente	$1/X$

Cada transformação responde a um mecanismo estrutural distinto. Não se trata de “corrigir o gráfico”, mas de modelar melhor o processo subjacente.

Etapa 3 — Ajuste do modelo transformado

Após escolher a transformação, ajusta-se o novo modelo, por exemplo:

$$\log(Y_i) = \beta_0^* + \beta_1^* X_i + \varepsilon_i,$$

ou

$$Y_i = \beta_0 + \beta_1 \log(X_i) + \varepsilon_i.$$

Nesse momento, todo o ciclo de verificação deve ser repetido:

- análise gráfica dos resíduos;
- testes formais (quando apropriado);
- avaliação da coerência interpretativa.

Etapa 4 — Avaliação comparativa

A comparação entre modelos deve considerar:

1. Qualidade dos resíduos (homoscedasticidade, normalidade).
2. Estabilidade dos coeficientes.
3. Interpretação substantiva.
4. Intervalos de confiança e precisão inferencial.

Um modelo com menor R^2 pode ser preferível se satisfaz melhor as hipóteses do MRLS e apresenta resíduos estruturalmente adequados.

9.5 Exemplo ilustrativo: antes e depois da transformação

Para consolidar as ideias discutidas até aqui, apresentamos um exemplo ilustrativo que mostra, de forma integrada, a **necessidade estatística** e a **eficácia inferencial** de uma transformação na variável resposta.

9.5.1 Cenário e especificação dos modelos

Suponha que estejamos interessados em modelar a relação entre **horas de prática de estudo (X)** e a **nota obtida em uma prova (Y)**. Intuitivamente, espera-se que estudantes que dedicam mais horas de estudo tendam a alcançar notas maiores. Contudo, é plausível que:

- o ganho médio de desempenho seja aproximadamente exponencial;
- a variabilidade das notas aumente à medida que X aumenta.

Essa estrutura implica que a variância condicional pode depender do nível médio da resposta, violando a hipótese de homoscedasticidade do MRLS.

Consideremos dois modelos concorrentes.

Modelo A (sem transformação):

$$Y_i = \beta_0 + \beta_1 X_i + e_i.$$

Esse modelo assume:

$$E(Y_i | X_i) = \beta_0 + \beta_1 X_i, \quad \text{Var}(Y_i | X_i) = \sigma^2.$$

Modelo B (com transformação logarítmica):

$$Y_i^* = \log(Y_i) = \beta_0^* + \beta_1^* X_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

Nesse caso, assumimos normalidade e homoscedasticidade **na escala logarítmica**. Implicitamente, isso significa que, na escala original,

$$Y_i | X_i \sim \text{LogNormal}(\mu_i, \sigma^2),$$

o que altera a estrutura probabilística do modelo.

9.5.2 Geração do conjunto de dados e análise descritiva

Para ilustrar essa situação, considere que a relação verdadeira é linear na escala logarítmica:

$$\log(Y_i) = 1.0 + 0.20X_i + u_i, \quad u_i \sim N(0, \sigma^2).$$

A partir dessa equação, obtemos

$$Y_i = \exp(1.0 + 0.20X_i + u_i),$$

o que gera:

- crescimento exponencial na média;
- variância crescente com X ;
- assimetria à direita na escala original.

```
library(dplyr)
set.seed(2025)

n <- 120
X <- seq(0, 10, length.out = n)

# Relação linear na escala log(Y)
sigma <- 0.6
logY <- 1.0 + 0.20*X + rnorm(n, 0, sigma)
Y <- exp(logY)

df <- tibble(
  X = X,
  Y = Y,
  logY = log(Y)
)
```

Estatísticas descritivas

Devem ser apresentadas:

- primeiras linhas da base;

- estatísticas resumidas para X , Y e $\log(Y)$.

```
head(df)
```

```
# A tibble: 6 × 3
      X      Y logY
  <dbl> <dbl> <dbl>
1 0      3.95 1.37
2 0.0840 2.82 1.04
3 0.168 4.47 1.50
4 0.252 6.13 1.81
5 0.336 3.63 1.29
6 0.420 2.68 0.986
```

```
summary(df)
```

X		Y		logY	
Min.	: 0.0	Min.	: 1.141	Min.	: 0.1318
1st Qu.	: 2.5	1st Qu.	: 4.384	1st Qu.	: 1.4779
Median	: 5.0	Median	: 6.833	Median	: 1.9217
Mean	: 5.0	Mean	: 9.724	Mean	: 1.9833
3rd Qu.	: 7.5	3rd Qu.	: 12.803	3rd Qu.	: 2.5497
Max.	: 10.0	Max.	: 40.396	Max.	: 3.6987

Ajuste dos modelos

Ajustamos ambos os modelos via MQO:

- Modelo A: $Y \sim X$
- Modelo B: $\log(Y) \sim X$

Comparar:

- estimativas dos coeficientes;
- erros-padrão;
- R^2 ;
- estatísticas t e F .

Note que os R^2 não são diretamente comparáveis entre escalas distintas, pois medem proporções de variabilidade em espaços diferentes.

```
mA <- lm(Y ~ X, data = df)
mB <- lm(logY ~ X, data = df)

cat("=== MODELO A (Y ~ X) ===\n")
```

```
=== MODELO A (Y ~ X) ===
```

```
print(summary(mA))
```

Call:

```
lm(formula = Y ~ X, data = df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-10.8050	-4.1989	-0.8159	1.8826	24.5691

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.0801	1.2119	1.716	0.0887 .
X	1.5288	0.2095	7.298	3.68e-11 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.68 on 118 degrees of freedom

Multiple R-squared: 0.311, Adjusted R-squared: 0.3052

F-statistic: 53.27 on 1 and 118 DF, p-value: 3.677e-11

```
cat("\n=== MODELO B (logY ~ X) ===\n")
```

```
=== MODELO B (logY ~ X) ===
```

```
print(summary(mB))
```

Call:

```
lm(formula = logY ~ X, data = df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.43792	-0.41121	-0.01437	0.36590	1.62093

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.15379	0.10872	10.612	< 2e-16 ***
X	0.16590	0.01879	8.828	1.16e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5992 on 118 degrees of freedom

Multiple R-squared: 0.3978, Adjusted R-squared: 0.3927

F-statistic: 77.94 on 1 and 118 DF, p-value: 1.164e-14

ANOVA

Apresentar as tabelas ANOVA para ambos os modelos.

```
cat("\n=== ANOVA – MODELO A ===\n")
```

```
=== ANOVA – MODELO A ===
```

```
print(anova(mA))
```

Analysis of Variance Table

```
Response: Y
      Df Sum Sq Mean Sq F value    Pr(>F)
X         1 2376.6  2376.59   53.266 3.677e-11 ***
Residuals 118  5264.9    44.62
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
cat("\n=== ANOVA – MODELO B ===\n")
```

```
=== ANOVA – MODELO B ===
```

```
print(anova(mB))
```

Analysis of Variance Table

```
Response: logY
      Df Sum Sq Mean Sq F value    Pr(>F)
X         1  27.984   27.9837   77.938 1.164e-14 ***
Residuals 118  42.368    0.3591
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

9.5.3 Diagnóstico gráfico: antes e depois

O contraste entre os modelos deve ser avaliado por meio dos gráficos diagnósticos.

```
# Padronização visual para TODOS os gráficos do exemplo
library(ggplot2)
library(dplyr)
library(tidyr)

base_size <- 12

theme_diag <- theme_minimal(base_size = base_size) +
  theme(
    panel.grid.minor = element_blank(),
    panel.grid.major.x = element_blank(),
    strip.text = element_text(face = "bold"),
    strip.background = element_rect(fill = "grey95", color = NA),
    plot.title.position = "plot",
    plot.caption.position = "plot"
  )
```

9.5.3.1 Dispersão da resposta vs. explicativa

- Modelo A: espera-se tendência crescente com dispersão aumentando (funil).
- Modelo B: dispersão aproximadamente constante e relação linear clara na escala transformada.


```
df_plot <- df %>%
  select(X, Y, logY) %>%
  pivot_longer(cols = c(Y, logY), names_to = "resp", values_to = "valor") %>%
  mutate(
    resp = ifelse(resp == "Y",
```

```

    "Modelo A: escala original (Y)",
    "Modelo B: escala log (log(Y))"
  )

ggplot(df_plot, aes(x = X, y = valor)) +
  geom_point(alpha = 0.8, size = 2) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 0.9) +
  facet_wrap(~resp, ncol = 2, scales = "free_y") +
  labs(
    x = "Horas de estudo (X)",
    y = NULL
  ) +
  theme_diag

```



9.5.3.2 Resíduos vs. valores ajustados

- Modelo A: padrão de funil e possível curvatura.
- Modelo B: resíduos aleatórios em torno de zero.

A ausência de estrutura no segundo caso indica que

$$\text{Var}(\varepsilon_i | X_i) \approx \sigma^2.$$

```


resA <- resid(mA); fitA <- fitted(mA)
resB <- resid(mB); fitB <- fitted(mB)

dados <- bind_rows(
  tibble(fit = fitA, res = resA, painel = "Modelo A: escala original (Y)"),
  tibble(fit = fitB, res = resB, painel = "Modelo B: escala log (log(Y))")
)

ggplot(dados, aes(x = fit, y = res)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~painel, ncol = 2, scales = "free_x") +

```

```
labs(
  x = "Valores ajustados",
  y = "Resíduo"
) +
theme_diag
```




9.5.3.3 Resíduos estudentizados vs. ajustados

- Modelo A: maior número de pontos fora do intervalo $[-2, 2]$.
- Modelo B: poucos pontos extremos, ausência de padrão.

```
studA <- rstudent(mA)
studB <- rstudent(mB)

dados <- bind_rows(
  tibble(fit = fitA, stud = studA, painel = "Modelo A: escala original (Y)"),
  tibble(fit = fitB, stud = studB, painel = "Modelo B: escala log (log(Y))")
)

ggplot(dados, aes(x = fit, y = stud)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  geom_hline(yintercept = c(-2, 2), linetype = "dotted", linewidth = 0.7) +
  facet_wrap(~painel, ncol = 2, scales = "free_x") +
  labs(
    x = "Valores ajustados",
    y = "Resíduo estudentizado (t*)"
  ) +
  theme_diag
```



9.5.3.4 QQ-plot

- Modelo A: desvios sistemáticos nas caudas.
- Modelo B: alinhamento próximo à reta de 45°.

Isso sugere que


$$\varepsilon_i \sim N(0, \sigma^2)$$

é plausível apenas na escala logarítmica.

```
qq_df <- function(r, painel){
  q <- qqnorm(r, plot.it = FALSE)
  tibble(theo = q$x, samp = q$y, painel = painel)
}

dados <- bind_rows(
  qq_df(resA, "Modelo A: QQ-plot dos resíduos (Y)"),
  qq_df(resB, "Modelo B: QQ-plot dos resíduos (log(Y))")
)

ggplot(dados, aes(x = theo, y = samp)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_abline(intercept = 0, slope = 1, linewidth = 0.7) +
  facet_wrap(~painel, ncol = 2, scales = "free") +
  labs(
    x = "Quantis teóricos (Normal)",
    y = "Quantis amostrais (resíduos)"
  ) +
  theme_diag
```




9.5.3.5 Histograma

- Modelo A: assimetria à direita e caudas pesadas.
- Modelo B: simetria aproximadamente normal.

```
dados <- bind_rows(
  tibble(r = resA, painel = "Modelo A: resíduos (Y)"),
  tibble(r = resB, painel = "Modelo B: resíduos (log(Y))")
)

ggplot(dados, aes(x = r)) +
  geom_histogram(aes(y = after_stat(density)),
    bins = 14,
    alpha = 0.7,
    color = "white") +
  geom_vline(xintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~painel, ncol = 2, scales = "free") +
  labs(
    x = "Resíduo",
    y = "Densidade"
  ) +
  theme_diag
```




9.5.3.6 Resíduos vs. X

- Modelo A: indícios de curvatura e variância crescente.
- Modelo B: dispersão uniforme.

```
dados <- bind_rows(
  tibble(X = df$X, res = resA, painel = "Modelo A: resíduos vs X (Y)"),
  tibble(X = df$X, res = resB, painel = "Modelo B: resíduos vs X (log(Y))")
)

ggplot(dados, aes(x = X, y = res)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~painel, ncol = 2, scales = "free_y") +
  labs(
    x = "Horas de estudo (X)",
    y = "Resíduo"
  ) +
  theme_diag
```



9.5.4 Comparação numérica e conclusão

Modelo A (escala original)

- R^2 aparentemente satisfatório.
- Violação da homoscedasticidade.
- Desvios de normalidade.
- Inferência potencialmente comprometida.

Modelo B (escala logarítmica)

- Melhor adequação estrutural dos resíduos.
- Testes t e F mais confiáveis.
- Intervalos de confiança coerentes com as hipóteses do modelo.

Um modelo pode apresentar bom R^2 e, ainda assim, violar hipóteses fundamentais. A validade da inferência depende da adequação dos resíduos, não apenas do poder explicativo.

9.5.4.1 Interpretação

No Modelo B,

$$\log(Y) = \beta_0^* + \beta_1^* X.$$

Logo,

$$Y = \exp(\beta_0^*) \exp(\beta_1^* X).$$

O efeito de X é **multiplicativo**:

$$\exp(\beta_1^*)$$

representa o fator pelo qual Y é multiplicado para cada unidade adicional em X .

Entretanto, para previsões na escala original,

$$E(Y | X) = \exp\left(\mu + \frac{1}{2}\sigma^2\right),$$

e não simplesmente $\exp(\mu)$ (Casella; Berger, 2002). Ignorar esse termo introduz **viés de retransformação**

Este exemplo evidencia que:

- a análise de resíduos é central na validação do modelo;
- transformações podem corrigir violações estruturais;
- a interpretação deve sempre respeitar a escala do modelo ajustado;
- a escolha da transformação deve ser guiada por diagnóstico e fundamentação teórica.

Em regressão, a forma funcional adequada é aquela que torna os resíduos compatíveis com as hipóteses do modelo — não necessariamente aquela que produz o maior R^2 .