

10 Comparação de Modelos

10.1 Motivação e princípios de comparação

Após discutir a análise de resíduos, surge uma questão natural: **como escolher entre diferentes modelos candidatos?** Nem sempre um único modelo é suficiente; muitas vezes ajustamos **várias alternativas** e precisamos compará-las.

A comparação de modelos, porém, não é um “campeonato de métricas”. Ela deve ser entendida como uma decisão estatística guiada por três ideias centrais: **adequação**, **parcimônia** e **finalidade** (explicar vs prever). Em particular, comparar modelos significa avaliar **trocias (trade-offs)**: um modelo pode ajustar melhor os dados, mas à custa de maior complexidade e menor estabilidade, especialmente em amostras moderadas/pequenas.

A comparação de modelos envolve duas dimensões principais:

1. **Qualidade estatística do ajuste** – medida por critérios formais (ex.: R^2 , teste F , AIC, BIC).
2. **Pertinência substantiva** – se o modelo faz sentido em relação ao fenômeno estudado, é parcimonioso e interpretável.

Em regressão, “modelo melhor” **não significa** “modelo com o maior ajuste numérico”. O ponto é: um modelo é um **compromisso** entre (i) representar a estrutura sistemática de Y explicada por X e (ii) não incorporar estrutura espúria (ruído) como se fosse sinal. Critérios como AIC e BIC foram propostos justamente para explicitar essa troca: melhorar o ajuste (via log-verossimilhança) **custa** complexidade (número de parâmetros), e essa penalização é uma maneira de desencorajar sobreajuste (Akaike, 1974; Burnham; Anderson, 2002; Schwarz, 1978).

Um ponto central é que **não adianta comparar dois modelos se ambos têm resíduos inadequados**. O primeiro filtro deve ser sempre o diagnóstico dos resíduos. Uma vez que os modelos estejam pelo menos aproximadamente bem especificados, podemos partir para critérios comparativos.

Essa ordem (“diagnóstico → comparação”) é importante porque muitos critérios formais assumem que o modelo está **minimamente compatível** com as hipóteses estruturais do MRLS (por exemplo: relação média aproximadamente linear na escala adotada, variância aproximadamente constante e ausência de padrões sistemáticos evidentes nos resíduos). Se essas condições falham, é comum observar situações enganosas como:

- um modelo com R^2 alto, mas com **padrão em funil** (heteroscedasticidade), o que compromete inferência usual e previsões com incerteza mal calibrada;
- um modelo com ligeira melhora em AIC/BIC após adicionar termos, mas com **curvatura residual persistente**, sinalizando que a forma funcional ainda está incorreta;
- um modelo “mais complexo” que parece melhor no ajuste dentro da amostra, mas piora a capacidade de generalização (sobreajuste).

10.1.1 Finalidade da comparação: explicar ou prever

Antes de escolher um critério, é útil explicitar o objetivo:

- **Explicação/interpretação**: prioriza parâmetros estáveis e interpretáveis e tende a valorizar parcimônia (frequentemente BIC é usado como referência em seleção mais “conservadora”).
- **Predição**: prioriza desempenho fora da amostra; critérios baseados em verossimilhança com penalização moderada (como AIC) são frequentemente usados como aproximações de desempenho preditivo, mas

idealmente devem ser complementados por validação (ex.: validação cruzada) quando isso fizer parte do desenho analítico (Burnham; Anderson, 2002).

Nesta seção, organizamos os principais critérios formais e práticos de comparação, seguidos de exemplos ilustrativos.

10.2 Critérios clássicos de comparação

10.2.1 Coeficiente de determinação R^2

O R^2 mede a proporção da variabilidade de Y explicada pelo modelo:

$$R^2 = 1 - \frac{SQ_{Res}}{SQ_{Tot}},$$

em que $SQ_{Res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ é a soma de quadrados dos resíduos e $SQ_{Tot} = \sum_{i=1}^n (Y_i - \bar{Y})^2$ é a soma de quadrados total.

O R^2 responde à pergunta: “quanto da variabilidade total observada em Y foi capturada pelo componente sistemático do modelo?”. Ele é, portanto, uma medida **descritiva de ajuste**: compara o erro do modelo com o erro de um “modelo nulo” que sempre prediz $\bar{Y}$.

Como a decomposição

$$SQ_{Tot} = SQ_{Reg} + SQ_{Res}$$

vale no MRLS com intercepto, também podemos escrever

$$R^2 = \frac{SQ_{Reg}}{SQ_{Tot}},$$

isto é, a fração da variabilidade total explicada pela regressão.

10.2.1.1 Propriedades e limitações

É tentador ler R^2 como “o modelo é bom/ruim”, mas isso é perigoso por três razões:

1. R^2 não diagnostica adequação das hipóteses: um modelo pode ter R^2 alto e ainda assim apresentar resíduos com curvatura, heteroscedasticidade ou dependência. Por isso, o diagnóstico de resíduos vem antes.
2. R^2 não mede capacidade preditiva fora da amostra: ele é calculado na amostra usada no ajuste.
3. R^2 depende da variabilidade de Y : em bases com pouca variação em Y , mesmo modelos úteis podem ter R^2 modestos; e em bases com grande variação em Y , R^2 pode ser alto sem que o modelo seja substantivamente satisfatório.

Vantagens e limitações

- **Vantagem:** fornece uma medida intuitiva de ajuste.
- **Limitação 1 (monotonicidade):** em modelos de MQO com intercepto, R^2 **nunca diminui** quando adicionamos regressores ao conjunto de candidatos. Isso ocorre porque, ao adicionar parâmetros, o MQO minimiza SQ_{Res} em um espaço maior, logo SQ_{Res} só pode diminuir (ou permanecer igual).
- **Limitação 2 (comparabilidade):** R^2 **não é comparável** entre modelos com e sem intercepto, pois a decomposição de somas de quadrados muda. Em particular, quando o intercepto é omitido, o “modelo nulo” implícito deixa de ser $Y = \bar{Y}$, e interpretações usuais de R^2 podem se tornar enganosas.

- **Limitação 3 (escala da resposta):** se você transforma Y (por exemplo, $\log(Y)$), o R^2 passa a descrever ajuste **na escala transformada**, não na escala original.

Observação: no MRLS (com intercepto), vale a relação $R^2 = r_{XY}^2$, conectando a medida de ajuste com a intensidade de associação linear entre X e Y .

10.2.2 Coeficiente de determinação ajustado R_{aj}^2

Para penalizar modelos excessivamente complexos, define-se:

$$R_{aj}^2 = 1 - \frac{SQ_{Res}/(n-p)}{SQ_{Tot}/(n-1)},$$

em que n é o tamanho da amostra e p é o número de parâmetros (incluindo o intercepto).

O R_{aj}^2 substitui “proporção de variância explicada” por uma comparação entre **variâncias estimadas**:

- $SQ_{Res}/(n-p)$ é o estimador de σ^2 (variância do erro) sob o modelo candidato;
- $SQ_{Tot}/(n-1)$ é a variância amostral de Y .

Assim, R_{aj}^2 pergunta: “**o quanto a variância residual estimada caiu em relação à variância total de Y** , levando em conta quantos parâmetros eu usei para isso?”

Ao contrário do R^2 , o R_{aj}^2 **pode diminuir** quando adicionamos regressoras. Isso é desejável: se um novo termo reduz pouco o SQ_{Res} , a penalização por perder graus de liberdade pode dominar, sinalizando que o ganho de ajuste não compensa a complexidade.

10.2.2.1 Vantagens e limitações

- **Vantagem:** permite comparar modelos com diferentes números de parâmetros, desde que estejam na mesma escala da resposta e com intercepto.
- **Limitação:** em amostras pequenas, ainda pode favorecer modelos com leve sobreajuste, pois sua penalização é relativamente moderada.
- **Uso prático:** quando a comparação envolve modelos com diferentes estruturas, R_{aj}^2 é preferível ao R^2 simples.

10.2.3 Teste F para modelos aninhados

Quando um modelo é **caso particular de outro** (modelo restrito vs. modelo completo), podemos usar:

$$F = \frac{(SQ_{Res, restrito} - SQ_{Res, completo})/q}{SQ_{Res, completo}/(n-p)},$$

em que:

- q é o número de restrições impostas (equivalentemente, o número de parâmetros “removidos” quando passamos do completo para o restrito);
- p é o número de parâmetros no modelo completo (incluindo intercepto).

O teste F para modelos aninhados avalia se a redução em SQ_{Res} ao passarmos do modelo restrito para o completo é **grande o suficiente** para justificar os parâmetros adicionais.

- No numerador está o “ganho médio” de ajuste por restrição relaxada: $(SQ_{Res, restrito} - SQ_{Res, completo})/q$.

- No denominador está uma estimativa de σ^2 no modelo completo: $SQ_{Res, completo} / (n - p)$.

Se o ganho médio (numerador) é grande comparado ao ruído residual esperado (denominador), a estatística F fica grande e rejeitamos o modelo restrito.

10.2.3.1 Hipóteses e decisão

- **Hipóteses:**
 - H_0 : as restrições são válidas (o modelo mais simples é suficiente).
 - H_1 : pelo menos uma restrição é falsa (o modelo completo melhora o ajuste de forma relevante).
- **Regra:** rejeitar H_0 para valores grandes de F (ou valor-p pequeno).
- **Uso:** útil para verificar se a inclusão de um termo (ou intercepto) melhora de forma estatisticamente significativa o ajuste.
- **Limitação:** só se aplica a modelos **aninhados** (isto é, quando o modelo restrito pode ser obtido impondo restrições lineares nos parâmetros do modelo completo).

Adicionalmente, mesmo quando o teste F rejeita H_0 , ainda é necessário verificar:

- se o termo adicional tem interpretação substantiva coerente;
- se a inclusão introduz instabilidade (por exemplo, poucos dados sustentando um termo);
- se o ganho é relevante na prática (e não apenas detectável por tamanho amostral).

10.3 Critérios de informação

Além dos critérios clássicos, que se baseiam em soma de quadrados e variâncias, temos medidas que incorporam explicitamente a ideia de **verossimilhança e parcimônia**. Esses critérios nascem de uma perspectiva mais geral de modelagem estatística, na qual o modelo é visto como uma aproximação para a distribuição geradora dos dados.

No contexto do MRLS com erros normais,

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2),$$

a estimação por MQO coincide com a estimação por **máxima verossimilhança**. Assim, podemos usar a log-verossimilhança avaliada nos estimadores para comparar modelos.

10.3.1 Critério de Informação de Akaike (AIC)

$$AIC = -2\ell(\hat{\theta}) + 2p,$$

em que:

- $\ell(\hat{\theta})$ é a log-verossimilhança no ponto estimado;
- p é o número de parâmetros estimados (incluindo σ^2 , quando apropriado).

O AIC pode ser interpretado como uma aproximação para a **distância de Kullback–Leibler** entre o modelo candidato e o verdadeiro mecanismo gerador dos dados (Akaike, 1974; Burnham; Anderson, 2002). Ele busca selecionar o modelo que, entre os candidatos, minimiza a perda de informação esperada.

A estrutura do critério explicita o compromisso:

- $-2\ell(\hat{\theta})$ recompensa melhor ajuste (maior verossimilhança);
- $2p$ penaliza complexidade.

Assim, modelos com mais parâmetros precisam “ganhar” log-verossimilhança suficiente para compensar a penalização.

Interpretação prática

- **Regra:** entre modelos comparáveis, preferir o de **menor AIC**.
- O AIC não tem interpretação absoluta; só faz sentido **comparativamente**.
- Diferenças pequenas (por exemplo, menores que 2 unidades) geralmente indicam que os modelos têm suporte semelhante nos dados (Burnham; Anderson, 2002).

O AIC não testa hipóteses do tipo H_0 vs. H_1 . Ele não produz valor-p nem decisão “rejeita/não rejeita”. É um critério de **seleção por informação**, não um teste clássico de significância.

Além disso, o AIC tende a favorecer modelos levemente mais complexos, especialmente em amostras pequenas. Em contextos de amostras reduzidas, versões corrigidas (como AICc) podem ser mais adequadas (Burnham; Anderson, 2002).

10.3.2 Critério Bayesiano de Schwarz (BIC)

$$BIC = -2\ell(\hat{\theta}) + p \log(n).$$

O BIC possui forma semelhante ao AIC, mas a penalização cresce com $\log(n)$. Assim:

- Para amostras grandes, $\log(n)$ pode ser bem maior que 2;
- A penalização por parâmetro torna-se mais severa à medida que n aumenta.

O BIC pode ser interpretado como uma aproximação ao **log do fator de Bayes** sob certas condições assintóticas (Schwarz, 1978). Por isso, ele é frequentemente associado a uma perspectiva de **seleção do modelo “verdadeiro”** dentro do conjunto candidato.

Interpretação prática

- **Regra:** entre modelos comparáveis, preferir o de **menor BIC**.
- O BIC tende a ser mais conservador que o AIC.
- Em amostras grandes, pode penalizar fortemente modelos com muitos parâmetros.

10.3.3 Boas práticas e comparabilidade entre escalas

AIC vs. BIC: qual usar?

- **AIC:** mais orientado à predição e desempenho fora da amostra.
- **BIC:** mais orientado à identificação de uma estrutura “mais plausível” dentro do conjunto de candidatos.
- Compare apenas modelos ajustados na **mesma escala** da variável resposta.

A escolha depende do objetivo da análise. Em contextos aplicados, é comum reportar ambos e discutir a coerência entre eles.

Nota importante sobre AIC e BIC:

Embora possamos calcular AIC e BIC para qualquer modelo ajustado, **não é correto comparar diretamente** os valores de um modelo ajustado em Y com outro ajustado em $\log(Y)$, por exemplo.

Isso acontece porque a transformação da resposta altera a escala e a própria função de verossimilhança usada no cálculo dos critérios. Assim, os valores de AIC/BIC ficam em “bases diferentes”.

Como proceder então?

- Compare AIC/BIC apenas entre modelos ajustados **na mesma escala da resposta**.
- Use análise de resíduos e diagnóstico gráfico para avaliar se a transformação foi benéfica.
- Para fins de **predição**, utilize métricas de erro calculadas na escala original de Y (ex.: RMSE, MAE) para decidir qual modelo é mais adequado.

Em síntese: AIC e BIC são ferramentas valiosas, mas devem ser usados com critério. Transformações em Y exigem avaliação adicional baseada em resíduos e desempenho preditivo.

10.3.4 Estratégia prática de comparação

Ao comparar modelos alternativos:

1. **Primeiro passo:** verifique os **resíduos** (condição mínima).
 - Se um modelo viola homocedasticidade ou apresenta estrutura sistemática, mesmo que tenha R^2 alto, não deve ser preferido.
2. **Segundo passo:** use os **critérios formais**.
 - Teste F quando os modelos são aninhados.
 - R^2_{aj} quando a comparação é dentro da mesma escala.
 - AIC/BIC para comparações amplas (mesma resposta, diferentes ajustes).
3. **Terceiro passo:** considere a **interpretação substantiva**.
 - Um modelo matematicamente melhor pode ser substantivamente inadequado.

10.4 Exemplos ilustrativos de comparação de modelos

Para consolidar as ideias, apresentamos dois exemplos didáticos que demonstram como comparar modelos no contexto do **MRLS**. Cada exemplo explora um tipo de decisão prática enfrentada por analistas de dados.

10.4.1 Exemplo 1 — Intercepto e transformação na resposta

Simulação do Exemplo 1: gerar `df1` com as variáveis `X` e `Y` (com $Y > 0$, para permitir $\log(Y)$).

```
library(dplyr)

set.seed(2025)

# Simulação: consumo (Y) vs tempo de funcionamento (X)
n <- 50
X <- seq(0, 10, length.out = n)

# Consumo com intercepto > 0 (stand-by) e heterocedasticidade moderada
mu <- 5 + 1.2*X
sigma <- 0.6 + 0.05*X
Y <- mu + rnorm(n, 0, sigma)
Y <- pmax(Y, 0.1) # garantir Y>0 (para log)

df1 <- tibble(X = X, Y = Y)
```

- i. **Cenário e modelos candidatos:** consumo de energia (Y) em função do tempo de funcionamento (X), com $n = 50$ observações.

Modelos candidatos:

1. Com intercepto

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Representa consumo mínimo (stand-by). Esperado em contextos onde $Y > 0$ mesmo quando $X = 0$.

2. Sem intercepto

$$Y = \beta_1 X + \varepsilon$$

Força a reta a passar pela origem. Só faz sentido se sabemos que $Y = 0$ quando $X = 0$.

3. Transformado (log da resposta)

$$\log Y = \beta_0 + \beta_1 X + \varepsilon$$

Nesta configuração com variável transformada, o coeficiente β_1 indica a mudança **aditiva em $\log(Y)$** a cada unidade adicional em X . Na escala original de Y , isso equivale a dizer que um aumento de 1 unidade em X está associado a uma multiplicação esperada de Y por $\exp(\beta_1)$.

Aqui estamos comparando três “ideias de modelo” que, apesar de parecidas na forma, respondem a perguntas ligeiramente diferentes:

- **Modelo A (com intercepto)** permite que exista um nível médio de consumo quando $X = 0$ (consumo residual/stand-by).
- **Modelo A0 (sem intercepto)** declara, como hipótese estrutural, que “se $X = 0$, então $Y = 0$ ”. Essa é uma afirmação forte: se ela for falsa, o ajuste pode “compensar” deslocando a inclinação e gerando resíduos estruturados.
- **Modelo B (com $\log Y$)** muda a escala da resposta e, portanto, muda o tipo de erro “natural” no modelo (efeitos multiplicativos no Y original tendem a virar efeitos aditivos em $\log(Y)$).

Visualização da primeiras linhas da Base de dados

```
head(df1)
```

```
# A tibble: 6 × 2
      X      Y
<dbl> <dbl>
1 0      5.37
2 0.204  5.27
3 0.408  5.97
4 0.612  6.54
5 0.816  6.22
6 1.02   6.12
```

i. Estimação e resumos dos modelos

Ajustes e tabela de coeficientes: ajustar `mod_A`, `mod_A0` e `mod_log`.

```
# Ajustes
mod_A    <- lm(Y ~ X, data = df1)      # com intercepto
mod_A0   <- lm(Y ~ 0 + X, data = df1)  # sem intercepto
mod_log  <- lm(log(Y) ~ X, data = df1) # resposta em log

cat("Modelo com intercepto (A):\n")
```

Modelo com intercepto (A):

```
print(coef(summary(mod_A)))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.137603	0.24760614	20.74909	1.297563e-25
X	1.196581	0.04266949	28.04301	2.032694e-31

```
cat("\nModelo sem intercepto (A0):\n")
```

Modelo sem intercepto (A0):

```
print(coef(summary(mod_A0)))
```

	Estimate	Std. Error	t value	Pr(> t)
X	1.959437	0.06767437	28.9539	1.770922e-32

```
cat("\nModelo com log(Y) (B):\n")
```

Modelo com log(Y) (B):

```
print(coef(summary(mod_log)))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.7791870	0.025029186	71.08450	2.673492e-50
X	0.1143677	0.004313232	26.51554	2.548074e-30

Comentários:

- O **Modelo A (com intercepto)** mostra um termo constante significativo, representando consumo em stand-by ($Y > 0$ em $x \approx 0$).
- O **Modelo A0 (sem intercepto)** ignora o consumo em stand-by e força a reta a passar pela origem.
- O **Modelo B (log da resposta)** reduz heteroscedasticidade: os coeficientes mantêm significância e a interpretação passa a ser na escala da variável transformada.

Teste de resíduos (omnibus, Jarque-Bera, skew, kurtosis, Durbin-Watson, etc.)

```
# Testes/medidas adicionais dos resíduos
library(lmtest) # dwtest
library(tseries) # jarque.bera.test
library(moments) # skewness, kurtosis

res_tests <- function(mod, nome){
  e <- resid(mod)

  jb <- jarque.bera.test(e)
  sk <- skewness(e)
  ku <- kurtosis(e) # kurtosis "crua" (Normal ~ 3)

  # Durbin-Watson (lmtest)
  dw <- dwtest(mod)
```



```

# Omnibus D'Agostino-Pearson (quando disponível via fBasics::dagoTest)
omni_out <- NULL
if (requireNamespace("fBasics", quietly = TRUE)) {
  omni_out <- fBasics::dagoTest(e)
}

cat("\n=====\\n")
cat("Testes dos resíduos –", nome, "\\n")
cat("=====\\n")

cat("Jarque-Bera:\\n")
print(jb)

cat("\\nAssimetria (skewness): ", round(sk, 4), "\\n", sep = "")
cat("Curtose (kurtosis):  ", round(ku, 4), " (Normal ~ 3)\\n", sep = "")

cat("\\nDurbin-Watson (lmtest::dwtest):\\n")
print(dw)

if (!is.null(omni_out)) {
  cat("\\nOmnibus (D'Agostino-Pearson) – fBasics::dagoTest:\\n")
  print(omni_out)
} else {
  cat("\\nOmnibus (D'Agostino-Pearson):\\n")
  cat("Pacote 'fBasics' não disponível no ambiente. (Opcional: instalar para executar o o
}

res_tests(mod_A,  "Modelo A (Y ~ X, com intercepto)")

```

```

=====
Testes dos resíduos – Modelo A (Y ~ X, com intercepto)
=====

```

Jarque-Bera:

Jarque Bera Test

data: e

X-squared = 0.39891, df = 2, p-value = 0.8192

Assimetria (skewness): 0.1998

Curtose (kurtosis): 2.8216 (Normal ~ 3)

Durbin-Watson (lmtest::dwtest):

Durbin-Watson test

data: mod

DW = 2.165, p-value = 0.6695

alternative hypothesis: true autocorrelation is greater than 0

Omnibus (D'Agostino-Pearson) – fBasics::dagoTest:

Title:
D'Agostino Normality Test

Test Results:

STATISTIC:

Chi2 | Omnibus: 0.4194

Z3 | Skewness: 0.6388

Z4 | Kurtosis: 0.1065

P VALUE:

Omnibus Test: 0.8108

Skewness Test: 0.523

Kurtosis Test: 0.9152

```
res_tests(mod_A0, "Modelo A0 (Y ~ X, sem intercepto)")
```

=====

Testes dos resíduos – Modelo A0 (Y ~ X, sem intercepto)

=====

Jarque-Bera:

Jarque Bera Test

data: e

X-squared = 2.6548, df = 2, p-value = 0.2652

Assimetria (skewness): -0.0498

Curtose (kurtosis): 1.8755 (Normal ~ 3)

Durbin-Watson (lmtest::dwtest):

Durbin-Watson test

data: mod

DW = 0.22013, p-value < 2.2e-16

alternative hypothesis: true autocorrelation is greater than 0

Omnibus (D'Agostino-Pearson) – fBasics::dagoTest:

Title:

D'Agostino Normality Test

Test Results:

STATISTIC:

Chi2 | Omnibus: 8.7587

Z3 | Skewness: -0.1602

Z4 | Kurtosis: -2.9552

P VALUE:

Omnibus Test: 0.01253

Skewness Test: 0.8728

Kurtosis Test: 0.003125

```
res_tests(mod_log, "Modelo B (log(Y) ~ X)")
```

=====

Testes dos resíduos – Modelo B ($\log(Y) \sim X$)

=====

Jarque-Bera:

Jarque Bera Test

data: e

X-squared = 3.1899, df = 2, p-value = 0.2029

Assimetria (skewness): 0.5779

Curtose (kurtosis): 3.4418 (Normal ~ 3)

Durbin-Watson (lmtest::dwtest):

Durbin-Watson test

data: mod

DW = 1.5831, p-value = 0.04934

alternative hypothesis: true autocorrelation is greater than 0

Omnibus (D'Agostino-Pearson) – fBasics::dagoTest:

Title:

D'Agostino Normality Test

Test Results:

STATISTIC:

Chi2 | Omnibus: 4.236

Z3 | Skewness: 1.7691

Z4 | Kurtosis: 1.0518

P VALUE:

Omnibus Test: 0.1203

Skewness Test: 0.07688

Kurtosis Test: 0.2929

Comentários:

• Modelo A (com intercepto):

- O teste Omnibus e o Jarque-Bera não são significativos (valores-p altos), sugerindo que os resíduos não violam fortemente a normalidade.
- O Durbin-Watson próximo de 2 indica ausência de autocorrelação serial.
- Conclusão: resíduos adequados, modelo consistente.

• Modelo A0 (sem intercepto):

- O Durbin-Watson é muito baixo ($\approx 0,2$), indicando forte autocorrelação positiva dos resíduos.
- Embora Omnibus/Jarque-Bera não rejeitem a normalidade, a dependência serial torna o modelo problemático.
- Conclusão: estatisticamente inadequado, reforçando que a exclusão do intercepto distorce o ajuste.

• Modelo B (log da resposta):

- Testes de normalidade (Omnibus, JB) continuam não significativos, mas a assimetria (Skew negativo) sugere leve desvio.
- O Durbin-Watson $\approx 1,4$ aponta alguma autocorrelação positiva.

- o Conclusão: apesar das pequenas imperfeições, o modelo log-transformado melhora a homocedasticidade em relação ao Modelo A.

Em dados simulados sem mecanismo temporal explícito, autocorrelação forte geralmente é um **sinal de especificação inadequada** (por exemplo, restrições erradas como $\beta_0 = 0$ podem “organizar” os resíduos e induzir padrões). Em aplicações reais, autocorrelação também pode ocorrer por dependência temporal genuína; nesse caso, o MRLS pode precisar ser estendido (tema para capítulos posteriores).

iii. Modelos aninhados: teste F (A0 vs A)

```
# Teste F (modelos aninhados): A0 (restrito) vs A (com intercepto)
cat("ANOVA (Teste F: A0 vs A):\n")
```

ANOVA (Teste F: A0 vs A):

```
print(anova(mod_A0, mod_A))
```

Analysis of Variance Table

Model 1: Y ~ 0 + X

Model 2: Y ~ X

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	49	377.84				
2	48	37.90	1	339.94	430.52	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

O modelo sem intercepto (A0) é um **caso particular** do modelo com intercepto (A), obtido ao impor a restrição $\beta_0 = 0$. Logo, o teste F avalia se “forçar a origem” piora o ajuste além do esperado por acaso.

Comentários:

- O teste F compara os modelos **A0 (restrito)** e **A (com intercepto)**.
- O resultado altamente significativo (valor-p próximo de zero) indica que o **intercepto é necessário**.
- Assim, rejeitamos o modelo sem intercepto e preferimos o modelo com intercepto.

iv. Comparação numérica (R^2 , R^2_{aj} , AIC, BIC)

```
library(tidyverse)

cmp1 <- tibble(
  Modelo = c("A: Y~X (c/ intercepto)", "A0: Y~X (sem intercepto)",
             "B: log(Y)~X"),
  R2      = c(summary(mod_A)$r.squared,      summary(mod_A0)$r.squared,
             summary(mod_log)$r.squared),
  R2_adj  = c(summary(mod_A)$adj.r.squared, summary(mod_A0)$adj.r.squared,
             summary(mod_log)$adj.r.squared),
  AIC     = c(AIC(mod_A), AIC(mod_A0), AIC(mod_log)),
  BIC     = c(BIC(mod_A), BIC(mod_A0), BIC(mod_log))
)

cmp1
```

```
# A tibble: 3 × 5
  Modelo          R2 R2_adj  AIC    BIC
  <chr>          <dbl> <dbl> <dbl> <dbl>
1 A: Y~X (c/ intercepto)  0.942 0.941 134.  140.
2 A0: Y~X (sem intercepto) 0.945 0.944 247.  251.
3 B: log(Y)~X          0.936 0.935 -95.1 -89.4
```

Lembre-se que um R^2 elevado pode coexistir com **resíduos ruins**. Isso acontece porque R^2 mede “quanto o modelo explica” em termos de variabilidade total, mas não garante que as hipóteses do MRLS estejam razoavelmente satisfeitas. Em particular, um modelo pode ter alto R^2 e ainda assim produzir inferências pouco confiáveis (erros-padrão distorcidos).

Comentários:

- O **Modelo A0** apresenta R^2 elevado, mas penalizações via AIC/BIC mostram que é muito inferior (valores bem maiores). Logo, acredita-se que os coeficientes ficaram distorcidos, superestimando a inclinação.
- O **Modelo A** combina bom ajuste (R^2_{aj} alto) e parcimônia.
- O **Modelo B (log)** apresenta os menores valores de AIC/BIC.

v. Diagnóstico gráfico comparativo


Dispersões com retas ajustadas dos dois modelos restantes

```
suppressPackageStartupMessages({
  library(ggplot2)
  library(dplyr)
  library(tidyr)
})

dfA <- df1 %>% mutate(valor = Y,          modelo = "A: Y ~ X (c/ intercepto)")
dfA0 <- df1 %>% mutate(valor = Y,          modelo = "A0: Y ~ X (sem intercepto)")
dfB <- df1 %>% mutate(valor = log(Y),      modelo = "B: log(Y) ~ X")

df_plot <- bind_rows(dfA, dfA0, dfB)

ggplot(df_plot, aes(x = X, y = valor)) +
  geom_point(alpha = 0.9, size = 2) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 1) +
  facet_wrap(~modelo, ncol = 3, scales = "free_y") +
  labs(x = "X", y = NULL) +
  theme_minimal(base_size = 12)
```



Exemplo 1 — Dispersão com reta OLS: Modelo A ($Y \sim X$, com intercepto), Modelo A0 ($Y \sim X$, sem intercepto) e Modelo B ($\log(Y) \sim X$).

Comentários:


- Em ambos os **Modelos (A e B)**, não observa-se aumento relevante da variabilidade de Y conforme X cresce.

Resíduos vs. valores ajustados

```
library(ggplot2)
library(dplyr)

dados <- bind_rows(
  tibble(fit = fitted(mod_A), res = resid(mod_A), modelo = "A: Y ~ X (c/ intercepto)"),
  tibble(fit = fitted(mod_A0), res = resid(mod_A0), modelo = "A0: Y ~ X (sem intercepto)"),
  tibble(fit = fitted(mod_log), res = resid(mod_log), modelo = "B: log(Y) ~ X")
)

ggplot(dados, aes(x = fit, y = res)) +
  geom_point(alpha = 0.9, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~modelo, ncol = 3, scales = "free_x") +
  labs(x = "Ajustados", y = "Resíduo") +
  theme_minimal(base_size = 12)
```



Exemplo 1 — Resíduos vs Ajustados: comparação entre A, A0 e B.

Comentário:

Neste gráfico, buscamos uma nuvem aproximadamente aleatória em torno de 0. Três estruturas são especialmente informativas:

- **Funil** (dispersão aumentando/diminuindo com o nível ajustado): sinal de **heteroscedasticidade**.
- **Curvatura** (padrão em arco): sinal de **forma funcional inadequada** (não linearidade não capturada).
- **Faixas** (bandas horizontais): podem surgir por discretização/limitação de medida em $\hat{Y}$.


Na comparação entre modelos, o melhor candidato é o que *reduz* essas estruturas, sem criar novas.

Resíduos estudentizados vs. valores ajustados

```
library(ggplot2)
library(dplyr)

dados <- bind_rows(
  tibble(fit = fitted(mod_A), stud = rstudent(mod_A), modelo = "A: Y ~ X (c/ intercepto)",
  tibble(fit = fitted(mod_A0), stud = rstudent(mod_A0), modelo = "A0: Y ~ X (sem intercepto)",
  tibble(fit = fitted(mod_log), stud = rstudent(mod_log), modelo = "B: log(Y) ~ X")
)

ggplot(dados, aes(x = fit, y = stud)) +
  geom_point(alpha = 0.9, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  geom_hline(yintercept = c(-2, 2), linetype = "dotted", linewidth = 0.6) +
  facet_wrap(~modelo, ncol = 3, scales = "free_x") +
  labs(x = "Ajustados", y = "t* (estudentizado)") +
  theme_minimal(base_size = 12)
```



Exemplo 1 — Resíduos estudentizados vs Ajustados: comparação entre A, A0 e B.

Comentário:

Estes gráficos apresentam informações similares às ilustradas nos gráficos anteriores

QQ-plot dos resíduos

```
library(ggplot2)
library(dplyr)

# dados do QQ-plot + parâmetros da reta ao estilo qqline (base R)
qq_df_line <- function(mod, modelo){
  r <- rstandard(mod)
  q <- qqnorm(r, plot.it = FALSE)
  df <- tibble(theo = q$x, samp = q$y, modelo = modelo)

  # mesma regra do qqline: reta baseada nos quartis (25% e 75%)
  yq <- quantile(r, probs = c(0.25, 0.75), na.rm = TRUE)
  xq <- qnorm(c(0.25, 0.75))

  slope <- (yq[2] - yq[1]) / (xq[2] - xq[1])
  intercept <- yq[1] - slope * xq[1]

  list(df = df, line = tibble(modelo = modelo, intercept = intercept, slope = slope))
}


outA <- qq_df_line(mod_A, "A: Y ~ X (c/ intercepto)")
outA0 <- qq_df_line(mod_A0, "A0: Y ~ X (sem intercepto)")
outB <- qq_df_line(mod_log, "B: log(Y) ~ X")

dados <- bind_rows(outA$df, outA0$df, outB$df)
linhas <- bind_rows(outA$line, outA0$line, outB$line)

ggplot(dados, aes(x = theo, y = samp)) +
  geom_point(alpha = 0.9, size = 2) +
  geom_abline(data = linhas, aes(intercept = intercept, slope = slope),
    linewidth = 0.8) +
```



```
facet_wrap(~modelo, ncol = 3, scales = "free") +
labs(x = "Quantis teóricos (Normal)",
     y = "Resíduos padronizados") +
theme_minimal(base_size = 12)
```



Exemplo 1 — QQ-plot (rstandard) com reta tipo qqline: comparação entre A, A0 e B.

Comentário:

O QQ-plot avalia *normalidade aproximada* por meio do alinhamento entre os quantis amostrais dos resíduos e os quantis teóricos da Normal. A interpretação deve ser feita por padrões:

- **Alinhamento global próximo da reta:** evidência visual a favor de resíduos aproximadamente normais (pelo menos no “miolo” da distribuição).
- **Desvios sistemáticos nas caudas** (pontos afastando-se da reta apenas no início e no fim): indicam **caudas mais pesadas ou mais leves** que a Normal; isso costuma afetar sobretudo inferência em amostras pequenas.
- **Padrão em “S”:** sugere **assimetria** (skewness diferente de 0).
- **Um ou poucos pontos muito afastados:** podem ser indício de **outliers** (verificar também resíduos estudentizados e Cook).

Ao comparar modelos, prefira o que apresenta **menos estrutura sistemática** no QQ-plot, especialmente quando isso é coerente com as medidas numéricas de assimetria/curtose e com testes como Jarque-Bera.


Histograma dos resíduos

```
library(ggplot2)
library(dplyr)

dados <- bind_rows(
  tibble(r = resid(mod_A), modelo = "A: Y ~ X (c/ intercepto)"),
  tibble(r = resid(mod_A0), modelo = "A0: Y ~ X (sem intercepto)"),
  tibble(r = resid(mod_log), modelo = "B: log(Y) ~ X")
)

ggplot(dados, aes(x = r)) +
  geom_histogram(bins = 12, alpha = 0.7, color = "white") +
  facet_wrap(~modelo, ncol = 3, scales = "free") +
```

```
labs(x = "Resíduo", y = "Frequência") +
theme_minimal(base_size = 12)
```



Exemplo 1 — Histograma dos resíduos: comparação entre A, A0 e B.

Comentário:

O histograma é um diagnóstico auxiliar: ele ajuda a visualizar **assimetria** e **caudas**. Em geral:

- histograma muito assimétrico sugere assimetria nos resíduos;
- caudas longas ou “ombros” podem sugerir caudas pesadas e/ou outliers.


A interpretação deve ser combinada com QQ-plot e com medidas como assimetria/curtose.

Resíduos vs. X

```
suppressPackageStartupMessages({
  library(ggplot2)
  library(dplyr)
})

dados <- bind_rows(
  tibble(X = df1$X, res = resid(mod_A), modelo = "A: Y ~ X (c/ intercepto)"),
  tibble(X = df1$X, res = resid(mod_A0), modelo = "A0: Y ~ X (sem intercepto)"),
  tibble(X = df1$X, res = resid(mod_log), modelo = "B: log(Y) ~ X")
)

ggplot(dados, aes(x = X, y = res)) +
  geom_point(alpha = 0.9, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~modelo, ncol = 3, scales = "free_y") +
  labs(x = "X", y = "Resíduo") +
  theme_minimal(base_size = 12)
```



Exemplo 1 — Resíduos vs X: comparação entre A, A0 e B.

Comentário:

- Ambos os **Modelos (A e B)** apresentam dispersão uniforme em torno de zero, corroborando a homocedasticidade.

O diagnóstico gráfico serve como “primeira triagem”: se houver funil, curvatura ou caudas muito pesadas, isso aparece visualmente de modo imediato. Somente depois disso faz sentido dar peso às comparações numéricas.

vi. Conclusões do exemplo

- O modelo sem intercepto tende a se ajustar mal, pois ignora o consumo em stand-by. Este modelo foi descartado no teste com modelo aninhados.
- O modelo com intercepto melhora substancialmente o ajuste quando comparado com o modelo sem intercepto.
- Assim como o modelo com intercepto (A), o modelo com variável transformada (B) também mostrou um bom ajuste.
- Os resíduos dos modelos A e B mostraram que podemos considerar que ambos os modelos foram bem especificados.
- O modelo B apresentou AIC/BIC menores. No entanto, como apresentado anteriormente, não é correto comparar diretamente os valores de um modelo ajustado em Y com outro ajustado em $\log(Y)$, pois a verossimilhança é diferente.
- Considerando que os modelos A e B foram bem especificados e não teve uma métrica de qualidade de ajuste muito favorável a um deles, é aconselhado o uso do modelo mais simples e na escala original da variável (Modelo A - com intercepto).

10.4.2 Exemplo 2 — Escolhendo a melhor variável explicativa

i. **Cenário e modelos candidatos** um pesquisador deseja explicar a produtividade agrícola (Y) a partir de três variáveis candidatas:

- X_1 = quantidade de fertilizante aplicada (kg/ha)
- X_2 = volume de irrigação (mm)
- X_3 = horas de sol na safra (h)

O objetivo é descobrir **qual dessas variáveis explica melhor Y** de forma individual.

Os três MRLS candidatos são:

1. **Modelo A:** $Y = \beta_0 + \beta_1 X_1 + \varepsilon$
2. **Modelo B:** $Y = \beta_0 + \beta_2 X_2 + \varepsilon$
3. **Modelo C:** $Y = \beta_0 + \beta_3 X_3 + \varepsilon$

Passos da análise comparativa:

1. **Ajuste de cada modelo** separadamente.
2. **Diagnóstico dos resíduos** em cada caso, verificando linearidade, homoscedasticidade e normalidade.
3. **Comparação de medidas de ajuste:** R^2 , R^2_{aj} , AIC e BIC.
4. **Discussão substantiva:** qual variável faz mais sentido teoricamente como explicativa de Y .

Critérios práticos de decisão:

- Se todos os modelos tiverem resíduos adequados, a comparação pode ser feita pelos critérios formais (AIC/BIC, R^2_{aj}).
- Se apenas um modelo tiver resíduos consistentes com as hipóteses do MRLS, ele deve ser preferido.
- Mesmo que dois modelos apresentem ajustes estatisticamente próximos, a escolha deve considerar a **interpretação prática**.

ii. Simulação dos dados

```
suppressPackageStartupMessages({
  library(dplyr)
})

set.seed(2025)

# Simulação: produtividade (Y) explicada por X1, X2, X3 (candidatas)
n2 <- 120
X1 <- runif(n2, 0, 100) # fertilizante, 0-100 kg/ha
X2 <- runif(n2, 0, 60)  # irrigação, 0-60 mm
X3 <- runif(n2, 200, 350) # horas de sol, 200-350 h

# Verdade de geração
Y2 <- 20 + 0.45*X1 + 0.12*X2 + 0.02*X3 + rnorm(n2, 0, 10)

df2 <- tibble(Y = Y2, X1 = X1, X2 = X2, X3 = X3)

head(df2)
```

```
# A tibble: 6 × 4
      Y    X1    X2    X3
<dbl> <dbl> <dbl> <dbl>
1  68.4  73.3  43.4  239.
2  59.9  47.6  39.9  245.
3  67.5  51.4  44.3  229.
4  59.2  49.8  33.2  332.
5  49.9  78.0  41.1  250.
6  42.0  50.4  43.0  241.
```

Neste exemplo, as três variáveis candidatas têm escalas diferentes, mas isso não impede o ajuste de três MRLS separados. O que muda é a interpretação dos coeficientes e a magnitude dos erros-padrão. Como o objetivo é “melhor preditor individual”, estamos comparando **três modelos alternativos não aninhados**.

Este exemplo buscar mostrar que, mesmo no contexto de MRLS, a comparação entre variáveis explicativas pode guiar a seleção do **melhor preditor individual**.

iii. **Roteiro de tarefas (atividade guiada)**

1. **Ajuste os três modelos candidatos** separadamente:

- Modelo A: $\$ Y = _0 + _1 X_1 + \$$
- Modelo B: $\$ Y = _0 + _2 X_2 + \$$
- Modelo C: $\$ Y = _0 + _3 X_3 + \$$

2. **Inspecione os resíduos** de cada modelo:

- Gráficos de resíduos versus ajustados.
- QQ-plot para verificar normalidade.
- Histograma dos resíduos.
- Resíduos versus a variável explicativa X .

3. **Compare as medidas de ajuste** entre os modelos:

- R^2_{aj} (ajustado)
- AIC
- BIC

4. **Discuta os resultados obtidos:**

- Qual modelo apresentou resíduos mais consistentes com as hipóteses do MRLS?
- Qual modelo apresentou melhor desempenho segundo R^2_{aj} , AIC e BIC?
- Existe coerência entre os diagnósticos gráficos e as medidas numéricas?

5. **Reflexão substantiva:**

- Do ponto de vista prático, qual variável é a melhor candidata a explicar a produtividade agrícola (Y) individualmente e por quê?
- Considere plausibilidade causal e relevância no contexto agrícola (fertilizante, irrigação ou horas de sol).

6. **Desafio opcional:**

- Re-simule os dados com outro *seed* ou altere o nível de ruído.
- Observe se a escolha do melhor modelo permanece a mesma ou se muda.

```
# Ajustes dos três MRLS candidatos
m1 <- lm(Y ~ X1, data = df2)
m2 <- lm(Y ~ X2, data = df2)
m3 <- lm(Y ~ X3, data = df2)

cat("=== Modelo A: Y ~ X1 ===\n"); print(summary(m1))
```

=== Modelo A: Y ~ X1 ===

Call:

lm(formula = Y ~ X1, data = df2)

Residuals:

Min	1Q	Median	3Q	Max
-30.5982	-6.0204	0.6442	6.9029	27.5385

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	31.49842	1.84972	17.03	<2e-16 ***
X1	0.41940	0.03076	13.63	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.73 on 118 degrees of freedom

Multiple R-squared: 0.6117, Adjusted R-squared: 0.6084

F-statistic: 185.9 on 1 and 118 DF, p-value: < 2.2e-16

```
cat("\n=== Modelo B: Y ~ X2 ===\n"); print(summary(m2))
```

=== Modelo B: Y ~ X2 ===

Call:

lm(formula = Y ~ X2, data = df2)

Residuals:

Min	1Q	Median	3Q	Max
-45.332	-10.528	2.142	12.276	35.247

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	47.69985	2.63414	18.108	< 2e-16 ***
X2	0.19641	0.07436	2.641	0.00937 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.17 on 118 degrees of freedom

Multiple R-squared: 0.05583, Adjusted R-squared: 0.04783

F-statistic: 6.977 on 1 and 118 DF, p-value: 0.009374

```
cat("\n=== Modelo C: Y ~ X3 ===\n"); print(summary(m3))
```

=== Modelo C: Y ~ X3 ===

Call:

lm(formula = Y ~ X3, data = df2)

Residuals:

Min	1Q	Median	3Q	Max
-49.032	-12.257	1.166	11.872	31.353

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	58.31156	8.78394	6.638	1.02e-09 ***
X3	-0.01715	0.03168	-0.541	0.589

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.59 on 118 degrees of freedom

Multiple R-squared: 0.002478, Adjusted R-squared: -0.005975

F-statistic: 0.2932 on 1 and 118 DF, p-value: 0.5892

```

cmp2 <- tibble(
  Modelo = c("A: Y~X1", "B: Y~X2", "C: Y~X3"),
  R2      = c(summary(m1)$r.squared, summary(m2)$r.squared, summary(m3)$r.squared),
  R2_aj   = c(summary(m1)$adj.r.squared, summary(m2)$adj.r.squared, summary(m3)$adj.r.squared),
  AIC     = c(AIC(m1), AIC(m2), AIC(m3)),
  BIC     = c(BIC(m1), BIC(m2), BIC(m3))
)

```

```
cmp2
```

```

# A tibble: 3 × 5
  Modelo      R2    R2_aj   AIC    BIC
  <chr>    <dbl>  <dbl> <dbl> <dbl>
1 A: Y~X1 0.612    0.608   891.  899.
2 B: Y~X2 0.0558   0.0478  997. 1006.
3 C: Y~X3 0.00248 -0.00598 1004. 1012.

```

Diagnóstico gráfico comparativo:

- dispersão Y vs cada X_j com reta OLS (um painel por modelo);
- resíduos vs ajustados (um painel por modelo);
- QQ-plot (um painel por modelo);
- histograma dos resíduos (um painel por modelo);
- resíduos vs X_j (um painel por modelo).

```

suppressPackageStartupMessages({
  library(ggplot2)
  library(dplyr)
  library(tidyr)
})

# Organizar dados em formato longo para facilitar facetas
long_xy <- df2 %>%
  pivot_longer(cols = c(X1, X2, X3), names_to = "Xname", values_to = "X") %>%
  mutate(modelo = recode(Xname, X1 = "Modelo A: Y~X1", X2 = "Modelo B: Y~X2", X3 = "Modelo C: Y~X3"))

# Função auxiliar para extrair resíduos e ajustados por modelo
aug1 <- tibble(fit = fitted(m1), res = resid(m1), modelo = "Modelo A: Y~X1")
aug2 <- tibble(fit = fitted(m2), res = resid(m2), modelo = "Modelo B: Y~X2")
aug3 <- tibble(fit = fitted(m3), res = resid(m3), modelo = "Modelo C: Y~X3")
aug <- bind_rows(aug1, aug2, aug3)

# 1) Y vs X com reta OLS
p1 <- ggplot(long_xy, aes(x = X, y = Y)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 1) +
  facet_wrap(~modelo, ncol = 3, scales = "free_x") +
  labs(x = NULL, y = "Y") +
  theme_minimal(base_size = 12)

# 2) Resíduos vs ajustados
p2 <- ggplot(aug, aes(x = fit, y = res)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~modelo, ncol = 3, scales = "free_x") +

```

```

labs(x = "Ajustados", y = "Resíduo") +
theme_minimal(base_size = 12)

# 3) QQ-plot (estilo plot.lm, which = 2)

qq_df_lmstyle <- function(mod, modelo){
  r <- rstandard(mod) # mesmo tipo de resíduo do plot.lm
  q <- qqnorm(r, plot.it = FALSE)

  pts <- tibble(
    theo = q$x,
    samp = q$y,
    modelo = modelo
  )

  # reta tipo qqline(): passa pelos quartis 25% e 75%
  yq <- quantile(r, c(0.25, 0.75))
  xq <- qnorm(c(0.25, 0.75))
  slope <- (yq[2] - yq[1])/(xq[2] - xq[1])
  intercept <- yq[1] - slope*xq[1]

  line <- tibble(
    modelo = modelo,
    intercept = as.numeric(intercept),
    slope = as.numeric(slope)
  )

  list(pts = pts, line = line)
}

o1 <- qq_df_lmstyle(m1, "Modelo A: Y~X1")
o2 <- qq_df_lmstyle(m2, "Modelo B: Y~X2")
o3 <- qq_df_lmstyle(m3, "Modelo C: Y~X3")

qq_all <- bind_rows(o1$pts, o2$pts, o3$pts)
qq_line <- bind_rows(o1$line, o2$line, o3$line)

p3 <- ggplot(qq_all, aes(x = theo, y = samp)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_abline(
    data = qq_line,
    aes(intercept = intercept, slope = slope),
    linewidth = 0.8
  ) +
  facet_wrap(~modelo, ncol = 3, scales = "free") +
  labs(x = "Quantis teóricos (Normal)", y = "Resíduos padronizados") +
  theme_minimal(base_size = 12)

# 4) Histogramas dos resíduos
res_all <- bind_rows(
  tibble(r = resid(m1), modelo = "Modelo A: Y~X1"),
  tibble(r = resid(m2), modelo = "Modelo B: Y~X2"),
  tibble(r = resid(m3), modelo = "Modelo C: Y~X3")
)

p4 <- ggplot(res_all, aes(x = r)) +

```



```


geom_histogram(bins = 12, alpha = 0.7, color = "white") +
facet_wrap(~modelo, ncol = 3, scales = "free") +
labs(x = "Resíduo", y = "Frequência") +
theme_minimal(base_size = 12)

# 5) Resíduos vs X (por modelo)
rx <- bind_rows(
  df2 %>% transmute(X = X1, res = resid(m1), modelo = "Modelo A: Y~X1"),
  df2 %>% transmute(X = X2, res = resid(m2), modelo = "Modelo B: Y~X2"),
  df2 %>% transmute(X = X3, res = resid(m3), modelo = "Modelo C: Y~X3")
)

p5 <- ggplot(rx, aes(x = X, y = res)) +
  geom_point(alpha = 0.85, size = 2) +
  geom_hline(yintercept = 0, linetype = "dashed", linewidth = 0.6) +
  facet_wrap(~modelo, ncol = 3, scales = "free_x") +
  labs(x = NULL, y = "Resíduo") +
  theme_minimal(base_size = 12)


# Mostrar os 5 gráficos (um por vez, na ordem)
print(p1)

```




Diagnóstico gráfico comparativo (Exemplo 2): cada linha corresponde a um modelo (A, B, C).

```
print(p2)
```




Diagnóstico gráfico comparativo (Exemplo 2): cada linha corresponde a um modelo (A, B, C).

```
print(p3)
```




Diagnóstico gráfico comparativo (Exemplo 2): cada linha corresponde a um modelo (A, B, C).

```
print(p4)
```



Diagnóstico gráfico comparativo (Exemplo 2): cada linha corresponde a um modelo (A, B, C).

```
print(p5)
```



Diagnóstico gráfico comparativo (Exemplo 2): cada linha corresponde a um modelo (A, B, C).

- Se um modelo “vence” nos critérios numéricos, mas apresenta funil/curvatura/caudas pesadas, ele deve perder força como candidato.
- Se dois modelos forem próximos numericamente, a decisão pode depender do contexto (medição, causalidade plausível, custo de obter a variável, etc.).

iv. Fechamento e síntese

Os dois exemplos mostraram situações complementares na prática do MRLS. O **Exemplo 1** destacou como diferentes especificações de um mesmo modelo, com intercepto, sem intercepto e com transformação em (Y), podem levar a conclusões distintas sobre ajuste, resíduos e interpretação. Já o **Exemplo 2** explorou a escolha entre

diferentes variáveis candidatas, mostrando como a comparação de modelos separados orienta a seleção do preditor mais adequado.

Em conjunto, os exemplos reforçam que a escolha do modelo não deve se basear apenas em indicadores numéricos, mas sim no equilíbrio entre **consistência estatística, parcimônia e coerência substantiva** com o fenômeno estudado.