

## 14 Estrutura Matricial dos Modelos de Regressão Linear

A formulação moderna dos modelos de regressão linear é essencialmente matricial. Essa notação vetorial revela a estrutura geométrica do problema de estimação, explicita as condições necessárias para identificabilidade dos parâmetros e permite analisar propriedades estatísticas dos estimadores de forma sistemática (Harville, 2000).

Este apêndice consolida os principais elementos de Álgebra Linear utilizados ao longo do estudo de regressão, com ênfase nas estruturas que reaparecem na estimação por mínimos quadrados, na inferência e na análise de diagnóstico.

### 14.1 Operações Fundamentais com Matrizes e Vetores

A linguagem matricial é uma forma compacta de escrever o modelo de regressão que permite enxergar o problema como um problema geométrico em  $\mathbb{R}^n$ . Cada vetor corresponde a um ponto ou direção nesse espaço, e cada matriz representa uma transformação linear.

Sejam  $\mathbf{A}$  e  $\mathbf{B}$  matrizes de dimensões compatíveis e  $\mathbf{x}, \mathbf{y}$  vetores coluna em  $\mathbb{R}^n$ .

Para fixar ideias, considere explicitamente:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}.$$

#### 14.1.1 Soma Matricial

Se

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix},$$

então

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} \\ a_{21} + b_{21} & a_{22} + b_{22} \end{bmatrix}.$$

A soma é definida elemento a elemento e exige dimensões idênticas.

#### 14.1.2 Produto Matricial

Se

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix},$$

então

$$\mathbf{AB} = \begin{bmatrix} a_{11}b_{11} + a_{12}b_{21} & a_{11}b_{12} + a_{12}b_{22} \\ a_{21}b_{11} + a_{22}b_{21} & a_{21}b_{12} + a_{22}b_{22} \end{bmatrix}.$$

O produto matricial corresponde à composição de transformações lineares.

No modelo linear

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta},$$

a matriz  $\mathbf{X}$ , de dimensão  $n \times (p + 1)$  transforma o vetor de parâmetros  $\boldsymbol{\beta}$ , de dimensão  $(p + 1) \times 1$  em um vetor no espaço das respostas. Assim,  $\mathbf{X}$  pode ser interpretada como uma transformação que leva parâmetros em  $\mathbb{R}^{p+1}$  para vetores ajustados em  $\mathbb{R}^n$ .

### 14.1.3 Produto Interno e Norma

O produto interno entre vetores é dado por

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^n x_i y_i.$$

Quando  $\mathbf{x} = \mathbf{y}$ , obtemos

$$\mathbf{x}^\top \mathbf{x} = \sum_{i=1}^n x_i^2,$$

que define o quadrado da norma euclidiana:

$$\|\mathbf{x}\|^2 = \mathbf{x}^\top \mathbf{x}.$$

Essa noção de norma é central na regressão, pois a estimação por mínimos quadrados consiste em minimizar

$$\|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2.$$

Portanto, o problema de estimação é um problema geométrico de minimizar distância no espaço  $\mathbb{R}^n$ . A formulação geométrica da regressão em termos de subespaços e projeções é desenvolvida em detalhe em Harville (2000).

### 14.1.4 Forma Quadrática

Uma expressão da forma

$$\mathbf{x}^\top \mathbf{A} \mathbf{x}$$

é chamada forma quadrática.

Para visualizar, considere

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} a & b \\ b & c \end{bmatrix}.$$

Então

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} = ax_1^2 + 2bx_1x_2 + cx_2^2.$$

Observe que surgem termos quadráticos e termos mistos. Em regressão, as somas de quadrados explicada e residual podem ser escritas exatamente como formas quadráticas do vetor  $\mathbf{Y}$  (Rencher; Christensen, 2012).

### 14.1.5 Transposição

A transposta de uma matriz é obtida trocando linhas por colunas:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \Rightarrow \mathbf{A}^\top = \begin{bmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{bmatrix}.$$

A transposição é essencial para definir produtos internos e garantir que expressões como  $\mathbf{X}^\top \mathbf{X}$  sejam matrizes quadradas.

### 14.1.6 Inversão

Uma matriz quadrada  $\mathbf{A}$  é invertível se existe  $\mathbf{A}^{-1}$  tal que

$$\mathbf{A}^{-1} \mathbf{A} = \mathbf{A} \mathbf{A}^{-1} = \mathbf{I}.$$

Por exemplo, para uma matriz  $2 \times 2$ ,

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

se  $ad - bc \neq 0$ , então

$$\mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

Na regressão, a invertibilidade de  $\mathbf{X}^\top \mathbf{X}$  é condição necessária para a existência do estimador de mínimos quadrados único. Para o caso de posto deficiente e o uso de decomposição SVD e pseudoinversas ([Golub; Van Loan, 2013](#)).

### 14.1.7 Propriedades Importantes

Duas identidades frequentemente utilizadas são

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top, \quad (\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1}.$$

Essas propriedades são fundamentais na dedução de resultados como:

$$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1},$$

e na demonstração das propriedades das matrizes de projeção.

Essas operações constituem o mecanismo estrutural que permitirá:

- interpretar o estimador como projeção ortogonal;
- escrever somas de quadrados como formas quadráticas;
- analisar variâncias e covariâncias de estimadores;
- compreender a geometria do ajuste e do diagnóstico.

Nos itens seguintes, essas operações serão organizadas dentro da estrutura específica do modelo linear múltiplo.

## 14.2 Estruturas Matriciais Relevantes

Determinados tipos de matrizes surgem de forma recorrente na teoria da regressão linear. Cada uma delas corresponde a uma propriedade geométrica ou estatística que será explorada na estimação, na inferência e na análise de diagnóstico.

A tabela a seguir resume algumas dessas estruturas fundamentais.

| Tipo                      | Definição                                                                 | Relevância                                |
|---------------------------|---------------------------------------------------------------------------|-------------------------------------------|
| Identidade $\mathbf{I}_n$ | Diagonal principal composta por 1's                                       | Elemento neutro da multiplicação          |
| Simétrica                 | $\mathbf{A} = \mathbf{A}^\top$                                            | Autovalores reais                         |
| Idempotente               | $\mathbf{A}^2 = \mathbf{A}$                                               | Projeções                                 |
| Ortogonal                 | $\mathbf{A}^\top \mathbf{A} = \mathbf{I}$                                 | Preserva norma                            |
| Diagonal                  | Elementos fora da diagonal iguais a zero                                  | Simplifica formas quadráticas             |
| Definida positiva         | $\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0$ para todo $\mathbf{x} \neq 0$ | Garantia de invertibilidade e convexidade |

A seguir, detalham-se as propriedades e implicações dessas estruturas no contexto do modelo linear.

### 14.2.1 Matriz Identidade

A matriz identidade de ordem  $n$  é dada por

$$\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}.$$

Ela satisfaz

$$\mathbf{I}_n \mathbf{x} = \mathbf{x} \quad \text{para todo } \mathbf{x} \in \mathbb{R}^n.$$

No modelo linear, a identidade aparece, por exemplo, na matriz de covariância dos erros sob homocedasticidade:

$$\text{Cov}(\boldsymbol{\epsilon}) = \sigma^2 \mathbf{I}_n.$$

Sob normalidade, essa estrutura implica independência e variância constante dos erros.

### 14.2.2 Matrizes Simétricas

Uma matriz é simétrica se

$$\mathbf{A} = \mathbf{A}^\top.$$

Por exemplo,

$$\mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 3 \end{bmatrix}$$

é simétrica.

Matrizes simétricas possuem autovalores reais e podem ser diagonalizadas por matrizes ortogonais. Essa propriedade é crucial para compreender a decomposição espectral de  $\mathbf{X}^\top \mathbf{X}$  e analisar problemas como multicolinearidade ([Harville, 2000](#)).

No modelo linear, as matrizes  $\mathbf{X}^\top \mathbf{X}$ ,  $\mathbf{H}$  e  $\mathbf{M}$  são simétricas.

### 14.2.3 Matrizes Idempotentes

Uma matriz é idempotente se

$$\mathbf{A}^2 = \mathbf{A}.$$

Isso implica que aplicar a transformação duas vezes produz o mesmo resultado que aplicá-la uma vez.

Por exemplo, a matriz

$$\mathbf{P} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

é idempotente.

No modelo linear, a matriz de projeção

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$$

satisfaz

$$\mathbf{H}^2 = \mathbf{H}.$$

Isso significa que  $\mathbf{H}$  projeta vetores no subespaço  $\text{col}(\mathbf{X})$ . Uma vez projetado, aplicar novamente a projeção não altera o vetor.

Essa propriedade é fundamental para compreender:

- decomposição ortogonal;
- independência entre componentes projetadas sob normalidade;
- decomposição da soma de quadrados total.

### 14.2.4 Matrizes Ortogonais

Uma matriz  $\mathbf{Q}$  é ortogonal se

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Isso implica que

$$\|\mathbf{Q}\mathbf{x}\| = \|\mathbf{x}\|.$$

Ou seja, matrizes ortogonais preservam comprimentos e ângulos.

Essa propriedade é central na decomposição espectral de matrizes simétricas:

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^\top,$$

em que  $\mathbf{\Lambda}$  é diagonal contendo os autovalores. A análise numérica dessas decomposições é tratada em profundidade em Golub; Van Loan (2013).

Na regressão, essa decomposição permite analisar:

- a estrutura de  $\mathbf{X}^\top \mathbf{X}$ ;
- a estabilidade numérica da estimação;
- o efeito da multicolinearidade.

### 14.2.5 Matrizes Diagonais

Uma matriz diagonal possui a forma

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix}.$$

Formas quadráticas envolvendo matrizes diagonais simplificam-se para

$$\mathbf{x}^\top \mathbf{D} \mathbf{x} = \sum_{i=1}^n d_i x_i^2.$$

Essa simplificação é útil na análise de variâncias e na interpretação de decomposições espectrais.

### 14.2.6 Matrizes Definidas Positivas

Uma matriz simétrica  $\mathbf{A}$  é definida positiva se

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} > 0 \quad \text{para todo } \mathbf{x} \neq \mathbf{0}.$$

Equivalentemente, todos os seus autovalores são positivos.

Essa propriedade possui consequências fundamentais:

1.  $\mathbf{A}$  é invertível;
2. a função  $\mathbf{x}^\top \mathbf{A} \mathbf{x}$  é estritamente convexa;
3. problemas de minimização associados possuem solução única.

No modelo de regressão linear, a matriz

$$\mathbf{X}^\top \mathbf{X}$$

é simétrica e definida positiva se, e somente se, as colunas de  $\mathbf{X}$  forem linearmente independentes. Isso equivale à condição

$$\text{rank}(\mathbf{X}) = p + 1.$$

Quando essa condição é satisfeita, o estimador de mínimos quadrados

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

existe e é único.

Se  $\mathbf{X}^\top \mathbf{X}$  não for definida positiva, o problema de estimação perde identificabilidade, caracterizando multicolinearidade perfeita.

A compreensão dessas estruturas matriciais permite interpretar o modelo linear como:

- um problema geométrico de projeção em subespaços;
- um problema analítico de minimização convexa;
- um problema espectral envolvendo autovalores e autovetores.

Essas perspectivas convergem na teoria de estimação, inferência e diagnóstico.

## 14.3 Estrutura Geométrica do Modelo Linear

Considere o modelo linear múltiplo em notação matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

em que

- $\mathbf{Y} \in \mathbb{R}^n$  é o vetor de respostas observadas,
- $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$  é a matriz de planejamento,
- $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$  é o vetor de parâmetros,
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$  é o vetor de erros.

Explicitamente, pode-se escrever

$$\mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}.$$

Cada coluna de  $\mathbf{X}$  é um vetor em  $\mathbb{R}^n$ . Assim,  $\mathbf{X}$  pode ser vista como um conjunto de  $p + 1$  vetores que geram um subespaço de  $\mathbb{R}^n$ .

### 14.3.1 Espaço Coluna e Identificabilidade

O **espaço coluna** de  $\mathbf{X}$  é definido como

$$\text{col}(\mathbf{X}) = \{\mathbf{X}\boldsymbol{\beta} : \boldsymbol{\beta} \in \mathbb{R}^{p+1}\}.$$

Esse conjunto é um subespaço vetorial de  $\mathbb{R}^n$ , cujo posto é

$$\text{rank}(\mathbf{X}) \leq p + 1.$$

Se as colunas de  $\mathbf{X}$  forem linearmente independentes, então

$$\text{rank}(\mathbf{X}) = p + 1,$$

e o espaço coluna tem dimensão  $p + 1$ .

Essa condição é equivalente à positividade definida de  $\mathbf{X}^\top \mathbf{X}$  e garante a identificabilidade única dos parâmetros.

### 14.3.2 O Problema de Mínimos Quadrados como Problema de Projeção

O estimador de mínimos quadrados é definido como a solução do problema

$$\min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2.$$

Geometricamente, isso significa encontrar o vetor em  $\text{col}(\mathbf{X})$  que esteja mais próximo de  $\mathbf{Y}$  na métrica euclidiana.

Seja

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}.$$

Então

$$\hat{\mathbf{Y}} \in \text{col}(\mathbf{X})$$

e

$$\mathbf{Y} - \hat{\mathbf{Y}} \perp \text{col}(\mathbf{X}).$$

Ouseja,

$$\mathbf{X}^\top (\mathbf{Y} - \hat{\mathbf{Y}}) = \mathbf{0}.$$

Essa condição é exatamente a forma matricial das equações normais.

### 14.3.3 Interpretação Ortogonal e Soma Direta

Seja  $V = \mathbb{R}^n$  equipado com o produto interno usual

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}.$$

Se  $S$  é um subespaço de  $\mathbb{R}^n$ , define-se seu complemento ortogonal como

$$S^\perp = \{\mathbf{z} \in \mathbb{R}^n : \mathbf{z}^\top \mathbf{s} = 0 \text{ para todo } \mathbf{s} \in S\}.$$

Diz-se que  $\mathbb{R}^n$  é a **soma direta ortogonal** de dois subespaços  $S$  e  $T$  se:

1. todo vetor de  $\mathbb{R}^n$  pode ser escrito como soma de um vetor em  $S$  e um vetor em  $T$ ;
2. essa decomposição é única;
3.  $S$  e  $T$  são ortogonais, isto é,  $\mathbf{s}^\top \mathbf{t} = 0$  para todo  $\mathbf{s} \in S$  e  $\mathbf{t} \in T$ .

Nessa situação escreve-se

$$\mathbb{R}^n = S \oplus T,$$

em que o símbolo  $\oplus$  indica soma direta.

No contexto do modelo linear, tomando

$$S = \text{col}(\mathbf{X}), \quad T = \text{col}(\mathbf{X})^\perp,$$

obtem-se

$$\mathbb{R}^n = \text{col}(\mathbf{X}) \oplus \text{col}(\mathbf{X})^\perp.$$

Isso significa que qualquer vetor  $\mathbf{Y} \in \mathbb{R}^n$  pode ser decomposto de maneira única como

$$\mathbf{Y} = \hat{\mathbf{Y}} + \hat{\boldsymbol{\varepsilon}},$$

onde

- $\hat{\mathbf{Y}} \in \text{col}(\mathbf{X})$ ,
- $\hat{\boldsymbol{\varepsilon}} \in \text{col}(\mathbf{X})^\perp$ .

A ortogonalidade implica

$$\hat{\mathbf{Y}}^\top \hat{\boldsymbol{\varepsilon}} = 0,$$

ou, equivalentemente,

$$\mathbf{X}^\top \hat{\boldsymbol{\varepsilon}} = \mathbf{0}.$$



Essa decomposição é puramente geométrica e independe de qualquer hipótese probabilística sobre os erros. Ela constitui o núcleo estrutural do método de mínimos quadrados e fundamenta:

- a decomposição da soma de quadrados total;
- a contagem de graus de liberdade;
- a independência entre componentes projetadas sob normalidade.

Assim, o modelo linear pode ser interpretado como a decomposição ortogonal do vetor de respostas em duas componentes pertencentes a subespaços complementares.

### 14.3.4 Relação com Posto e Dimensão

Se  $\text{rank}(\mathbf{X}) = r$ , então:

- $\dim(\text{col}(\mathbf{X})) = r$ ,
- $\dim(\text{col}(\mathbf{X})^\perp) = n - r$ .

No modelo linear completo com intercepto e colunas independentes,

$$r = p + 1,$$

e, portanto, o espaço residual tem dimensão

$$n - (p + 1).$$

Essa contagem de dimensões será reinterpretada mais adiante como graus de liberdade na decomposição das somas de quadrados.

### 14.3.5 Conexão com Diagnóstico

A estrutura geométrica permite compreender diversos elementos de diagnóstico:

- Vetores de alta alavancagem correspondem a observações cuja projeção sobre  $\text{col}(\mathbf{X})$  é dominante.
- Resíduos grandes correspondem a componentes significativas no subespaço ortogonal.
- A decomposição da variabilidade total decorre da ortogonalidade entre componentes projetadas.

O modelo linear é, portanto, uma decomposição geométrica do vetor de respostas em dois componentes ortogonais.

## 14.4 Matrizes de Projeção e Decomposição Ortogonal

---

A matriz de projeção associada ao modelo linear múltiplo é definida por

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

Essa matriz desempenha papel relevante na teoria da regressão, pois formaliza algebricamente a projeção ortogonal sobre o subespaço  $\text{col}(\mathbf{X})$ .

#### 14.4.0.1 Verificação das Propriedades Estruturais

##### Simetria

$$\mathbf{H}^\top = [\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top]^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{H}.$$

Utilizou-se o fato de que  $\mathbf{X}^\top \mathbf{X}$  é simétrica e que a transposta de um produto inverte a ordem dos fatores.

## Idempotência

$$\mathbf{H}^2 = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

Como

$$\mathbf{X}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} = \mathbf{I},$$

segue que

$$\mathbf{H}^2 = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top = \mathbf{H}.$$

A idempotência caracteriza transformações que, uma vez aplicadas, não alteram mais o vetor.

### 14.4.0.2 Interpretação Geométrica

Para qualquer vetor  $\mathbf{y} \in \mathbb{R}^n$ ,

$$\mathbf{H}\mathbf{y} \in \text{col}(\mathbf{X}).$$

Além disso,

$$\mathbf{y} - \mathbf{H}\mathbf{y} \in \text{col}(\mathbf{X})^\perp.$$

Portanto,

$$\mathbf{y} = \mathbf{H}\mathbf{y} + (\mathbf{I} - \mathbf{H})\mathbf{y}.$$

Definindo

$$\mathbf{M} = \mathbf{I}_n - \mathbf{H},$$

obtém-se a projeção complementar sobre o subespaço ortogonal.

### 14.4.0.3 Propriedades da Matriz Residual

A matriz

$$\mathbf{M} = \mathbf{I}_n - \mathbf{H}$$

satisfaz:

- $\mathbf{M}^\top = \mathbf{M}$ ,
- $\mathbf{M}^2 = \mathbf{M}$ ,
- $\mathbf{H}\mathbf{M} = \mathbf{0}$ ,
- $\mathbf{M}\mathbf{H} = \mathbf{0}$ .

Essas propriedades garantem que os subespaços são ortogonais e complementares.

### 14.4.0.4 Decomposição do Vetor de Respostas

Aplicando as matrizes ao vetor  $\mathbf{Y}$ :

$$\mathbf{Y} = \mathbf{H}\mathbf{Y} + \mathbf{M}\mathbf{Y} = \hat{\mathbf{Y}} + \hat{\boldsymbol{\varepsilon}}.$$

em que

- $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$  pertence ao espaço coluna;
- $\hat{\boldsymbol{\varepsilon}} = \mathbf{M}\mathbf{Y}$  pertence ao complemento ortogonal.

A ortogonalidade implica

$$\hat{\mathbf{Y}}^\top \hat{\boldsymbol{\varepsilon}} = 0.$$

Essa identidade é a base da decomposição da soma de quadrados total.

#### 14.4.0.5 Traço, Posto e Autovalores

Para matrizes idempotentes e simétricas, os autovalores são apenas 0 ou 1.

Se

$$\text{rank}(\mathbf{X}) = p + 1,$$

então:

- $\mathbf{H}$  possui  $p + 1$  autovalores iguais a 1,
- e  $n - (p + 1)$  autovalores iguais a 0.

Assim,

$$\text{tr}(\mathbf{H}) = p + 1.$$

De forma análoga,

$$\text{tr}(\mathbf{M}) = n - p - 1.$$

Como o traço de uma matriz idempotente simétrica coincide com seu posto, essas quantidades correspondem às dimensões dos subespaços projetados (ver Harville (2000)).

#### 14.4.0.6 Conexão com Somas de Quadrados

A soma de quadrados ajustada pode ser escrita como

$$\mathbf{Y}^\top \mathbf{H} \mathbf{Y}.$$

A soma de quadrados residual é

$$\mathbf{Y}^\top \mathbf{M} \mathbf{Y}.$$

Como  $\mathbf{H}$  e  $\mathbf{M}$  projetam sobre subespaços ortogonais,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{H} \mathbf{Y} + \mathbf{Y}^\top \mathbf{M} \mathbf{Y}.$$

Essa identidade é puramente geométrica e antecede qualquer consideração probabilística.

#### 14.4.0.7 Relação com Diagnóstico

A diagonal de  $\mathbf{H}$  contém as alavancagens:

$$h_{ii} = (\mathbf{H})_{ii}.$$

Essas quantidades medem o grau de influência estrutural da  $i$ -ésima observação no ajuste, pois determinam o peso da projeção sobre o espaço coluna (ver Weisberg (2005)).

Valores elevados de  $h_{ii}$  indicam observações que ocupam posições extremas no espaço das covariáveis.

A matriz de projeção sintetiza, portanto, três dimensões fundamentais do modelo linear:

1. Estrutura geométrica (projeção ortogonal);
2. Estrutura algébrica (idempotência e posto);
3. Estrutura estatística (somas de quadrados e graus de liberdade).

## 14.5 Diferenciação Matricial e Estimação por Mínimos Quadrados

A estimação por mínimos quadrados consiste na minimização da soma de quadrados dos resíduos,

$$S(\beta) = \|\mathbf{Y} - \mathbf{X}\beta\|^2 = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Essa função é uma forma quadrática em  $\beta$ . Para compreender sua estrutura, é útil expandi-la explicitamente:

$$S(\beta) = \mathbf{Y}^\top \mathbf{Y} - 2\beta^\top \mathbf{X}^\top \mathbf{Y} + \beta^\top \mathbf{X}^\top \mathbf{X} \beta.$$

Observa-se que:

- $\mathbf{Y}^\top \mathbf{Y}$  é constante em relação a  $\beta$ ;
- $\beta^\top \mathbf{X}^\top \mathbf{Y}$  é termo linear;
- $\beta^\top \mathbf{X}^\top \mathbf{X} \beta$  é forma quadrática.

A função objetivo é, portanto, um polinômio quadrático convexo sempre que  $\mathbf{X}^\top \mathbf{X}$  for definida positiva.

### 14.5.1 Derivadas Matriciais Fundamentais

As identidades de cálculo matricial utilizadas a seguir são sistematizadas em Abadir; Magnus (2005).

1. 
$$\frac{\partial(\mathbf{a}^\top \mathbf{x})}{\partial \mathbf{x}} = \mathbf{a}$$
2. 
$$\frac{\partial(\mathbf{x}^\top \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}$$

Em particular, se  $\mathbf{A}$  é simétrica,

3. 
$$\frac{\partial(\mathbf{x}^\top \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x}.$$
4. 
$$\frac{\partial(\mathbf{x}^\top \mathbf{A} \mathbf{b})}{\partial \mathbf{x}} = \mathbf{A}^\top \mathbf{b}$$
5. 
$$\frac{\partial \text{tr}(\mathbf{A} \mathbf{X})}{\partial \mathbf{X}} = \mathbf{A}^\top$$
5. 
$$\frac{\partial(\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta)}{\partial \beta} = -2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta).$$

### 14.5.2 Derivação das Equações Normais

Aplicando a derivada à função  $S(\beta)$  (Abadir; Magnus, 2005):

$$\nabla_\beta S(\beta) = -2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta).$$

Igualando o gradiente a zero:

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\beta}) = 0.$$

Reorganizando,

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{Y}.$$

Essas são as **equações normais**.

Se  $\mathbf{X}^\top \mathbf{X}$  é invertível, isto é, se as colunas de  $\mathbf{X}$  são linearmente independentes, obtém-se a solução única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

### 14.5.3 Interpretação Algébrica

A condição

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}) = 0$$

implica

$$\mathbf{X}^\top \hat{\boldsymbol{\epsilon}} = 0,$$

ou seja, o vetor residual é ortogonal a cada coluna de  $\mathbf{X}$ .

### 14.5.4 Interpretação Geométrica

A minimização de  $S(\boldsymbol{\beta})$  equivale a resolver

$$\min_{\mathbf{v} \in \text{col}(\mathbf{X})} \|\mathbf{Y} - \mathbf{v}\|^2.$$

Portanto,

$$\hat{\mathbf{Y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$$

é a projeção ortogonal de  $\mathbf{Y}$  sobre  $\text{col}(\mathbf{X})$ . Essa caracterização independe de qualquer hipótese probabilística.

## 14.6 Estrutura Matricial para Diagnóstico e Inferência

---

A formulação matricial do modelo linear não se limita à obtenção do estimador de mínimos quadrados. Ela estrutura integralmente os procedimentos de diagnóstico e prepara o terreno para a inferência estatística.

Recordemos a decomposição fundamental:

$$\mathbf{Y} = \mathbf{H}\mathbf{Y} + \mathbf{M}\mathbf{Y} = \hat{\mathbf{Y}} + \hat{\boldsymbol{\epsilon}}.$$

Essa identidade organiza o vetor de respostas em duas componentes ortogonais pertencentes a subespaços complementares.

### 14.6.1 Alavancagem e Estrutura da Matriz $\mathbf{H}$

A diagonal da matriz de projeção

$$h_{ii} = (\mathbf{H})_{ii}$$

mensura o quanto a  $i$ -ésima observação contribui estruturalmente para sua própria projeção.

Explicitamente,

$$h_{ii} = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i,$$

em que  $\mathbf{x}_i^\top$  é a  $i$ -ésima linha da matriz  $\mathbf{X}$ .

Propriedades fundamentais:

- $0 \leq h_{ii} \leq 1$ ;
- $\sum_{i=1}^n h_{ii} = p + 1$ ;
- observações com valores elevados de  $h_{ii}$  ocupam posições extremas no espaço das covariáveis.

## 14.6.2 Estrutura dos Resíduos

Os resíduos podem ser escritos como

$$\hat{\boldsymbol{\varepsilon}} = \mathbf{M}\mathbf{Y}.$$

Como  $\mathbf{M}$  é simétrica e idempotente,

$$\mathbf{M}^2 = \mathbf{M}, \quad \mathbf{M}^\top = \mathbf{M}.$$

Além disso,

$$\mathbf{X}^\top \hat{\boldsymbol{\varepsilon}} = \mathbf{0},$$

o que garante que os resíduos são ortogonais às colunas de  $\mathbf{X}$ .

Essa ortogonalidade fundamenta:

- a decomposição das somas de quadrados;
- a independência geométrica entre componentes ajustadas e residuais;
- a contagem de graus de liberdade.

## 14.6.3 Somas de Quadrados em Forma Matricial

A soma de quadrados total pode ser escrita como

$$\mathbf{Y}^\top \mathbf{Y}.$$

A soma de quadrados explicada pelo modelo é

$$\mathbf{Y}^\top \mathbf{H}\mathbf{Y}.$$

A soma de quadrados residual é

$$\mathbf{Y}^\top \mathbf{M}\mathbf{Y}.$$

Como  $\mathbf{H}$  e  $\mathbf{M}$  projetam sobre subespaços ortogonais,

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{H}\mathbf{Y} + \mathbf{Y}^\top \mathbf{M}\mathbf{Y}.$$

Essa identidade é puramente algébrica e independe de qualquer suposição probabilística.

## 14.6.4 Postos e Graus de Liberdade

Como visto anteriormente,

$$\text{tr}(\mathbf{H}) = p + 1, \quad \text{tr}(\mathbf{M}) = n - p - 1.$$

Para matrizes simétricas idempotentes, o traço coincide com o posto. Portanto:

- o subespaço ajustado tem dimensão  $p + 1$ ;
- o subespaço residual tem dimensão  $n - p - 1$ .

Essas dimensões serão reinterpretadas, no contexto probabilístico, como graus de liberdade associados às somas de quadrados.