

15 Distribuição Normal

Este apêndice tem um papel estrutural na fundamentação matemática dos modelos de regressão linear. A Distribuição Normal, especialmente em sua forma multivariada, fornece a base probabilística que torna possível derivar distribuições amostrais exatas para estimadores, contrastes lineares e estatísticas de teste em amostras finitas. Uma exposição formal e sistemática dessas propriedades pode ser encontrada em Anderson (2003) e Casella; Berger (2002).

A ideia central que deve acompanhar o leitor ao longo deste apêndice é a seguinte:

Em regressão, não estudamos variáveis isoladas, mas vetores aleatórios e suas transformações lineares e quadráticas.

Essa perspectiva vetorial não é apenas notacional. Ela altera profundamente a forma de pensar sobre variabilidade, dependência e inferência.

15.1 Distribuição Normal Univariada

Uma variável aleatória Y tem distribuição Normal univariada com média $\mu \in \mathbb{R}$ e variância $\sigma^2 > 0$ se sua função densidade (fpd) é

$$f(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right), \quad y \in \mathbb{R}.$$

Essa distribuição surge com frequência em modelagem estatística porque aparece como **distribuição limite** em muitos contextos, especialmente quando uma quantidade observada pode ser representada como a soma (ou média) de um grande número de contribuições aleatórias.

O **Teorema Central do Limite** estabelece que, sob condições adequadas, a soma devidamente padronizada de variáveis aleatórias independentes, ou fracamente dependentes, converge em distribuição para a Normal, independentemente da forma das distribuições individuais; essa fundamentação é essencialmente assintótica e aproximada, não constituindo uma identidade estrutural exata. Uma formulação rigorosa desse resultado pode ser consultada em Casella; Berger (2002).

No contexto de modelos de regressão, a suposição de Normalidade **não é obrigatória** nem define o modelo em si. Um modelo de regressão linear pode ser formulado sem qualquer hipótese distributiva explícita sobre o erro, bastando condições sobre esperança, variância e independência.

A Normalidade é frequentemente adotada porque constitui o **caso mais simples e matematicamente tratável**, permitindo obter distribuições exatas para estimadores, estatísticas de teste e intervalos de confiança em amostras finitas. Em outros contextos, distribuições alternativas podem ser mais adequadas, levando a extensões naturais da regressão linear, como os modelos lineares generalizados.

Os parâmetros da Normal univariada admitem interpretações diretas, mas é importante compreendê-las com precisão estatística.

O parâmetro μ representa o **valor esperado teórico** da variável aleatória Y , isto é, o ponto em torno do qual a distribuição se concentra em média. Trata-se de uma quantidade populacional, definida independentemente de qualquer amostra específica, e que resume a tendência central do fenômeno sob o modelo probabilístico adotado.

O parâmetro σ^2 representa a **variância populacional** da variável aleatória, quantificando a dispersão em torno de μ . Essa variabilidade reflete a incerteza inerente ao fenômeno modelado e não carrega, nesse estágio, qualquer interpretação ligada a explicação ou não explicação por covariáveis. Essa distinção só surgirá no contexto de modelos condicionais, como a regressão.

Essas interpretações ficam claras ao observarmos duas propriedades fundamentais da distribuição Normal:

- Esperança:

$$\mathbb{E}[Y] = \mu$$

- Variância:

$$\text{Var}(Y) = \sigma^2$$

Essas igualdades não são meras convenções, mas decorrem da integração direta da densidade.

Uma característica estrutural importante da Normal é sua estabilidade por transformações lineares. Se $Y \sim N(\mu, \sigma^2)$ e definimos

$$Z = aY + b,$$

com $a \neq 0$, então

$$Z \sim N(a\mu + b, a^2\sigma^2).$$

Essa propriedade, demonstrada em Casella; Berger (2002), é o primeiro indício da importância da Normal na regressão: combinações lineares preservam a forma distributiva.

Uma transformação particularmente importante, tanto do ponto de vista teórico quanto prático, é a **padronização**. Definindo

$$Z = \frac{Y - \mu}{\sigma},$$

obtem-se uma nova variável aleatória com distribuição

$$Z \sim N(0, 1),$$

conhecida como **Normal padrão**.

A padronização desempenha um papel central em inferência estatística porque remove as unidades de medida e a escala original da variável, permitindo comparar desvios em termos relativos. Em modelos de regressão, essa ideia reaparece de forma sistemática: estatísticas de teste, resíduos padronizados e intervalos de confiança são construídos a partir de quantidades que mensuram desvios em relação a uma média teórica, expressos em unidades de desvio-padrão.

Assim, compreender profundamente o significado de μ , σ^2 e da padronização é essencial para interpretar corretamente os resultados inferenciais que surgirão nos modelos de regressão.

15.2 Distribuição Normal Bivariada

Ao avançarmos para o caso bivariado, deixamos de estudar variáveis aleatórias isoladas e passamos a lidar explicitamente com **dependência entre variáveis aleatórias**. Esse é um passo conceitual fundamental, pois

modelos estatísticos mais complexos e abrangentes, incluindo os modelos de regressão, são construídos exatamente a partir de relações entre variáveis.

Considere o vetor aleatório

$$\mathbf{Y} = (Y_1, Y_2)^\top.$$

Dizemos que $\mathbf{Y}$ segue uma **Distribuição Normal bivariada** se

$$\mathbf{Y} \sim N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

onde o vetor de médias é dado por

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix},$$

e a matriz de covariância é

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix}.$$

Neste ponto ocorre uma mudança conceitual importante. Enquanto no caso univariado a variância era um único número, agora a **matriz** $\boldsymbol{\Sigma}$ passa a concentrar toda a informação sobre dispersão e dependência:

- os termos da diagonal (σ_1^2 e σ_2^2) descrevem a variabilidade individual de cada componente;
- os termos fora da diagonal descrevem a associação linear entre as variáveis, resumida pelo coeficiente de correlação ρ .

Assim, a estrutura de dependência entre Y_1 e Y_2 não é um elemento acessório, mas parte integrante da própria definição da distribuição conjunta.

A função densidade de probabilidade conjunta, como apresentado em Anderson (2003), pode ser escrita de forma compacta como

$$f(\mathbf{y}) = \frac{1}{2\pi|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right\}.$$

Essa expressão merece uma leitura cuidadosa. O termo que aparece no expoente,

$$(\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}),$$

é um escalar obtido a partir de vetores e matrizes, resultado de uma operação que combina transposição, multiplicação matricial e produto interno.

Neste momento, **não é necessário compreender formalmente esse termo como uma “forma quadrática”** essa noção será estudada com cuidado em um apêndice específico.

Intuitivamente, essa quantidade mede quão distante o vetor $\mathbf{y}$ está do centro $\boldsymbol{\mu}$, mas **não usando a distância euclidiana usual**. Em vez disso, a distância é avaliada levando em conta a estrutura de variabilidade e dependência entre as componentes do vetor, codificada na matriz de covariância $\boldsymbol{\Sigma}$.

Dessa forma, desvios ao longo de direções em que há maior variabilidade conjunta são penalizados de maneira diferente de desvios ao longo de direções com menor variabilidade. É essa ponderação que faz com que a distribuição apresente contornos elípticos, em vez de circulares.

A formalização matemática desse tipo de expressão, bem como seu papel central na regressão, nas somas de quadrados e nas estatísticas de teste, será apresentada posteriormente, quando estudarmos explicitamente as distribuições associadas a expressões desse tipo.

Geometricamente, isso se traduz no fato de que as curvas de mesma densidade dessa distribuição são **elipses centradas em μ** .

A forma, o tamanho e a orientação dessas elipses dependem diretamente de Σ :

- quando $\rho = 0$, as elipses são alinhadas com os eixos coordenados;
- quando $\rho \neq 0$, as elipses tornam-se inclinadas, refletindo a associação linear entre Y_1 e Y_2 .

Essa interpretação geométrica será essencial mais adiante, quando discutirmos **projeções, decomposições ortogonais e ajuste de modelos de regressão**, nos quais a ideia de “direções relevantes” no espaço dos dados desempenha papel central.

Mesmo nesse cenário conjunto, algumas propriedades permanecem familiares e ajudam a consolidar a intuição:

- As **distribuições marginais** continuam sendo Normais univariadas:

$$Y_1 \sim N(\mu_1, \sigma_1^2), \quad Y_2 \sim N(\mu_2, \sigma_2^2).$$

Essas marginais mostram que, marginalmente, cada componente do vetor se comporta como uma variável Normal comum, mas isso **não elimina** a possibilidade de dependência entre elas quando observadas conjuntamente.

- As **distribuições condicionais** também são Normais:

$$Y_1 | Y_2 = y_2 \sim N\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2} (y_2 - \mu_2), (1 - \rho^2) \sigma_1^2\right).$$

Aqui aparece uma ideia conceitualmente profunda e extremamente importante para o que virá depois: **a média condicional de uma variável Normal é uma função linear da variável condicionante**.

Essa linearidade não é um artifício do modelo, nem uma escolha conveniente; ela é uma consequência direta da estrutura da Normalidade conjunta. Em modelos de regressão, essa propriedade será reinterpretada como a relação entre a resposta e as covariáveis, agora formulada de maneira explícita e sistemática.

Portanto, compreender a Normal bivariada é compreender, em um cenário simples, a origem probabilística da ideia de regressão como relação média condicional.

15.3 Distribuição Normal Multivariada

No caso geral, consideramos um vetor aleatório

$$\mathbf{Y} \in \mathbb{R}^n,$$

que segue uma **Distribuição Normal multivariada** se

$$\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

onde $\boldsymbol{\mu}$ é o vetor de médias e $\boldsymbol{\Sigma}$ é a matriz de covariância, simétrica e definida positiva.

A função densidade associada é

$$f(\mathbf{y}) = \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}) \right\}.$$

Neste ponto, é importante fazer uma mudança consciente na forma de pensar. Não estamos mais lidando com observações isoladas, mas com **vetores aleatórios**, e a incerteza passa a ser descrita por **estruturas geométricas em espaços de dimensão maior**.

O vetor $\boldsymbol{\mu}$ representa o centro da distribuição no espaço $\mathbb{R}^n$, enquanto a matriz $\boldsymbol{\Sigma}$ determina como a variabilidade se organiza em torno desse centro. Mais especificamente, $\boldsymbol{\Sigma}$ define:

- direções ao longo das quais a variabilidade conjunta é maior;
- direções ao longo das quais a variabilidade conjunta é menor;
- dependências lineares entre as componentes do vetor.

Essas direções não precisam coincidir com os eixos coordenados originais, e essa observação será fundamental quando discutirmos projeções e decomposições em regressão múltipla.

A expressão que aparece no expoente da densidade envolve novamente uma quantidade do tipo

$$(\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}),$$

que produz um escalar a partir de vetores e matrizes. Assim como no caso bivariado, **não é necessário, neste momento, compreender formalmente essa expressão como uma forma quadrática**. Por ora, basta interpretar essa quantidade como uma medida de distância multivariada entre $\mathbf{y}$ e o centro $\boldsymbol{\mu}$, ajustada pela estrutura de covariância.

Essa forma de medir distância explica por que as regiões de maior densidade da Normal multivariada são elipsoides em $\mathbb{R}^n$, generalizando as elipses vistas no caso bivariado.

Algumas propriedades fundamentais seguem diretamente dessa definição e merecem ser destacadas, pois reaparecerão continuamente ao longo do estudo de modelos de regressão.

A esperança e a covariância do vetor aleatório são dadas por

$$\mathbb{E}[\mathbf{Y}] = \boldsymbol{\mu}, \quad \text{Cov}(\mathbf{Y}) = \boldsymbol{\Sigma}.$$

Essas expressões formalizam a interpretação de $\boldsymbol{\mu}$ como centro da distribuição e de $\boldsymbol{\Sigma}$ como descrição completa da variabilidade conjunta.

Uma propriedade absolutamente central da Normal multivariada é sua **estabilidade por transformações lineares**. Se tomarmos uma transformação do tipo

$$\mathbf{Z} = \mathbf{A}\mathbf{Y} + \mathbf{a},$$

então a variável transformada também segue uma distribuição Normal multivariada:

$$\mathbf{Z} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{a}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

Essa propriedade merece atenção especial. Ela afirma que **qualquer combinação linear de um vetor Normal multivariado continua sendo Normal**, independentemente da dimensão envolvida.

Esse resultado será a pedra angular da teoria de regressão linear. Quando estudarmos regressão, veremos que os estimadores dos coeficientes, os valores ajustados e diversos contrastes estatísticos são obtidos exatamente como transformações lineares do vetor de respostas. A Normalidade dessas quantidades decorre diretamente desta propriedade, e não de argumentos ad hoc.

Outra quantidade natural que surge no contexto da Normal multivariada é a chamada **distância de Mahalanobis**:

$$Q = (\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu}),$$

para o qual vale

$$Q \sim \chi_n^2.$$

Mais uma vez, não é necessário aprofundar formalmente esse resultado neste momento. Conceitualmente, ele afirma que a distância multivariada entre $\mathbf{Y}$ e seu centro, quando devidamente padronizada pela matriz de covariância, possui uma distribuição conhecida.

Esse fato será explorado de forma sistemática em regressão, onde somas de quadrados, estatísticas de teste e medidas de ajuste surgirão como casos particulares desse tipo de expressão.

Assim, a Distribuição Normal multivariada fornece não apenas um modelo probabilístico para vetores de dados, mas também a base matemática para compreender por que as quantidades centrais da regressão admitem distribuições explícitas e interpretáveis.

15.4 Partição da Normal Multivariada

Um dos recursos mais poderosos da Normal multivariada é a possibilidade de **particionar o vetor aleatório** em blocos menores e ainda assim manter uma descrição probabilística completa e explícita.

Considere o vetor aleatório particionado como

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_n \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right).$$

Aqui, a partição é puramente conceitual: estamos apenas reorganizando o vetor em dois blocos, sem alterar o modelo probabilístico subjacente. Ainda assim, essa simples reorganização permite responder a perguntas fundamentais sobre o comportamento do vetor aleatório.

Em particular, ela nos permite distinguir claramente dois tipos de informação:

- **comportamento marginal**, isto é, como cada bloco se distribui quando considerado isoladamente;
- **comportamento condicional**, isto é, como um bloco se distribui quando o outro é observado.

As distribuições marginais seguem diretamente da definição da Normal multivariada:

$$\mathbf{Y}_1 \sim N_{n_1}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11}), \quad \mathbf{Y}_2 \sim N_{n_2}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22}).$$

Essas expressões mostram que, ao “olharmos apenas para uma parte do vetor”, o comportamento probabilístico dessa parte continua sendo Normal, com média e covariância correspondentes aos blocos apropriados de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ (Anderson, 2003; Casella; Berger, 2002). No entanto, essa visão marginal ignora completamente a dependência entre os blocos.

A riqueza da Normal multivariada aparece de forma ainda mais clara ao analisarmos o comportamento **condicional**. A distribuição de $\mathbf{Y}_1$ dado que $\mathbf{Y}_2 = \mathbf{y}_2$ é

$$\mathbf{Y}_1 \mid \mathbf{Y}_2 = \mathbf{y}_2 \sim N_{n_1}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{y}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$

Essa expressão concentra vários conceitos importantes em um único resultado.

Primeiro, observe que a **média condicional** de $\mathbf{Y}_1$ não é simplesmente $\boldsymbol{\mu}_1$. Ela é ajustada pelo termo

$$\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{y}_2 - \boldsymbol{\mu}_2),$$

que incorpora a informação trazida pela observação de $\mathbf{Y}_2$. Esse ajuste depende exclusivamente da estrutura de covariância entre os blocos, e não de escolhas arbitrárias de modelagem.

Segundo, note que a **matriz de covariância condicional**

$$\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$$

é sempre menor, no sentido de variância, do que a covariância marginal $\boldsymbol{\Sigma}_{11}$. Isso formaliza matematicamente uma ideia intuitiva: **ao observar parte do vetor, reduzimos a incerteza sobre o restante**.

Esse resultado mostra que, na Normal multivariada, o condicionamento produz dois efeitos simultâneos e bem definidos:

- a média é deslocada de forma linear em função da parte observada;
- a variabilidade é reduzida de maneira controlada pela estrutura de dependência.

Essas duas propriedades; linearidade da média condicional e redução da variância, não são hipóteses adicionais nem aproximações, elas são consequências diretas da Normalidade conjunta.

Embora ainda não estejamos estudando modelos de regressão, é importante registrar que essa lógica será reinterpretada mais adiante quando os coeficientes de um modelo passarem a ser entendidos como **efeitos condicionais**, isto é, como variações esperadas em uma componente do vetor quando outras são mantidas fixas.

Assim, a partição da Normal multivariada fornece o arcabouço probabilístico que sustenta a noção de regressão como estudo de relações condicionais, mesmo antes de qualquer equação de regressão ser escrita explicitamente.

15.5 Covariância zero implica independência

Em geral, para vetores aleatórios arbitrários, a condição de covariância nula **não implica independência**. Isto é, pode ocorrer que duas variáveis tenham covariância igual a zero e, ainda assim, sejam dependentes.

Entretanto, a família Normal possui uma propriedade estrutural especial:

Se um vetor aleatório é Normal multivariado, então quaisquer componentes (ou combinações lineares de componentes) que tenham covariância zero são independentes.

Mais precisamente, se

$$\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

e $\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$, então

$$\text{Cov}(\mathbf{a}^\top \mathbf{Y}, \mathbf{b}^\top \mathbf{Y}) = 0 \implies \mathbf{a}^\top \mathbf{Y} \text{ e } \mathbf{b}^\top \mathbf{Y} \text{ são independentes.}$$

Essa propriedade é específica da distribuição Normal e não vale em geral para outras distribuições multivariadas. Uma demonstração pode ser encontrada em Anderson (2003) e em Casella; Berger (2002).

Essa característica será essencial na regressão linear, pois permite concluir, sob Normalidade dos erros, que:

- o estimador dos coeficientes é independente do vetor de resíduos;
- diferentes somas de quadrados associadas a projeções ortogonais são independentes;
- estatísticas baseadas em decomposições ortogonais possuem distribuições independentes.

A independência decorre da ortogonalidade geométrica no espaço das observações, combinada com a estrutura da Normal multivariada.

15.5.1 Independência no caso bivariado

No caso particular bivariado, seja

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \sim N_2(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

com

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

Então vale a equivalência:

$$\rho = 0 \iff Y_1 \text{ e } Y_2 \text{ são independentes.}$$

Essa equivalência é uma consequência direta da forma explícita da densidade conjunta e constitui uma propriedade distintiva da Normal bivariada. Em distribuições gerais, correlação zero não implica independência.

15.5.2 Caso marginal

Se

$$\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

então qualquer subconjunto de componentes de $\mathbf{Y}$ também possui distribuição Normal multivariada.

Formalmente, se particionarmos

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix},$$

então as distribuições marginais são

$$\mathbf{Y}_1 \sim N_{n_1}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11}), \quad \mathbf{Y}_2 \sim N_{n_2}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22}).$$

Essa estabilidade marginal é consequência direta da definição da Normal multivariada e pode ser verificada integrando-se a densidade conjunta ou utilizando o resultado de que combinações lineares preservam Normalidade.

15.5.3 Partições e Independência entre Blocos

Considere novamente a partição

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_n\left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}\right).$$

Então:

$$\boldsymbol{\Sigma}_{12} = \mathbf{0} \iff \mathbf{Y}_1 \text{ e } \mathbf{Y}_2 \text{ são independentes.}$$

Isto é, na Normal multivariada, blocos são independentes se, e somente se, sua matriz de covariância cruzada for nula.

Essa propriedade tem papel central na teoria da regressão linear clássica. Quando se demonstra que duas quantidades são obtidas por projeções ortogonais e que a matriz de covariância cruzada entre elas é nula, a Normalidade garante automaticamente independência.

Essa combinação entre:

- ortogonalidade algébrica,
- covariância nula,
- estrutura Normal,

é o mecanismo matemático que sustenta a independência entre soma de quadrados do modelo e soma de quadrados do erro, fundamento da estatística F .

15.6 Papel da Distribuição Normal na fundamentação dos modelos de regressão

Os resultados apresentados neste apêndice fornecem uma base probabilística razoável para a formulação e a análise dos modelos clássicos de regressão linear. O objetivo aqui é explicitar as estruturas matemáticas que a tornam analisável de forma rigorosa.

Em modelos de regressão linear com erros normalmente distribuídos, considera-se que o vetor de respostas pode ser escrito como

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n),$$

o que implica diretamente que

$$\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

como discutido em Kutner et al. (2005). Essa especificação não define o modelo de regressão em si, que pode ser formulado sob hipóteses mais gerais, mas estabelece um **caso fundamental** no qual resultados exatos de inferência podem ser obtidos em amostras finitas.

A partir dessa estrutura probabilística decorrem, de forma sistemática, várias propriedades centrais da regressão linear clássica:

- os estimadores dos coeficientes surgem como **transformações lineares** do vetor aleatório $\mathbf{Y}$;
- os resíduos e as somas de quadrados associadas ao ajuste do modelo surgem como **expressões quadráticas** em $\mathbf{Y}$;
- as distribuições amostrais das estatísticas utilizadas para inferência são obtidas a partir das distribuições dessas transformações lineares e quadráticas.

Deste modo, estatísticas do tipo t e F não são introduzidas de maneira ad hoc, mas emergem naturalmente da combinação entre a Normal multivariada e as operações algébricas realizadas sobre o vetor de respostas.

Outros apêndices exploram explicitamente essas estruturas, estudando as distribuições associadas a transformações lineares e quadráticas de vetores aleatórios conjuntamente normais. Esse desenvolvimento

permitirá compreender, de forma unificada, a origem das principais ferramentas inferenciais utilizadas em modelos de regressão linear.