

16 Formas Lineares e Quadráticas na Normal Multivariada

Em regressão linear clássica, muitos estimadores e estatísticas fundamentais são **formas lineares** e **formas quadráticas** de um vetor aleatório Normal multivariado. Essa conexão não é meramente técnica: ela é estrutural e explica por que distribuições exatas em amostras finitas podem ser obtidas sob normalidade. A fundamentação matricial e geométrica desses resultados pode ser encontrada, em diferentes níveis de formalidade ([Anderson, 2003](#); [Harville, 2000](#)).

16.1 Preliminares: Normal multivariada e transformações lineares

Seja

$$\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

com $\boldsymbol{\Sigma}$ simétrica definida positiva.

Uma propriedade central da Normal multivariada é sua **estabilidade por transformações lineares**: se $\mathbf{A}$ é uma matriz fixa $m \times n$ e $\mathbf{a} \in \mathbb{R}^m$, então

$$\mathbf{Z} = \mathbf{A}\mathbf{Y} + \mathbf{a} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{a}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

Esse resultado é apresentado de forma sistemática em Anderson ([2003](#)) e constitui a base probabilística da teoria da regressão linear.

Como caso particular, para um vetor fixo $\mathbf{c} \in \mathbb{R}^n$,

$$L = \mathbf{c}^\top \mathbf{Y} \sim N(\mathbf{c}^\top \boldsymbol{\mu}, \mathbf{c}^\top \boldsymbol{\Sigma} \mathbf{c}).$$

A dedução segue diretamente da propriedade anterior e também pode ser vista como aplicação do fato de que combinações lineares de vetores Normais permanecem Normais, como discutido em Casella; Berger ([2002](#)).

Essa estrutura será aplicada diretamente a:

- $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$;
- contrastes $\mathbf{C}\hat{\boldsymbol{\beta}}$;
- previsões lineares e combinações de coeficientes.

16.2 Padronização multivariada e redução ao caso I

Para estudar formas quadráticas, é útil reduzir o problema ao caso esférico.

Como $\boldsymbol{\Sigma}$ é definida positiva, existe uma matriz simétrica definida positiva $\boldsymbol{\Sigma}^{1/2}$ tal que

$$\boldsymbol{\Sigma}^{1/2} \boldsymbol{\Sigma}^{1/2} = \boldsymbol{\Sigma}, \quad (\boldsymbol{\Sigma}^{1/2})^{-1} = \boldsymbol{\Sigma}^{-1/2}.$$

A existência dessa raiz quadrada decorre da decomposição espectral de matrizes simétricas definidas positivas, tratada em detalhe em Harville ([2000](#)).

Defina

$$\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{Y} - \boldsymbol{\mu}).$$

Então

$$\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n).$$

Essa transformação separa de maneira conceitualmente limpa os papéis de média e dispersão, reduzindo a análise probabilística ao caso esférico. Além disso, ela mostra que a chamada distância de Mahalanobis

$$(\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu})$$

é simplesmente a norma euclidiana ao quadrado de um vetor Normal padrão:

$$(\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu}) = \mathbf{Z}^\top \mathbf{Z}.$$

Essa ponte entre geometria (normas e projeções) e distribuição (Qui-quadrado) é central na teoria da inferência sob normalidade.

16.3 Forma linear: distribuição, interpretação e conexão com regressão

Uma **forma linear** de um vetor aleatório é uma expressão do tipo

$$L = \mathbf{c}^\top \mathbf{Y},$$

onde $\mathbf{c}$ é fixo.

Se $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então:

- L é Normal;
- $\mathbb{E}(L) = \mathbf{c}^\top \boldsymbol{\mu}$;
- $\text{Var}(L) = \mathbf{c}^\top \boldsymbol{\Sigma} \mathbf{c}$.

Na regressão linear, quando se assume normalidade dos erros, tanto $\hat{\boldsymbol{\beta}}$ quanto qualquer contraste $\mathbf{C}\hat{\boldsymbol{\beta}}$ são formas lineares em $\mathbf{Y}$. Por isso, possuem distribuição Normal exata em amostras finitas.

16.4 Forma quadrática: definição e interpretação

Uma **forma quadrática** em $\mathbf{Y}$ é uma expressão do tipo

$$Q = \mathbf{Y}^\top \mathbf{A} \mathbf{Y},$$

onde $\mathbf{A}$ é uma matriz fixa $n \times n$.

Primeira observação fundamental: apenas a parte simétrica de $\mathbf{A}$ influencia Q . De fato,

$$\mathbf{Y}^\top \mathbf{A} \mathbf{Y} = \mathbf{Y}^\top \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right) \mathbf{Y}.$$

Logo, pode-se assumir $\mathbf{A}$ simétrica sem perda de generalidade, fato discutido na literatura matricial estatística como em Harville (2000).

Em regressão, as somas de quadrados são precisamente formas quadráticas:

$$\text{SQReg} = \mathbf{Y}^\top \mathbf{H} \mathbf{Y}, \quad \text{SQRes} = \mathbf{Y}^\top \mathbf{M} \mathbf{Y}.$$

O comportamento probabilístico de Q depende criticamente das propriedades estruturais de $\mathbf{A}$. Quando $\mathbf{A}$ é uma projeção ortogonal (simétrica e idempotente), a forma quadrática se reduz a uma soma de quadrados de componentes Normais padrão em um subespaço.

16.5 O caso central: $\mathbf{Z}^\top \mathbf{Z}$ e a distribuição χ^2

Se $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$, então suas componentes são independentes e

$$Z_i \sim N(0, 1).$$

Consequentemente,

$$\mathbf{Z}^\top \mathbf{Z} = \sum_{i=1}^n Z_i^2 \sim \chi_n^2.$$

Esse resultado é a base de todas as somas de quadrados na regressão sob normalidade, como apresentado em textos de inferência como Casella; Berger (2002).

16.6 Projeções ortogonais e Qui-quadrado

Seja $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$ e seja $\mathbf{A}$ simétrica e idempotente:

$$\mathbf{A}^\top = \mathbf{A}, \quad \mathbf{A}^2 = \mathbf{A}.$$

Se $r = \text{rank}(\mathbf{A}) = \text{tr}(\mathbf{A})$, então

$$\mathbf{Z}^\top \mathbf{A} \mathbf{Z} \sim \chi_r^2.$$

Esse resultado pode ser deduzido via decomposição espectral de $\mathbf{A}$ e é tratado com rigor em Harville (2000) e Rencher; Christensen (2012).

Geometricamente, $\mathbf{A}$ projeta sobre um subespaço S de dimensão r . Assim, $\mathbf{Z}^\top \mathbf{A} \mathbf{Z}$ mede o comprimento ao quadrado da componente projetada de $\mathbf{Z}$ em S , que se comporta como soma de quadrados de r Normais padrão.

Esse resultado aplica-se diretamente às matrizes $\mathbf{H}$ (posto $p + 1$) e $\mathbf{M}$ (posto $n - p - 1$). Quando $\mathbf{Z}$ representa a versão padronizada do vetor de erros, as somas de quadrados do modelo e do resíduo assumem distribuições Qui-quadrado com graus de liberdade dados por esses postos.

16.7 Independência via ortogonalidade

Se $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}, \mathbf{B}$ são simétricas idempotentes tais que

$$\mathbf{AB} = \mathbf{0},$$

então

$$\mathbf{Z}^\top \mathbf{A} \mathbf{Z} \perp \mathbf{Z}^\top \mathbf{B} \mathbf{Z}.$$

A independência decorre da decomposição ortogonal do espaço combinada com a simetria esférica da Normal padrão.

Critério análogo vale para independência entre forma linear $L = \mathbf{a}^\top \mathbf{Z}$ e forma quadrática $Q = \mathbf{Z}^\top \mathbf{A} \mathbf{Z}$: se

$$\mathbf{A}\mathbf{a} = \mathbf{0},$$

então L e Q são independentes.

16.8 MRLM Normal

Considere o modelo de regressão linear múltipla sob normalidade e homocedasticidade:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

Como consequência direta da estabilidade da Normal multivariada por transformações lineares, tem-se

$$\mathbf{Y} \sim N_n(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n).$$

As quantidades centrais do modelo podem ser classificadas estruturalmente da seguinte forma, destacando-se suas distribuições quando há uma forma conhecida.

16.8.1 Estimador como forma linear em $\mathbf{Y}$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

Trata-se de uma transformação linear do vetor aleatório $\mathbf{Y}$. Logo,

$$\hat{\boldsymbol{\beta}} \sim N_{p+1}(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}).$$

Em particular, para cada componente $\hat{\beta}_j$,

$$\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}} \sim N(0, 1).$$

16.8.2 Resíduos como transformação linear

$$\hat{\boldsymbol{\epsilon}} = \mathbf{M}\mathbf{Y}, \quad \mathbf{M} = \mathbf{I}_n - \mathbf{H}.$$

Como $\hat{\boldsymbol{\epsilon}}$ é transformação linear de um vetor Normal multivariado, segue que

$$\hat{\boldsymbol{\epsilon}} \sim N_n(\mathbf{M}\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{M}).$$

Como $\mathbf{M}\mathbf{X} = \mathbf{0}$, obtém-se

$$\hat{\boldsymbol{\epsilon}} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{M}).$$

Assim, os resíduos possuem estrutura Normal degenerada em um subespaço de dimensão $n - p - 1$.

16.8.3 Soma de quadrados residual como forma quadrática

$$\text{SQRes} = \hat{\boldsymbol{\epsilon}}^\top \hat{\boldsymbol{\epsilon}} = \mathbf{Y}^\top \mathbf{M}\mathbf{Y}.$$

Como $\mathbf{M}$ é simétrica idempotente com

$$\text{rank}(\mathbf{M}) = n - p - 1,$$

segue que, após padronização por σ^2 ,

$$\frac{\text{SQRes}}{\sigma^2} = \frac{\mathbf{Y}^\top \mathbf{M} \mathbf{Y}}{\sigma^2} \sim \chi^2_{n-p-1}.$$

Equivalentemente,

$$\text{SQRes} \sim \sigma^2 \chi^2_{n-p-1}.$$

Além disso, definindo

$$\hat{\sigma}^2 = \frac{\text{SQRes}}{n-p-1},$$

tem-se

$$\frac{(n-p-1)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-p-1}.$$

16.8.4 Decomposição ortogonal da soma de quadrados total

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{H} \mathbf{Y} + \mathbf{Y}^\top \mathbf{M} \mathbf{Y}.$$

Sob o modelo Normal, após padronização por σ^2 , as duas parcelas tornam-se formas quadráticas associadas a projeções ortogonais complementares.

Escrevendo $\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$, obtém-se:

- **Parte ajustada (forma quadrática não-central)**

$$\frac{\mathbf{Y}^\top \mathbf{H} \mathbf{Y}}{\sigma^2} \sim \chi^2_{p+1}(\lambda), \quad \lambda = \frac{\boldsymbol{\mu}^\top \boldsymbol{\mu}}{\sigma^2}.$$

- **Parte residual (forma quadrática central)**

$$\frac{\mathbf{Y}^\top \mathbf{M} \mathbf{Y}}{\sigma^2} \sim \chi^2_{n-p-1}.$$

Como $\mathbf{H}\mathbf{M} = \mathbf{0}$ e ambas são projeções ortogonais, essas duas formas quadráticas são independentes:

$$\frac{\mathbf{Y}^\top \mathbf{H} \mathbf{Y}}{\sigma^2} \perp \frac{\mathbf{Y}^\top \mathbf{M} \mathbf{Y}}{\sigma^2}.$$

16.8.5 Surgimento das distribuições t e F

A partir dessas distribuições, emergem naturalmente as estatísticas de inferência.

Para cada coeficiente,

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}} = \frac{\frac{\hat{\beta}_j - \beta_j}{\sigma \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}}}{\sqrt{\frac{\text{SQRes}/\sigma^2}{n-p-1}}} \sim t_{n-p-1}.$$

A estatística t surge como razão entre uma Normal padrão e a raiz de uma Qui-quadrado independente dividida por seus graus de liberdade.

De modo análogo, a estatística global de significância do modelo pode ser escrita como

$$F = \frac{(\mathbf{Y}^\top \mathbf{H} \mathbf{Y}) / (p + 1)}{(\mathbf{Y}^\top \mathbf{M} \mathbf{Y}) / (n - p - 1)} \sim F_{p+1, n-p-1},$$

no caso central sob a hipótese nula apropriada.

Assim, as distribuições t e F não são introduzidas ad hoc: elas emergem diretamente da estrutura geométrica das projeções ortogonais combinada com a Normalidade multivariada do vetor de respostas.