

17 Tratamento de dados para regressão

Este apêndice organiza, em forma de roteiro estruturado, os procedimentos que devem ser realizados **antes** do ajuste de qualquer modelo de regressão. O objetivo é preparar bases de dados tabulares (em que linhas representam observações e colunas representam variáveis) para que estejam **coerentes, consistentes, completas e adequadas à modelagem estatística**.

Os métodos de regressão (lineares, generalizados ou penalizados) **pressupõem** que a variabilidade observada nos dados represente o fenômeno real sob estudo, e não erros de registro, inconsistências de escala ou problemas de codificação. O tratamento pré-modelagem constitui, portanto, o **primeiro passo do raciocínio estatístico aplicado**: garantir que o modelo descreva o mundo observado e não artefatos do processo de coleta ou organização dos dados.

Princípios norteadores da preparação de dados

1. **Parcimônia**: trate o necessário, não o possível. Cada transformação modifica o significado estatístico das variáveis e pode alterar a interpretação dos resultados.
2. **Transparência**: todo procedimento deve ser reproduzível e documentado (log de alterações + dicionário de variáveis).
3. **Consistência**: mantenha coerência entre bases, períodos e versões (nomes de variáveis, unidades de medida, tipos e categorias).
4. **Domínio do contexto**: conheça o fenômeno estudado antes de decidir se determinado valor é erro, exceção legítima ou padrão relevante.
5. **Validação cruzada**: confirme decisões de tratamento por mais de uma ótica — estatística e substantiva. (Iannone, 2024)

Ferramentas e escopo

- Trabalharemos com **R** (por exemplo, utilizando `tidyverse` ou `data.table`) e com **dados estruturados em formato tabular**.
- **Não** abordaremos, neste apêndice, dados não estruturados ou semi-estruturados (texto livre, JSON heterogêneo, imagens, áudio ou bases documentais).
- Quando utilizarmos expressões como “detectar”, “verificar” ou “avaliar”, estaremos nos referindo a **operações descritivas e exploratórias**, sem ajuste formal de modelos nesta etapa.

Fluxo geral do processo analítico

coleta → organização → tratamento → **(entregável: base tratada + dicionário + log de decisões)** → modelagem → diagnóstico → interpretação

O tratamento de dados é, portanto, uma etapa intermediária e estruturante, que conecta a coleta bruta à modelagem estatística.

17.1 Exemplos do dia a dia e Checklist rápido

Exemplos rápidos do dia a dia

- **CSV que não abre “corretamente”**: o arquivo foi salvo com `;` em vez de `,` como separador, e o decimal usa `,` (ex.: `3,14`). Resultado: números são interpretados como texto.

- Tratamento:** especificar corretamente o delimitador e o símbolo decimal na leitura; padronizar separadores.
- **Acentos e caracteres estranhos:** colunas aparecem como ação, aÃ§Ã£o ou nomes quebrados.
Tratamento: ajustar o encoding (ex.: UTF-8 vs latin-1) e padronizar nomes de variáveis.
- **Tipos incorretos:** idades lidas como texto ("21"), datas como strings ("2025-10-24") e variáveis 0/1 lidas como numéricas quando deveriam ser categóricas. **Tratamento:** converter explicitamente para os tipos adequados (numérico, data/hora, fator) e validar o resultado.
- **Códigos de “faltante” disfarçados:** valores como 999, -1, NA, "" representam ausência, mas estão misturados com dados válidos. (Wickham et al., 2024)
Tratamento: recodificar para ausentes padronizados e decidir entre excluir, imputar ou manter com justificativa.
- **Duplicatas e chaves quebradas:** a mesma unidade amostral aparece repetida; totais e médias ficam incorretos.
Tratamento: identificar chaves únicas, remover ou conciliar duplicatas e documentar a decisão.
- **Categorias inconsistentes:** Masculino, M, masc e male aparecem como níveis distintos.
Tratamento: unificar rótulos, definir categoria de referência substantiva e gerar dummies adequadamente.
- **Datas em formatos mistos:** 31/12/2025 e 12-31-2025 na mesma coluna.
Tratamento: normalizar formato, verificar timezone quando relevante e extrair componentes (ano/mês/dia) se necessário.
- **Valores impossíveis:** altura = -5, proporção > 1, idade = 300.
Tratamento: definir faixas válidas segundo o domínio e corrigir ou descartar observações inconsistentes.
- **Escalas heterogêneas:** receita em reais e custo em milhares de reais; área em m² e km².
Tratamento: padronizar unidades ou aplicar reescala/padronização (ex.: z-score).
- **Outliers evidentes:** uma observação muito superior às demais; zero estrutural inesperado.
Tratamento: verificar plausibilidade no contexto, decidir entre correção, winsorização, transformação ou manutenção justificada.
- **Resposta incompatível com o objetivo:** deseja-se regressão linear contínua, mas a variável resposta é binária ou contagem.
Tratamento: verificar se o tipo de resposta é compatível com o modelo pretendido (linear, logístico, Poisson etc.).

Observe que, assim como a cozinha precisa estar organizada para a receita “dar certo”, a base precisa estar **coerente, completa e padronizada** para que a modelagem produza resultados interpretáveis e estatisticamente válidos.

Checklist rápido: Faça antes de modelar

1. **Defina o objetivo e o tipo de resposta:** contínua, binária ou contagem; confirme que a variável resposta é compatível com o modelo pretendido.
2. **Garanta leitura correta:** verifique separador, encoding e símbolo decimal; confirme que variáveis numéricas não foram importadas como texto.
3. **Acerte tipos e unidades:** converta datas, inteiros e reais; padronize unidades e nomes de variáveis.
4. **Mapeie e trate dados faltantes:** identifique NA, vazios e códigos artificiais (ex.: 999); decida entre excluir, imputar ou manter com justificativa. (Wickham et al., 2024)
5. **Elimine inconsistências:** remova ou una duplicatas, valide chaves, corrija valores impossíveis.

6. **Cuide de outliers:** identifique pontos extremos; corrija, transforme ou mantenha. Todas as ações com outliers devem ser realizadas com justificativa documentada.
7. **Codifique variáveis qualitativas:** unifique rótulos, defina categoria de referência e evite colinearidade perfeita na matriz de projeto.
8. **Cheque condições mínimas para regressão:**
 - Variabilidade das covariáveis;
 - Ausência de colinearidade perfeita ($X^T X$ não singular);
 - Número de observações maior que o número de parâmetros ($n > p + 1$);
 - Gere sumários e gráficos básicos;
 - **Salve a versão tratada com dicionário de variáveis e log de decisões.**

Cartões de decisão

- **Faltantes:**

Qual a proporção? A variável é essencial? Qual o mecanismo provável (MCAR/MAR/MNAR)? (Little; Rubin, 2019)
→ excluir / imputar (média, mediana, por grupo, métodos múltiplos) / manter com justificativa. (Buuren; Groothuis-Oudshoorn, 2024; Kuhn et al., 2024)

- **Outliers:**

Erro de digitação ou unidade? Valor plausível no domínio?
→ corrigir / winsorizar / transformar / manter e justificar.

- **Catagóricas:**

Existem níveis raros (alta cardinalidade)?
→ agrupar em “outros”; escolher referência substantiva; padronizar rótulos.

- **Escalas:**

Magnitudes muito diferentes entre covariáveis?
→ aplicar padronização (z-score) ou reescala; revisar unidades.

- **Reprodutibilidade:**

Toda decisão foi registrada no **log de tratamento**?

##Leitura e organização dos dados

Ler corretamente um arquivo de dados (formato, delimitador, encoding, símbolo decimal) é a primeira barreira contra erros que podem comprometer toda a análise. Uma leitura incorreta pode fazer com que números sejam interpretados como texto, datas como caracteres ou colunas inteiras sejam deslocadas. Esses problemas, se não detectados no início, propagam-se até a modelagem e podem invalidar inferências.

Em regressão, erros de tipagem e leitura afetam diretamente a construção da matriz de projeto X e da variável resposta y . Portanto, esta etapa é estrutural, não meramente operacional.

Conexões com a literatura e boas práticas

Autores como Charnet et al. (2008) e Sheather (2009) enfatizam que a qualidade dos dados influencia diretamente as estimativas, testes e intervalos de confiança. Essa etapa integra o que se denomina **análise exploratória de dados (AED)**: conhecer o material empírico antes de ajustar qualquer modelo.

Explorar não é modelar, é compreender a estrutura do dado.

Funções úteis no R

Pacotes e funções frequentemente utilizados nessa etapa incluem:

- `readr`: `read_csv()`, `read_delim()`, `guess_encoding()`, `locale()`
- `readxl`: `read_excel()`
- `dplyr`: `glimpse()`, `summarise()`, `count()`
- `fs` e `here`: organização de diretórios e caminhos reproduzíveis
- `vroom`: leitura rápida de arquivos grandes
- `stringi`: diagnóstico e conversão de encoding

O objetivo não é “usar funções”, mas garantir que a base esteja corretamente interpretada pelo R antes de qualquer transformação.

O que fazer

- Mapear a **origem dos dados** (site, repositório, disciplina, experimento) e sua **licença de uso**.
- Conferir o **formato do arquivo** (CSV, XLSX, SAV, DTA etc.) e o **delimitador** utilizado (, , ; , tabulação).
- Ajustar corretamente o **encoding** (UTF-8, latin-1) e o **símbolo decimal** (, ou .).
- Definir um **esquema de pastas do projeto** (por exemplo: `dados_brutos/`, `dados_interinos/`, `dados_tratados/`) e convenções padronizadas de nomes.

Boas práticas

- Manter a pasta `dados_brutos/` **imutável**. Nunca sobrescrever dados originais.
- Realizar todas as modificações em cópias armazenadas em `dados_tratados/`.
- Padronizar nomes de colunas: minúsculas, sem acento, em formato `snake_case`.
- Criar um arquivo `README_dados.md` com:
 - Fonte dos dados
 - Data de download
 - Responsável
 - Descrição geral das variáveis

Erros comuns (e como evitar)

- Arquivo CSV com ; como separador lido como se fosse , → verificar explicitamente o delimitador.
- Valores como 1,23 interpretados como texto → ajustar `locale(decimal_mark = ",")` ou converter adequadamente.
- Datas ambíguas (ex.: 01/02/2020) → padronizar formato (preferencialmente ISO 8601: 2020-02-01).
- Colunas numéricas importadas como `character` → converter explicitamente e validar.

Checklist rápido

Antes de seguir para qualquer transformação ou modelagem, verifique:

- ☐ Colunas numéricas estão realmente no tipo numérico?
- ☐ Datas foram reconhecidas como datas?
- ☐ Há duplicatas segundo a chave da base?
- ☐ Nomes de colunas estão padronizados?
- ☐ A leitura preservou o número esperado de linhas e colunas?

Se qualquer resposta for negativa, o tratamento ainda não começou e a leitura ainda não terminou.

17.2 Estrutura e tipagem das variáveis

A estrutura e o tipo das variáveis determinam como a matriz de projeto $\mathbf{X}$ será construída. Uma tipagem incorreta não é apenas um erro técnico: ela altera o significado estatístico do modelo, pode introduzir colinearidade artificial e comprometer estimativas, testes e interpretações.

De acordo com Sheather (2009), a correta identificação do tipo de cada variável é condição essencial para que o modelo represente adequadamente a relação entre preditores e resposta. Uma variável categórica tratada como numérica impõe uma estrutura inexistente; uma variável numérica tratada como categórica multiplica desnecessariamente parâmetros.

Em regressão, a tipagem define como cada coluna entra em $\mathbf{X}$: como valor contínuo, como conjunto de dummies ou como transformação temporal.

Ferramentas R úteis

Funções base do R:

- `str()` — inspeciona a estrutura da base
- `class()` — verifica o tipo de objeto
- `as.numeric()`, `as.integer()` — conversões numéricas
- `as.Date()` — conversão de datas

Pacotes auxiliares:

- `lubridate`: `ymd()`, `dmy()`, `ymd_hms()`
- `dplyr`: `mutate()`, `across()`
- `forcats`: manipulação de fatores

Para validação: - `is.na()` — valores ausentes

- `is.finite()` — valores numéricos válidos

- Verificações de faixa (ex.: idade ≥ 0)

O objetivo não é apenas converter, mas **verificar se a conversão preserva o significado substantivo da variável**.

Classifique as variáveis

Antes de qualquer modelagem, identifique claramente:

- Numéricas **contínuas** (salário, temperatura, peso)
- Numéricas **discretas** (número de visitas, contagem de eventos)
- **Binárias** (0/1, sim/não)
- **Categóricas nominais** (sexo, região)
- **Categóricas ordinais** (baixo, médio, alto)
- **Temporais** (datas, horários)
- **Identificadores (IDs)** que não devem entrar como preditores numéricos

Identificadores numéricos (ex.: matrícula, CPF, código do lote) **não são variáveis quantitativas** e não devem ser tratados como tal na regressão.

Ajustes típicos

- Converter strings numéricas para número de forma explícita.
- Converter datas para classe apropriada e, quando necessário, extrair componentes (ano, mês).
- Transformar variáveis 0/1 em fator quando a interpretação for categórica.

- Definir fatores com níveis claros e ordenados quando houver estrutura ordinal.
- Padronizar rótulos inconsistentes (ex.: `M`, `Masculino`, `male` → um único padrão).

Após os ajustes, reavalie a estrutura da base e confirme que cada coluna está no tipo esperado antes de avançar para o tratamento de faltantes ou criação de dummies.

17.3 Tratamento de dados faltantes (missing)

Dados faltantes alteram o tamanho efetivo da amostra, modificam a estrutura da matriz de projeto $\mathbf{X}$ e podem introduzir viés nas estimativas quando o mecanismo de ausência não é completamente aleatório (MCAR). Em regressão, a presença de faltantes pode funcionar como um **mecanismo implícito de seleção amostral**, afetando tanto a estimação quanto a interpretação dos coeficientes.

Excluir observações com valores ausentes equivale, muitas vezes, a analisar uma subamostra potencialmente não representativa.

Erros clássicos

- Imputar zero indiscriminadamente (por exemplo, via `replace_na`) sem considerar o significado substantivo.
- Realizar junções (*joins*) entre tabelas sem validar chaves, criando duplicações artificiais.
- Remover colunas inteiras apenas por conterem `NA`, sem avaliar sua relevância analítica.
- Imputar a variável resposta sem justificativa metodológica.

Sugestões da literatura

Segundo Little; Rubin (2019), o tratamento adequado depende do mecanismo de ausência:

- **MCAR (Missing Completely At Random)**: ausência independente de variáveis observadas e não observadas.
- **MAR (Missing At Random)**: ausência depende apenas de variáveis observadas.
- **MNAR (Missing Not At Random)**: ausência depende de informação não observada.

Em situações simples e com baixa proporção de faltantes, imputações por média ou mediana podem ser aceitáveis como aproximação. Em contextos mais complexos, recomenda-se imputação múltipla ou métodos baseados em modelos, preservando a incerteza associada ao processo.

Como minimizar problemas

- Mapear sistematicamente os valores ausentes com `is.na()` e quantificar proporções por variável.
- Identificar códigos artificiais de ausência (`999`, `-1`, `" "`) e recodificá-los para `NA`.
- Avaliar a importância substantiva da variável antes de decidir pela exclusão.
- Documentar cada remoção ou imputação realizada.
- Para duplicatas associadas a junções, utilizar verificações de chave e funções como `duplicated()` ou `distinct()`.

A decisão deve ser estatística e substantiva.

Boas práticas

- Manter um log explícito das decisões tomadas.
- Comparar estatísticas descritivas antes e depois da imputação.
- Evitar alterar a distribuição da variável de forma não justificada.

- Não imputar automaticamente a variável resposta nesta etapa, salvo sob estratégia metodológica claramente definida.

Procedimento recomendado

1. Calcular a taxa de faltantes por coluna.
2. Identificar padrões estruturais de ausência.
3. Classificar o possível mecanismo (MCAR/MAR/MNAR).
4. Definir estratégia:
 - excluir observações,
 - imputar (média, mediana, por grupo ou múltipla),
 - manter e modelar posteriormente o mecanismo de ausência.
5. Registrar todas as decisões no log de tratamento.

Tratamento de dados faltantes não é apenas limpeza — é uma decisão inferencial que pode alterar os resultados do modelo.

17.4 Detecção de valores extremos e inconsistências

Valores extremos (outliers) podem ser resultado de erro de digitação, inconsistência de unidade ou representar fenômenos reais raros. Em regressão, esses pontos podem influenciar de forma desproporcional os estimadores $\hat{\beta}$, os resíduos e os diagnósticos de ajuste.

Nem todo valor extremo é um erro, mas todo valor extremo exige investigação.

Erros clássicos

- Remover automaticamente qualquer ponto extremo sem verificar sua origem.
- Estabelecer cortes arbitrários sem registrar critérios e justificativas.
- Transformar a variável resposta sem considerar a nova interpretação dos coeficientes.
- Ignorar a possibilidade de que o ponto seja informativo para o fenômeno estudado.

Segundo Charnet et al. (2008) e Sheather (2009), valores extremos podem distorcer estimativas, ampliar variâncias e comprometer testes de hipóteses.

Barnett; Lewis (1994) oferecem fundamentos formais para detecção de outliers em análises univariadas e multivariadas, distinguindo entre:

- Observações extremas na distribuição marginal;
- Pontos de alta alavancagem (leverage);
- Observações influentes (que alteram substancialmente o ajuste do modelo).

Embora diagnósticos formais de influência sejam discutidos em outros capítulos, a identificação preliminar já deve ocorrer nesta etapa.

Ferramentas R

Para inspeção inicial:

- `quantile()` — limites interquartílicos
- `sd()` e `scale()` — padronização e z-score
- `summary()` — inspeção geral

Visualizações:

- `ggplot2::geom_boxplot()`
- `ggplot2::geom_histogram()`
- `ggplot2::geom_point()`

A visualização frequentemente revela padrões que estatísticas isoladas não mostram.

Como resolver ou minimizar efeitos

- Confirmar se o valor resulta de erro de digitação ou unidade (ex.: centímetros vs metros).
- Corrigir inconsistências quando verificadas documentalmente.
- Aplicar winsorização (`DescTools::Winsorize`) quando a estratégia for limitar extremos mantendo observações.
- Utilizar transformações (log, raiz quadrada) quando houver forte assimetria.
- Manter a observação quando for substantivamente plausível e documentar a decisão.

A remoção deve ser exceção, não regra.

Observação importante

Eliminar valores extremos altera a distribuição da variável, o tamanho da amostra e potencialmente a matriz **X**. Toda decisão deve ser registrada no log de tratamento.

17.5 Padronização e transformações numéricas

Padronizar variáveis numéricas torna os preditores comparáveis em escala e pode melhorar a estabilidade numérica de procedimentos de estimação. Transformações adequadas, por sua vez, reduzem assimetria, estabilizam variância e facilitam interpretações coerentes com o fenômeno estudado.

Em regressão linear clássica, a padronização não altera o ajuste global do modelo nem o R^2 , mas modifica a escala dos coeficientes e sua interpretação. Já em métodos penalizados (Ridge e LASSO), a padronização é praticamente indispensável.

Charnet et al. (2008) ressaltam que variáveis em escalas muito distintas podem gerar instabilidade numérica e dificultar a comparação entre efeitos.

Sheather (2009) destaca que reescalar variáveis pode facilitar a interpretação de coeficientes em regressões múltiplas, especialmente quando as unidades originais são muito grandes ou muito pequenas.

Montgomery; Peck; Vining (2021) enfatizam que diferenças extremas de magnitude entre covariáveis podem afetar diagnósticos e procedimentos computacionais.

Ferramentas R

- `scale()` — padronização pelo z-score (média zero e desvio padrão um).
- Reescala min-max — pode ser feita manualmente via transformações aritméticas.
- `MASS::boxcox()` — identificação de transformações do tipo Box-Cox.
- `log()` ou `log1p()` — transformações logarítmicas (úteis para assimetria positiva).
- Transformações via `dplyr::mutate()` para aplicação sistemática.

A escolha da transformação deve ser guiada pelo comportamento empírico da variável e pelo contexto substantivo.

Soluções recomendadas na literatura

- Para variáveis altamente assimétricas, aplicar transformações logarítmicas pode aproximar a normalidade e reduzir heterocedasticidade.
- Para contagens moderadas, Paula (2004) sugere transformação por raiz quadrada como alternativa simples.
- Para distribuições fortemente assimétricas, considerar Box–Cox quando apropriado.
- Evitar misturar variáveis em escalas radicalmente diferentes sem padronização prévia.

Quando padronizar

- Para comparar magnitudes relativas entre preditores.
- Para métodos penalizados (Ridge, LASSO), em que a penalização depende da escala.
- Para algoritmos baseados em distância ou otimização numérica.
- Quando unidades originais dificultam interpretação direta.

Padronizar não é obrigação universal; é uma decisão metodológica que deve preservar a interpretabilidade do modelo.

17.6 Codificação de variáveis categóricas (dummies)

Uma variável categórica com k níveis não pode entrar diretamente como coluna numérica em $\mathbf{X}$. É necessário convertê-la em variáveis indicadoras (dummies), usualmente em número $k - 1$, para evitar colinearidade perfeita.

A escolha da codificação determina a interpretação dos coeficientes estimados.

Erros comuns

- Criar k dummies para k categorias (armadilha da variável dummy), gerando singularidade em $\mathbf{X}^T \mathbf{X}$.
- Escolher categoria de referência sem critério substantivo.
- Manter níveis raros, produzindo colunas quase vazias e estimativas instáveis.
- Usar rótulos inconsistentes (acentos, abreviações, maiúsculas/minúsculas misturadas).
- Tratar variável ordinal como nominal sem refletir sobre a estrutura de ordem.

Conexão com a modelagem

Quando uma variável categórica é convertida corretamente em $k - 1$ dummies, cada coeficiente estimado representa a diferença média entre aquela categoria e a categoria de referência, mantendo os demais preditores constantes.

Se todas as k dummies forem incluídas juntamente com o intercepto, ocorre dependência linear exata, tornando $\mathbf{X}^T \mathbf{X}$ não invertível no caso clássico de MRLM.

Portanto, a codificação correta não é apenas conveniência computacional, é condição para a existência do estimador de mínimos quadrados.

Fundamentação teórica

Charnet et al. (2008) destacam a importância da escolha da categoria de referência para interpretação dos coeficientes.

James et al. (2013) discutem como alta cardinalidade pode gerar modelos instáveis e sobreajustados.

Para variáveis ordinais, a estrutura de ordenação pode ser incorporada explicitamente, evitando perda de informação.

Ferramentas R

- `model.matrix()` — gera automaticamente a matriz de projeto com codificação apropriada.
- `fastDummies` — criação explícita de variáveis indicadoras.
- `recipes::step_dummy()` — codificação sistemática em pipelines.
- `forcats` — manipulação e reorganização de níveis.
- Fatores ordenados (`ordered`) para variáveis com hierarquia natural.

O R, por padrão, utiliza codificação por tratamento (*treatment contrasts*), mas outras codificações podem ser especificadas conforme necessidade.

Boas práticas

- Definir categoria de referência com base em critério substantivo (grupo controle, baseline, padrão).
- Agrupar níveis raros quando apropriado.
- Manter um dicionário de variáveis documentando níveis e significados.
- Padronizar rótulos antes da geração de dummies.
- Verificar o número final de parâmetros gerados após codificação.

Atenção à alta cardinalidade

Variáveis com muitos níveis distintos podem gerar dezenas ou centenas de colunas em $\mathbf{X}$, aumentando dimensionalidade e risco de sobreajuste.

Nesses casos, considere:

- Agrupamento por regras de negócio;
- Seleção de variáveis;
- Métodos penalizados (quando apropriado na etapa seguinte).

Codificar corretamente é garantir que a estrutura qualitativa do fenômeno seja traduzida adequadamente para o modelo quantitativo.

17.7 Verificação de condições para modelagem linear

Cumprir condições mínimas como variabilidade das covariáveis, ausência de colinearidade perfeita e tamanho amostral adequado ($n > p + 1$) é o que permite aplicar os resultados teóricos da regressão linear e múltipla com segurança.

No modelo linear clássico, a existência do estimador de mínimos quadrados depende de $\mathbf{X}^\top \mathbf{X}$ ser invertível, o que exige que a matriz de projeto $\mathbf{X}$ tenha posto completo. Assim, esta verificação não é opcional — é estrutural. (Searle (2016))

Essas checagens antecedem os diagnósticos formais e reduzem problemas posteriores na estimação e interpretação.

Ferramentas R úteis

- `cor()` ou pacote `corrr` — inspeção de associações entre preditores.
- `qr()` ou `Matrix::rankMatrix()` — verificação do posto da matriz de projeto.

- `car::vif()` — cálculo do fator de inflação da variância (VIF). (Fox; Weisberg (2024))
- `summary()` e inspeção de variância — identificação de variáveis constantes.

Essas ferramentas ajudam a identificar:

- Colinearidade perfeita ou quase perfeita;
- Variáveis constantes ou quase constantes;
- Relações lineares redundantes entre preditores.

Como mitigar problemas

- Remover ou combinar variáveis altamente correlacionadas.
- Revisar a codificação de dummies para evitar dependência linear.
- Padronizar variáveis quando necessário.
- Eliminar duplicatas estruturais na base.
- Reduzir dimensionalidade quando p se aproxima de n .

Toda verificação deve ser documentada no relatório de tratamento.

Compatibilidade da variável resposta

Antes da modelagem, é essencial verificar se o tipo da variável resposta é compatível com o modelo pretendido:

- **Contínua:** variável em escala intervalar ou razão.
- **Binária:** 0/1 ou fator com dois níveis.
- **Contagem:** inteiros não negativos.
- **Proporção:** valores no intervalo $[0, 1]$.

Escolher modelo inadequado ao tipo de resposta gera inferências inválidas.

Tabela-guia: tipo de resposta e cuidados

Tipo de resposta	Exemplo	Tratamento pré-modelo	Modelo típico
Contínua	Preço, temperatura	Verificar outliers, padronização e unidades	MRLS, MRLM
Binária	Sucesso/fracasso	Conferir codificação 0/1, balanceamento e faltantes	Logístico, Probit
Contagem	Nº de eventos	Avaliar zeros estruturais e dispersão	Poisson, Binomial Negativa
Proporção	Taxa, share	Verificar limites 0/1 e denominadores	Beta, Quasi-binomial

Modelar sem verificar essas condições equivale a aplicar teoria sob premissas não verificadas. O tratamento adequado garante que a transição para a modelagem seja matemática e estatisticamente legítima.

17.8 Sumários e visualizações exploratórias

Explorar os dados antes da modelagem permite identificar padrões, inconsistências e relações estruturais que orientam decisões de limpeza, transformação e especificação do modelo.

A visualização não substitui a modelagem, ela antecipa problemas e revela estruturas que podem afetar a construção de X e a escolha do modelo. (Tufte (2001))

Ferramentas R

Funções e pacotes úteis nesta etapa:

- `summary()` — estatísticas descritivas básicas.
- `table()` ou `dplyr::count()` — frequências de variáveis categóricas.
- `ggplot2` — histogramas, boxplots, gráficos de dispersão.
- `GGally::ggpairs()` — matriz gráfica de dispersão.
- `corrplot` ou `ggcorrplot` — visualização de matrizes de correlação.
- `plotly` — visualizações interativas (opcional).

O objetivo é compreender estrutura, dispersão, assimetria e possíveis relações lineares preliminares.

Como resolver dificuldades comuns

- Distribuições muito assimétricas → aplicar transformações (log, raiz quadrada) e reavaliar.
- Categorias vazias ou raras → reclassificar níveis ou agrupar.
- Escalas muito distintas → padronizar antes de comparar magnitudes.
- Correlações elevadas entre preditores → revisar especificação do modelo.

Visualizar é diagnosticar antes do diagnóstico formal.

Produtos esperados

Ao final da etapa exploratória, espera-se:

- Tabela de estatísticas descritivas por variável numérica (média, desvio padrão, p5, p50, p95).
- Frequência absoluta e relativa por variável categórica.
- Histogramas e boxplots para avaliar distribuição.
- Gráficos de dispersão entre Y e cada X .
- Matriz de correlação entre preditores numéricos.

Esses produtos funcionam como evidência documental do entendimento da base antes da modelagem.

Perguntas-guia

- Alguma variável apresenta assimetria extrema?
- Existem valores fora de faixa plausível?
- Há categorias quase vazias?
- Quais pares de X apresentam correlação elevada?
- A relação entre Y e X parece aproximadamente linear?

Responder a essas perguntas reduz erros na etapa seguinte.

Mapa de funções em R (resumo operacional)

- **Leitura:** `read_csv`, `read_delim`, `read_excel`.
- **Inspeção:** `glimpse`, `summary`, `count`.

- **Transformação:** `mutate`, `across`, `scale`.
- **Tipagem:** `as.numeric`, `as.Date`, `factor`.
- **Correlação:** `cor`.
- **Matriz de projeto:** `model.matrix`.
- **Diagnóstico estrutural:** `qr`, `rankMatrix`, `vif`.

A exploração sistemática consolida a transição entre tratamento de dados e modelagem estatística.

17.9 Salvamento e documentação da base tratada

A documentação do tratamento (log + dicionário) e o versionamento adequado garantem reprodutibilidade, transparência metodológica e facilitam revisão por pares.

Em regressão, a qualidade das inferências depende não apenas do modelo ajustado, mas da rastreabilidade das decisões tomadas antes da modelagem.

O que entregar ao final do tratamento

1. Base final tratada (formato padrão, por exemplo: CSV).
2. Dicionário de variáveis contendo:
 - Nome da variável
 - Tipo
 - Unidade (quando aplicável)
 - Níveis (para categóricas)
 - Origem ou transformação realizada
3. Log de decisões documentando:
 - O que foi modificado
 - Por que foi modificado
 - Quando foi modificado
4. Script reproduzível contendo todas as etapas do tratamento (opcional, mas altamente recomendado).

O objetivo é que qualquer outro pesquisador consiga reconstruir exatamente a base utilizada na modelagem.

Convenções úteis

- Utilizar nome de arquivo com carimbo de data, por exemplo:
`base_tratada_2025-10-26.csv`
- Manter script de preparo versionado e comentado.
- Utilizar estrutura organizada de pastas:
 - `dados_brutos/`
 - `dados_interinos/`
 - `dados_tratados/`

Nunca sobrescrever dados brutos.

Pipelines modernos e reprodutibilidade

Em aplicações contemporâneas, o tratamento de dados é frequentemente organizado em **pipelines**: sequências estruturadas de leitura → transformação → validação → saída tratada → modelagem.

Esse fluxo reduz erros humanos, aumenta consistência e fortalece a reprodutibilidade científica. No ecossistema R, essa abordagem é facilitada por ferramentas como `tidyverse`, `recipes` e estruturas de modelagem integradas.

Mesmo quando não formalizado em código automatizado, o processo deve ser concebido como um fluxo explícito, sequencial e documentado.

Modelar é o passo visível; documentar é o passo que garante credibilidade.

17.10 Checklist técnico: Condições mínimas para seguir à modelagem

Este checklist consolida os critérios estruturais que devem ser verificados ao final do tratamento de dados, antes do ajuste de qualquer modelo de regressão.

1. **Variabilidade das covariáveis:** nenhuma variável explicativa deve ser constante ou quase constante.
2. **Ausência de colinearidade perfeita:** a matriz $\mathbf{X}$ deve ter posto completo; logo, $\mathbf{X}^\top \mathbf{X}$ deve ser não singular.
3. **Tamanho amostral adequado:** $n > p + 1$ no caso do modelo linear com intercepto; caso contrário, considere reduzir dimensionalidade ou ampliar a amostra.
4. **Escalas compatíveis:** quando necessário, variáveis reescaladas ou padronizadas para evitar instabilidade numérica.
5. **Tipos de dados conferidos:** variáveis numéricas, categóricas e temporais corretamente tipadas.
6. **Ausência de erros estruturais:** duplicatas removidas, chaves validadas e inconsistências corrigidas.
7. **Base salva e documentada:** versão final armazenada com data, autor e dicionário de variáveis.
8. **Pronta para modelagem:** a base pode ser utilizada diretamente em MRLS, MRLM, MLG ou métodos penalizados sem retrabalho estrutural.

O não atendimento a qualquer desses critérios compromete a legitimidade estatística do modelo. A qualidade de toda inferência estatística depende dessa distinção, e ela começa antes do ajuste do primeiro modelo.

Ao finalizar o tratamento de uma base, tente **ajustar um modelo simples apenas para validar tipos e dummies** (sem discutir resultados). Se rodar sem erros e os sumários fizerem sentido, a base está pronta para a próxima unidade.

17.11 Glossário

Encoding (codificação de caracteres)

Como o computador guarda letras com acentos e símbolos. Exemplos: **UTF-8**, **latin-1**. Se o encoding está errado, aparecem “” ou letras quebradas.

Delimitador / Separador

Símbolo que separa colunas em arquivos de texto. Exemplos: vírgula  , ponto e vírgula  ; , tab  .

Decimal (símbolo decimal)

O símbolo que separa parte inteira e fracionária. Em pt-BR, vírgula (ex.: ); em en-US, ponto ().

CSV, XLSX, SAV, DTA

Formatos de planilha/tabela. **CSV**: texto simples; **XLSX**: Excel; **SAV**: SPSS; **DTA**: Stata.

Licença (de uso dos dados)

Condições legais de uso/compartilhamento do dataset (ex.: CC-BY). Leia antes de usar.

Faltante / Dados faltantes

Informação ausente em uma célula. Pode aparecer como **NA**, **NaN**, vazio  ou códigos como .

MCAR, MAR, MNAR

Tipos de mecanismo de ausência: **MCAR** (ausência completamente ao acaso), **MAR** (ao acaso condicional a outras variáveis), **MNAR** (não ao acaso; depende do próprio valor ausente).

Duplicatas e chaves

Duplicata: linha repetida. **Chave**: coluna (ou combinação) que identifica exclusivamente cada linha (ex.: `id`).

Log de duplicatas / Log de tratamento

Registro simples do que foi removido/alterado e por quê. Ajuda na reprodutibilidade.

Outlier

Valor muito fora do padrão do conjunto. Pode ser erro, evento raro ou caso especial.

Winsorização (winsorize)

Técnica que **limita** valores extremos a um limite (ex.: truncar no percentil 1% e 99%) para reduzir impacto de outliers.

Reescala / Padronização (z-score)

Colocar variáveis em escala comparável. **z-score**: subtrai a média e divide pelo desvio-padrão (fica média 0 e dp 1).

min-max: leva para [0,1] pela fórmula $(x - \min) / (\max - \min)$.

Cardinalidade (de categorias)

Número de níveis distintos de uma variável categórica. Alta cardinalidade = muitos níveis.

Padronizar rótulos

Escrever categorias de forma consistente (ex.: tudo minúsculo, sem acento, sem espaços extras), unificando sinônimos.

Dummies (one-hot)

Transformar uma variável categórica em colunas 0/1 (uma coluna a menos que o número de categorias, para evitar colinearidade perfeita).

Variável ordinal

Categorias que **têm ordem** (ex.: fundamental < médio < superior).

Zeros estruturais

Zeros esperados por construção (ex.: aluguel de bicicletas à 03h pode ser zero). Diferem de “zeros por acaso”.

Regularização (Ridge, LASSO)

Técnicas que penalizam coeficientes para lidar com muitas variáveis e reduzir sobreajuste; exigem atenção à **escala** dos preditores.

JSON

Formato de texto para dados estruturados em pares chave:valor (não será foco aqui; usamos tabelas).

Pipeline

Sequência organizada de passos de tratamento: leitura → limpeza → transformação → verificação → saída tratada.