

18 Exercícios e Atividades de Consolidação

18.1 Exercícios conceituais

18.1.1 Estrutura Matricial dos Modelos de Regressão Linear

1. Suponha $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$, $\mathbf{Y} \in \mathbb{R}^n$ e $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$.

a. Indique as dimensões de $\mathbf{X}^\top \mathbf{X}$, $\mathbf{X}^\top \mathbf{Y}$ e $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$.

b. Mostre por que $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ só faz sentido quando $\mathbf{X}^\top \mathbf{X}$ é invertível.

2. Explique, em termos de colunas de $\mathbf{X}$, o que significa $\text{rank}(\mathbf{X}) = p + 1$.

a. Interprete geometricamente essa condição.

b. Relacione-a com a unicidade do estimador de mínimos quadrados.

3. Partindo do problema

$$\min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2,$$

mostre que a condição de primeira ordem é

$$\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}.$$

Interprete essa igualdade como uma condição de ortogonalidade.

4. Defina $\text{col}(\mathbf{X})$ e descreva, em palavras, o conjunto

$$\{\mathbf{X}\boldsymbol{\beta} : \boldsymbol{\beta} \in \mathbb{R}^{p+1}\}.$$

Por que $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ pertence a esse conjunto?

5. Explique o significado de

$$\mathbb{R}^n = \text{col}(\mathbf{X}) \oplus \text{col}(\mathbf{X})^\perp.$$

a) O que garante a unicidade da decomposição $\mathbf{Y} = \hat{\mathbf{Y}} + \hat{\boldsymbol{\epsilon}}$?

b) O que significa $\hat{\mathbf{Y}}^\top \hat{\boldsymbol{\epsilon}} = 0$ em termos geométricos?

6. Considere

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top, \quad \mathbf{M} = \mathbf{I}_n - \mathbf{H}.$$

a) Explique por que $\mathbf{H}$ é uma projeção sobre $\text{col}(\mathbf{X})$.

b) Explique por que $\mathbf{M}$ projeta sobre $\text{col}(\mathbf{X})^\perp$.

7. Mostre que, quando $\mathbf{X}^\top \mathbf{X}$ é invertível, valem:

$$\mathbf{H}^\top = \mathbf{H}, \quad \mathbf{H}^2 = \mathbf{H}, \quad \mathbf{M}^\top = \mathbf{M}, \quad \mathbf{M}^2 = \mathbf{M}.$$

Interprete o que “idempotente” significa operacionalmente em uma projeção.

8. Justifique por que, para matrizes simétricas idempotentes, o traço coincide com o posto. Em particular, explique por que, no caso de posto completo de $\mathbf{X}$,

$$\text{tr}(\mathbf{H}) = p + 1, \quad \text{tr}(\mathbf{M}) = n - p - 1.$$

9. Use $\mathbf{Y} = \mathbf{H}\mathbf{Y} + \mathbf{M}\mathbf{Y}$ para deduzir:

$$\mathbf{Y}^\top \mathbf{Y} = \mathbf{Y}^\top \mathbf{H}\mathbf{Y} + \mathbf{Y}^\top \mathbf{M}\mathbf{Y}.$$

Explique por que essa decomposição é “puramente geométrica” (isto é, não usa hipóteses probabilísticas).

10. Dê um exemplo concreto, com $\mathbf{x} \in \mathbb{R}^2$ e $\mathbf{A}$ simétrica 2×2 , e escreva explicitamente $\mathbf{x}^\top \mathbf{A} \mathbf{x}$. Em seguida, explique por que $\mathbf{Y}^\top \mathbf{H}\mathbf{Y}$ e $\mathbf{Y}^\top \mathbf{M}\mathbf{Y}$ são formas quadráticas.

11. Descreva um cenário simples em que uma coluna de $\mathbf{X}$ seja combinação linear das demais.

- O que acontece com $\mathbf{X}^\top \mathbf{X}$?
- O que acontece com $\hat{\boldsymbol{\beta}}$ (unicidade)?
- Como SVD/pseudoinversa se relacionam com essa situação (em alto nível, sem detalhes técnicos)?

12. Considere $h_{ii} = (\mathbf{H})_{ii}$.

- Por que $0 \leq h_{ii} \leq 1$?
- Por que $\sum_{i=1}^n h_{ii} = p + 1$?
- Interprete “alavancagem alta” geometricamente (no espaço das covariáveis).

13. Mostre que $\mathbf{X}^\top \hat{\boldsymbol{\varepsilon}} = \mathbf{0}$, onde $\hat{\boldsymbol{\varepsilon}} = \mathbf{M}\mathbf{Y}$. Interprete essa propriedade como “resíduos ortogonais às colunas de $\mathbf{X}$ ”.

14. Explique por que $S(\boldsymbol{\beta}) = \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2$ é convexa em $\boldsymbol{\beta}$. Em que condição ela é *estritamente* convexa? Relacione com “solução única”.

15. Sem usar cálculos longos, explique por que $\mathbf{H}\mathbf{Y}$ é o vetor ajustado e $\mathbf{M}\mathbf{Y}$ é o vetor residual. Dica: use as afirmações “pertence a $\text{col}(\mathbf{X})$ ” e “pertence ao complemento ortogonal”.

18.1.2 Distribuição Normal

1. Seja $Y \sim N(\mu, \sigma^2)$. Explique, em palavras, o significado de μ e de σ^2 como quantidades populacionais. Em seguida, explique por que σ^2 não deve ser interpretada como “erro do modelo” fora do contexto de regressão.

2. Se $Y \sim N(\mu, \sigma^2)$ e $Z = aY + b$ com $a \neq 0$, determine:

- $\mathbb{E}[Z]$;
- $\text{Var}(Z)$;
- a distribuição de Z (nome + parâmetros).

3. Defina $Z = (Y - \mu)/\sigma$ para $Y \sim N(\mu, \sigma^2)$.

- Qual é a distribuição de Z ?
- Interprete o significado de $Z = 2$ em termos da variável original Y .

4. Explique (sem fórmulas) por que a Normalidade não define o modelo de regressão linear, mas é frequentemente usada para obter resultados exatos de inferência em amostras finitas.

5. No caso bivariado, a matriz

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

- codifica variabilidade e dependência. a) O que representam os elementos da diagonal?
b) O que representam os elementos fora da diagonal?
c) O que muda geometricamente quando $\rho = 0$ vs. $\rho \neq 0$?

6. Seja $(Y_1, Y_2)^\top \sim N_2(\boldsymbol{\mu}, \Sigma)$.

- Escreva as distribuições marginais de Y_1 e Y_2 .
- Explique por que “marginalmente Normal” não implica independência.

7. Para a Normal bivariada, sabe-se que

$$Y_1 \mid Y_2 = y_2 \sim N\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y_2 - \mu_2), (1 - \rho^2)\sigma_1^2\right).$$

- Identifique a média condicional e variância condicional.
- Explique por que a média condicional é uma função linear de y_2 .
- Compare $\text{Var}(Y_1 \mid Y_2)$ com $\text{Var}(Y_1)$ e interprete.

8. Se $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \Sigma)$ e $\mathbf{Z} = \mathbf{A}\mathbf{Y} + \mathbf{a}$:

- Qual é a distribuição de $\mathbf{Z}$? (nome + parâmetros)
- Qual é a dimensão de $\mathbf{Z}$ em função de $\mathbf{A}$?
- Interprete o papel de $\mathbf{A}\Sigma\mathbf{A}^\top$.

9. Considere

$$Q = (\mathbf{Y} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{Y} - \boldsymbol{\mu}).$$

- O que Q mede, intuitivamente?
- Qual é a distribuição de Q quando $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \Sigma)$?
- Em que sentido essa “distância” difere da distância euclidiana?

10. Considere

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{bmatrix} \sim N_n\left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}\right).$$

- Escreva as distribuições marginais de $\mathbf{Y}_1$ e $\mathbf{Y}_2$.
- Escreva a distribuição condicional de $\mathbf{Y}_1 \mid \mathbf{Y}_2 = \mathbf{y}_2$ (média e covariância).
- Explique por que a covariância condicional é “menor” (no sentido de incerteza) do que Σ_{11} .

11. Explique por que:

- em geral, $\text{Cov}(U, V) = 0$ não implica independência.
- no caso Normal multivariado, covariância zero implica independência (sem demonstrar).

12. No modelo

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n),$$

- Determine a distribuição de $\mathbf{Y}$ (nome + parâmetros).
- Explique por que $\hat{\boldsymbol{\beta}}$ é Normal (use apenas a ideia “transformação linear preserva Normalidade”).
- Dê um exemplo de quantidade importante em regressão que é uma forma quadrática em $\mathbf{Y}$.

18.1.3 Formas Lineares e Quadráticas na Normal Multivariada

1. Seja $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{Z} = \mathbf{A}\mathbf{Y} + \mathbf{a}$, com $\mathbf{A}$ de dimensão $m \times n$ e $\mathbf{a} \in \mathbb{R}^m$.

- Qual é a dimensão de $\mathbf{Z}$?
- Escreva a média e a covariância de $\mathbf{Z}$.
- Interprete, em palavras, por que $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ aparece como covariância.

2. Para um vetor fixo $\mathbf{c} \in \mathbb{R}^n$, defina $L = \mathbf{c}^\top \mathbf{Y}$.

- Qual é a distribuição de L ?
- Qual é a interpretação de $\mathbf{c}^\top \boldsymbol{\mu}$?
- Dê um exemplo, no contexto de regressão, de uma quantidade que tenha a forma $\mathbf{c}^\top \mathbf{Y}$.

3. Defina $\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2}(\mathbf{Y} - \boldsymbol{\mu})$.

- Qual é a distribuição de $\mathbf{Z}$?
- Mostre (por manipulação algébrica) que

$$(\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{Y} - \boldsymbol{\mu}) = \mathbf{Z}^\top \mathbf{Z}.$$

c) Explique, em palavras, o que significa "reduzir ao caso esférico".

4. Seja $Q = \mathbf{Y}^\top \mathbf{A} \mathbf{Y}$.

- Por que podemos assumir $\mathbf{A}$ simétrica “sem perda de generalidade”?
- Escreva explicitamente a matriz simétrica associada a $\mathbf{A}$ que produz o mesmo Q .
- Em regressão, cite duas somas de quadrados que são formas quadráticas em $\mathbf{Y}$.

5. Se $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$:

- Qual é a distribuição de $\mathbf{Z}^\top \mathbf{Z}$?
- Por que esse resultado depende da independência das componentes de $\mathbf{Z}$?
- Relacione esse resultado com a interpretação de “soma de quadrados” em regressão.

6. Seja $\mathbf{A}$ simétrica e idempotente e $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$.

- Qual é a distribuição de $\mathbf{Z}^\top \mathbf{A} \mathbf{Z}$ em termos de $r = \text{rank}(\mathbf{A})$?
- Interprete geometricamente o que mede $\mathbf{Z}^\top \mathbf{A} \mathbf{Z}$.
- Explique por que o “número de graus de liberdade” coincide com $\text{tr}(\mathbf{A})$ nesse caso.

7. Suponha $\mathbf{A}$ e $\mathbf{B}$ simétricas idempotentes e $\mathbf{A}\mathbf{B} = \mathbf{0}$.

- O que significa geometricamente a condição $\mathbf{A}\mathbf{B} = \mathbf{0}$?
- Qual conclusão probabilística é válida para $\mathbf{Z}^\top \mathbf{A} \mathbf{Z}$ e $\mathbf{Z}^\top \mathbf{B} \mathbf{Z}$ quando $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$?
- Dê um exemplo (em regressão) de duas formas quadráticas independentes obtidas por projeções ortogonais.

8. Seja $L = \mathbf{a}^\top \mathbf{Z}$ e $Q = \mathbf{Z}^\top \mathbf{A} \mathbf{Z}$, com $\mathbf{Z} \sim N_n(\mathbf{0}, \mathbf{I}_n)$ e $\mathbf{A}$ simétrica idempotente.

- Qual condição sobre $\mathbf{A}$ e $\mathbf{a}$ garante independência entre L e Q ?
- Interprete essa condição geometricamente.
- No MRLM, identifique uma situação típica em que um contraste linear é independente de uma soma de quadrados residual.

9. Considere o MRLM sob normalidade:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

e $\hat{\boldsymbol{\beta}}$ como forma linear.

- Mostre que $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ é transformação linear de $\mathbf{Y}$.
- Escreva $\mathbb{E}(\hat{\boldsymbol{\beta}})$ e $\text{Cov}(\hat{\boldsymbol{\beta}})$.
- Explique por que, sob normalidade, $\hat{\boldsymbol{\beta}}$ tem distribuição Normal multivariada exata.

18.1.4 Tratamento de dados

- Explique por que o tratamento de dados não é uma etapa meramente operacional, mas parte do raciocínio estatístico aplicado. Em sua resposta, discuta como erros de leitura, tipagem ou codificação podem afetar diretamente a construção da matriz de projeto $\mathbf{X}$ e a interpretação dos coeficientes estimados.
- Diferencie os mecanismos de ausência MCAR, MAR e MNAR. Para cada caso, discuta qualitativamente como a escolha entre excluir observações e imputar valores pode afetar viés, variância e interpretação do modelo de regressão.
- Justifique por que criar k dummies para uma variável categórica com k níveis, mantendo intercepto no modelo, gera singularidade em $\mathbf{X}^\top \mathbf{X}$. Relacione sua resposta com o conceito de posto completo da matriz $\mathbf{X}$.

4. Discuta a diferença entre:

- o valor extremo na distribuição marginal;
- o ponto de alta alavancagem;
- o observação influente.

Por que nem todo outlier deve ser removido automaticamente?

- Explique por que identificadores numéricos (por exemplo, código do aluno ou número de matrícula) não devem ser tratados como variáveis quantitativas na regressão, mesmo sendo números.
- Em que situações a padronização (z-score) é recomendável? Em que situações pode prejudicar a interpretação dos coeficientes? Discuta separadamente os casos de regressão linear clássica e métodos penalizados.
- Mostre por que a condição $n > p + 1$ é necessária (mas não suficiente) para a existência do estimador de mínimos quadrados no modelo linear com intercepto. Qual condição matricial adicional é estruturalmente indispensável?
- Explique o que são zeros estruturais em dados de contagem e por que sua presença pode indicar a necessidade de modelos diferentes daqueles utilizados para respostas contínuas.
- Discuta a importância do log de decisões no tratamento de dados. Por que a reprodutibilidade é parte da legitimidade estatística da inferência?
- Considere uma variável resposta binária codificada como 0 e 1. Explique por que ajustar uma regressão linear clássica pode produzir predições fora do intervalo $[0, 1]$ e por que isso motiva o uso de modelos específicos para respostas binárias.
- Ao integrar duas bases por meio de uma junção (*join*), explique como duplicações inesperadas podem alterar médias, totais e estimativas de regressão. Que verificações estruturais devem ser feitas antes e depois da junção?

12. Explique por que remover observações com dados faltantes pode equivaler, na prática, a realizar uma seleção amostral não planejada. Em que contexto essa decisão pode comprometer a validade externa do estudo?
13. Discuta a relação entre alta cardinalidade em variáveis categóricas e risco de sobreajuste. Por que o aumento do número de parâmetros pode afetar variância dos estimadores e estabilidade do modelo?
14. Explique por que a verificação de variáveis constantes ou quase constantes é uma etapa estrutural antes da modelagem. Qual o efeito de uma variável constante na matriz $\mathbf{X}$?
15. Elabore um pequeno roteiro conceitual (sem código) descrevendo o fluxo ideal: leitura → tipagem → verificação de faltantes → tratamento de inconsistências → padronização → verificação estrutural → documentação. Justifique a ordem proposta.

18.2 Atividades computacionais

18.2.1 Estrutura Matricial dos Modelos de Regressão Linear

1. (Construção de $\mathbf{X}$) Dado um conjunto de dados com resposta Y e dois preditores (X_1, X_2) :
 - a. Construa a matriz $\mathbf{X}$ explicitamente (com intercepto).
 - b. Calcule $\mathbf{X}^\top \mathbf{X}$ e verifique se é invertível (por determinante ou posto).
 - c. Calcule $\hat{\beta}$ via fórmula matricial e compare com `lm()`.
2. (Projeção e resíduos) Para o mesmo conjunto de dados:
 - a. Calcule $\mathbf{H}$ e $\mathbf{M}$.
 - b. Verifique numericamente (tolerância) que $\mathbf{H}^2 \approx \mathbf{H}$ e $\mathbf{M}^2 \approx \mathbf{M}$.
 - c. Verifique que $\hat{\mathbf{Y}} = \mathbf{H}\mathbf{Y}$ e $\hat{\epsilon} = \mathbf{M}\mathbf{Y}$ batem com os valores de `fitted()` e `resid()` do `lm()`.
3. (Ortogonalidade) Verifique numericamente que $\hat{\mathbf{Y}}^\top \hat{\epsilon} \approx 0$ e que $\mathbf{X}^\top \hat{\epsilon} \approx \mathbf{0}$.
4. (Decomposição de somas de quadrados) Calcule:

$$\mathbf{Y}^\top \mathbf{Y}, \quad \mathbf{Y}^\top \mathbf{H}\mathbf{Y}, \quad \mathbf{Y}^\top \mathbf{M}\mathbf{Y}$$

e verifique que $\mathbf{Y}^\top \mathbf{Y} \approx \mathbf{Y}^\top \mathbf{H}\mathbf{Y} + \mathbf{Y}^\top \mathbf{M}\mathbf{Y}$.

5. (Alavancagem) Extraia $h_{ii} = (\mathbf{H})_{ii}$ e compare com `hatvalues(lm_obj)`. Identifique as 3 maiores alavancagens e descreva, com base em (X_1, X_2) , por que são “pontos extremos”.
6. (Posto deficiente) Provoque multicolinearidade perfeita criando um preditor $X_3 = X_1 + X_2$.
 - a. Verifique o posto de $\mathbf{X}$.
 - b. Observe o comportamento de `lm()` (coeficientes não estimáveis/NA) e relacione com a não-invertibilidade de $\mathbf{X}^\top \mathbf{X}$.

18.2.2 Distribuição Normal

1. Simule uma amostra grande de $N(\mu, \sigma^2)$ com $\mu \neq 0$ e $\sigma \neq 1$, padronize e verifique numericamente: média próxima de 0 e variância próxima de 1.
2. Simule dados de uma Normal bivariada com:
 - a. $\rho = 0$;

b. $\rho = 0,8$;

Faça um gráfico de dispersão e compare a orientação/forma da nuvem de pontos.

3. Simule $\mathbf{Y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, compute Q para muitas repetições e compare a distribuição empírica de Q com χ_n^2 (por exemplo, via QQ-plot).

18.2.3 Tratamento de dados

Considere as seguintes bases de dados e orientações:

Escada de dificuldade das bases

- **Nível 1 (aquecimento):** Online Shoppers: tipagem + dummies + sumários.
- **Nível 2 (intermediário):** Ames/House Prices: faltantes moderados + reescala + dicionário.
- **Nível 3 (avançado):** Student Failure (messy): chaves/duplicatas + integração + plano de imputação.
- **Extra (discreta):** Bike Sharing: temporais + zeros estruturais + outliers climáticos.

Aqui são apresentadas **bases públicas e didáticas** para exercícios de tratamento pré-modelagem. Cada item traz link de acesso, o que a base representa e **situações-problema** que motivam o tratamento. Ao final de cada base há um bloco Tarefas sugeridas para orientar o estudo.

Em todas as atividades, os entregáveis mínimos são:

1. **Base tratada** (salva em arquivo, sem sobrescrever a base original);
2. **Dicionário de variáveis**, contendo (no mínimo): nome, tipo, unidade (quando aplicável), níveis (para categóricas) e transformações realizadas;
3. **Log de decisões**, registrando o que foi alterado, por que foi alterado e como foi alterado (de forma que outra pessoa consiga reproduzir o tratamento).

18.2.3.1 House Prices: Advanced Regression Techniques (Kaggle)

- **Tipo de resposta:** Contínua (**SalePrice**).
- **Link:** <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>
- **Sobre a base:** preços de casas em Ames (Iowa, EUA), com ~79 variáveis numéricas e categóricas.
- **Situação:**
 - Muitas colunas com valores ausentes (por ex.: **LotFrontage**, **Alley**, **PoolQC**).
 - Variáveis categóricas com codificação inconsistente e níveis raros.
 - Outliers em preço e área; unidades e escalas heterogêneas.
- Excelente caso para um **pipeline completo** de limpeza (missing, tipagem, codificação, reescala) antes da regressão contínua.
- **Tarefas sugeridas:**
 1. Mapear porcentagens de faltantes por coluna e decidir estratégia (excluir, imputar, manter), explicitando a justificativa no log.
 2. Padronizar nomes e unidades; verificar outliers em **SalePrice** e **GrLivArea**, distinguindo erro provável vs. valor plausível no domínio.
 3. Unificar níveis categóricos raros e definir dummies com categoria de referência, registrando o critério de referência adotado.
 4. Verificar condições mínimas para regressão (incluindo posto de **X** e colinearidade) e registrar eventuais correções realizadas.
 5. Salvar uma versão tratada e documentar as decisões (base tratada + dicionário + log).

18.2.3.2 Ames Housing Dataset

- **Tipo de resposta:** Contínua (`SalePrice`).
- **Link:** <https://github.com/data-doctors/kaggle-house-prices-advanced-regression-techniques>
- **Sobre a base:** variação/derivação do problema de habitação de Ames, amplamente usada em cursos.
- **Situação:**
 - Mistura de tipos (numéricos + categóricos), com valores ausentes e níveis raros.
 - Recomendação frequente de transformação logarítmica da resposta.
 - Outliers estruturais (ex.: casas muito acima da média).
- Reforça o **contraste de estratégias** de tratamento em relação à anterior.
- **Tarefas sugeridas:**
 1. Comparar duas abordagens de tratamento de faltantes (ex.: imputação por mediana vs. KNN) e registrar impactos em sumários (antes/depois).
 2. Testar padronização vs. não padronização nas variáveis contínuas, descrevendo quando a padronização é útil e quando não é necessária.
 3. Avaliar a transformação da resposta (por exemplo, $\log(\text{SalePrice})$), registrando a motivação e a implicação interpretativa no dicionário.
 4. Produzir um dicionário de variáveis claro e um log de decisões completo, incluindo critérios para tratamento de níveis raros.

18.2.3.3 Online Shoppers Purchasing Intention (UCI)

- **Tipo de resposta:** Binária (`Revenue` : sim/não).
- **Link:** <https://archive.ics.uci.edu/ml/datasets/Online%2BShoppers%2BPurchasing%2BIntention%2BDataset>
- **Sobre a base:** sessões de navegação em e-commerce; objetivo é prever se a sessão termina em compra.
- **Situação:**
 - Variáveis categóricas e temporais misturadas às numéricas; necessidade de codificação.
 - Possível desbalanceamento da classe `Revenue` .
 - Datas/temporais como texto exigindo normalização e extração de componentes.
- Bom **caso de tratamento moderado**, contrastando com bases mais “sujas”.
- **Tarefas sugeridas:**
 1. Verificar distribuição de `Revenue` (balanceamento) e registrar possíveis implicações para avaliação futura do modelo.
 2. Definir dummies consistentes e padronizar escalas numéricas quando necessário, registrando as escolhas no dicionário.
 3. Criar variáveis derivadas temporais (mês, dia da semana) de forma reprodutível, mantendo o procedimento documentado no log.
 4. Verificar se há inconsistências de tipagem (numérico vs. categórico) e corrigir de forma explícita, com checagens antes/depois.

18.2.3.4 Student Failure (Messy) Dataset (Kaggle)

- **Tipo de resposta:** Binária (`fail` = 1 se o aluno reprova/sai; 0 caso contrário).
- **Link:** <https://www.kaggle.com/code/sashatarakanova/student-failure-modelling-with-a-messy-dataset>
- **Sobre a base:** dados educacionais com múltiplas tabelas heterogêneas para prever reprovação.
- **Situação:**
 - Muitos valores ausentes; tabelas com chaves não padronizadas; duplicatas.
 - Categorias inconsistentes para o mesmo conceito (ex.: formas distintas de escrever “curso”).
 - Necessidade de unificação/integração de fontes (join/merge) com validação.
- Ótimo para treinar **integração e saneamento** antes de qualquer modelagem binária.
- **Tarefas sugeridas:**

1. Reconstruir uma chave única estável e eliminar duplicatas, descrevendo a regra adotada para definir unicidade.
2. Mapear e recodificar categorias equivalentes (sinônimos, grafias diferentes) e registrar o mapeamento no dicionário.
3. Documentar um plano de imputação apropriado por variável, justificando a estratégia (ex.: por grupo, múltipla, exclusão seletiva).
4. Validar o resultado das integrações (joins) com checagens estruturais (linhas esperadas, chaves, duplicações), registrando tudo no log.

18.2.3.5 Bike Sharing Dataset (UCI)

- **Tipo de resposta:** Discreta (contagem de bicicletas alugadas por hora/dia).
- **Link:** <https://archive.ics.uci.edu/dataset/275/bike%2Bsharing%2Bdataset>
- **Sobre a base:** uso de bicicletas compartilhadas, com variáveis meteorológicas, feriados, sazonalidade e efeitos de hora do dia.
- **Situação:**
 - Contagens com muitos zeros em horários de baixa demanda e picos em horários de pico; necessidade de identificar **zeros estruturais**.
 - Variáveis temporais em formato de texto exigindo conversão e extração (hora, dia da semana, feriado).
 - Possíveis outliers (eventos climáticos extremos) e variabilidade alta da resposta.
 - Padronização de escalas e codificação consistente de feriados/sazonalidade.
 - Preparar para o tratamento de **resposta discreta (contagem)**, anterior à escolha de modelos como Poisson ou Binomial Negativa.
- **Tarefas sugeridas:**
 1. Normalizar as variáveis temporais e criar indicadores (feriado, fim de semana, hora do rush), registrando as regras de derivação.
 2. Caracterizar zeros estruturais vs. esparsidade aleatória e discutir implicações para a modelagem, mantendo essa justificativa no log.
 3. Detectar outliers climáticos e decidir estratégia (transformação, winsorização ou justificativa de manutenção), com critério explícito.
 4. Entregar uma versão tratada com dicionário e log de decisões, incluindo a checagem de consistência de limites (por exemplo, contagens não negativas).

18.2.3.6 Ao final desta atividade o leitor deverá ser capaz de:

- Diagnosticar problemas estruturais em bases tabulares;
- Identificar mecanismos de ausência;
- Construir um pipeline reproduzível de tratamento;
- Verificar condições estruturais para regressão;
- Documentar decisões de limpeza de dados.